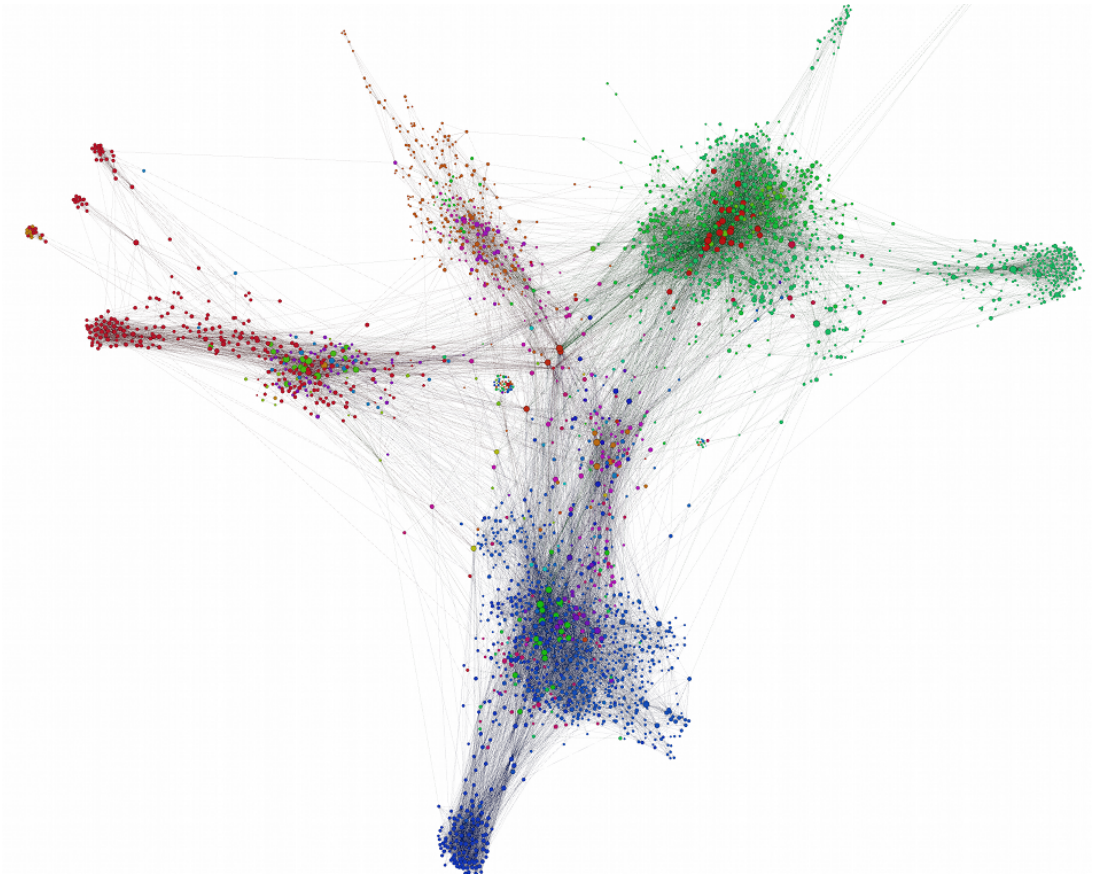
Soziale Netzwerkanalyse

©Michael Henninger

November 2024, Version 3.8.1



Inhaltsverzeichnis

I Einführung **9**

1 Aspekte der Soziologie **10**

1.1 Symbolischer Interaktionismus 10

1.1.1 Looking Glass Self 10

1.1.2 Me, Self & I 11

1.1.3 Maslowsche Bedürfnispyramide 12

1.2 Vernetzung 13

1.3 Social Forces 14

1.4 Tie Strength 17

1.5 Vernetzungs-Strategien optimieren 18

1.5.1 Exchange Theory von Homans 18

1.5.2 Structural Holes 19

1.5.3 Soziales Kapital 20

1.5.4 Link Optimierung 20

1.6 Soziale Netzwerke im Internet 21

1.6.1 Detaillierte Persönlichkeitsanalyse durch Cambridge Analytica . . 25

1.6.2 Influencer in Sozialen Medien: Vom Trend zum Beruf 27

2 Anwendungsfälle von Sozialer Netzwerkanalyse **29**

II Analyse **32**

3 Modellierung Sozialer Netzwerke **33**

3.1 Abbildung des Sozialen Netzwerks als Graph 33

3.2 Netzwerk-Typen 35

3.2.1 One-Mode Netzwerk 35

3.2.2 Multirelationales Netzwerk 36

3.2.3 Two-Mode Netzwerk 36

4 Reduktion des Netzwerks 42

4.1 Local View 42
4.2 Global View 42
4.3 Contextual View 43
4.4 Ego Netzwerk 43
4.5 Filtern anhand von Kanten-Attributen 43

5 Communities 44

5.1 Connected Components 44
5.2 Cliquen 46
5.2.1 k-Core 47
5.2.2 p-Cliques 48
5.2.3 n-Cliques 48
5.3 Clustering 50
5.3.1 Edge-Betweenness Clustering 50
5.3.2 Label Propagation 52
5.3.3 Louvain Algorithmus für Community Detection 56

6 Wichtigkeit von Knoten & Knotengruppen 61

6.1 Aktor-Zentralität 62
6.1.1 Degree Centrality 62
6.1.2 Closeness Centrality 63
6.1.3 Betweenness Centrality 65
6.1.4 Eigenvector Zentralität 69
6.2 Prestige 72
6.2.1 Indegree (Popularity) 72
6.2.2 Proximity Prestige 72
6.3 Actor Group Centrality 75
6.3.1 Degree Group Centrality 75
6.3.2 Closeness Group Centrality 75
6.3.3 Betweenness Group Centrality 76

7 Netzwerk Zentralisierung 78

7.1 Degree Zentralisierung 79
7.2 Betweenness Zentralisierung 80

7.3 Closeness Zentralisierung 81

8 Netzwerk-Metriken 83

8.1 Graph Density 83
8.2 Graph Diameter 84
8.3 Cluster Coefficient 85
8.4 Balance 87

9 Graph Connectivity 89

10 Korrelation in Netzwerken 92

10.1 Korrelationskoeffizient 94
10.2 Übliche Fehler im Zusammenhang mit Korrelation 94
10.3 Korrelationsmasse 95
10.3.1 Pearson Korrelationskoeffizient 95
10.3.2 Spearman Korrelation 96
10.4 Assortativität 98
10.4.1 Messen von Assortativität auf nummerischen Knoten-Attribute . 99
10.4.2 Messen von Assortativität auf kategorischen Knoten-Attribute . . 100

11 Inferenzielle Statistik in Netzwerken 103

11.1 Referenz-Netzwerke erzeugen 103
11.2 Aufbau von Hypothesentests 105
11.3 Arten von Hypothesentests in Netzwerken 106
11.3.1 Hypothesentests auf nummerischen Knoten-Attribute 106
11.3.2 Hypothesentests auf Kanten(-Attribute) in multirelationalen Netzwerken 107
11.3.3 Hypothesentests auf Knoten- und Kantenattribute 110
11.3.4 Hypothesentets auf Netzwerk-Metriken 112

12 Link-Prediction 113

12.1 Algorithmen 113
12.1.1 Common Neighbours 114
12.1.2 Soundarajan Hopcroft 115
12.1.3 Jaccard Coefficient 115
12.1.4 Resource Allocation 116
12.1.5 Adamic-Adar 116
12.1.6 Preferential Attachment 117

12.1.7 Weitere Algorithmen 117
12.2 Link-Prediction Experiment und Evaluation 117

13 Diffusion **121**
13.1 Independent Cascade Model (ICM) 124
13.2 Voter Model 128
13.3 Threshold Model 128

14 Graphlets **129**
14.1 Relative Graphlet Frequency Distance 130
14.2 Graphlet Degree Vektor 133

Stichwortverzeichnis **137**

Abbildungsverzeichnis

1.1 Zusammenspiel von Me, Self und I 12
1.2 Maslowsche Bedürfnispyramide 13
1.3 Balancierte und unbalancierte Triaden 17
1.4 Structural Hole 19
1.5 Die zwei Dimensionen der Link-Optimierung: Häufigkeit und Intimität . 21
1.6 Analyse von 50+ Millionen Facebook-Profilen durch Cambridge Analytica.[1] 25

3.1 Ungerichteter Graph 33
3.2 Gerichteter Graph 34
3.3 Signed Graph 36
3.4 Two Mode Network 37
3.5 Umgewandeltes Two Mode Netzwerk in ein One-Mode Netzwerk 37
3.6 Transformation eines Two-Mode Netzwerks zu einem One-Mode Netzwerk mit der gewichteten Projection. 38
3.7 Berechnung des Kantengewichts mit der Newman's Weighted Projection Formel 39
3.8 Transformation eines Two-Mode Netzwerks zu einem One-Mode Netzwerk mit der Newman's Weighted Projection 40
3.9 Transformation eines Two-Mode Netzwerks zu einem One-Mode Netzwerk mit der Overlap Projection 40

5.1 Strongly Connected Components 45
5.2 Weakly Connected Component 45
5.3 Giant Component 46
5.4 Netzwerk mit zwei eingekreisten Cliquen 47
5.5 3-core (grün eingefärbt) 48
5.6 Beispielgraph für 1-Cliques und 2-Cliques 49
5.7 Berechnen der Edge-Betweenness Centrality 50
5.8 Edge-Betweenness Clustering: Ausgangslage 51

5.9 Edge-Betweenness Clustering: Berechnete Edge-Betweenness Werte . . . 51
5.10 Edge-Betweenness Clustering: Neu berechnete Edge-Betweenness Werte 51
5.11 Edge-Betweenness Clustering: Aufgeteilt in zwei Clusters 52
5.12 Initialer Graph mit bereits nummerieren Knoten, auf welchem der Label Propagation Algorithmus ausgeführt wird. 53
5.13 Initialer Färbung des Graphen. 53
5.14 Angepasste Labels, nachdem die blau eingefärbten Knoten abgearbeitet wurden. 54
5.15 Angepasste Labels, nachdem die grün eingefärbten Knoten abgearbeitet wurden. 55
5.16 Angepasste Labels, nachdem die braun eingefärbten Knoten abgearbeitet wurden. 55
5.17 Communities, welche sich mit dem Label Propagation Algorithmus herauskristallisiert haben 56
5.18 Beispiel für die Modularity-Berechnung, wobei das Kantengewicht zwischen den Knoten A und B zwei ist, aber hier zur Veranschaulichung als zwei Kanten dargestellt wird. 57
5.19 Durchtrennen aller m Kanten, so dass sich daraus $2m$ „Kanten-Stummel“ ergeben 58
5.20 Die Schritte des Louvain Algorithmus 59

6.1 Knoten mit Degree Centrality als Bezeichnung 62
6.2 Knoten mit **normalisierten** Degree Centrality Werten 63
6.3 Degree-Centrality vs. Closness-Centrality 64
6.4 Beispielgraphen für die Berechnung der Closeness-Zentralität 64
6.5 Netzwerk mit Degree Centrality als Knotenbezeichnungen 65
6.6 Betweenness Centrality vs. Degree Centrality 66
6.7 Beispielgraphen für die Berechnung der Eigenvector Zentralität mit Repräsentation als Adjazenzmatrix. 70
6.8 Initiale *Wichtigkeit* der Knoten anhand der Degree-Zentralität. 70
6.9 Multiplikation der Adjazenzmatrix A mit dem Vektor x 70
6.10 71
6.11 Proximity Prestige Beispiel: Ausgangslage 73
6.12 Proximity Prestige Beispiel: Berechnet 74
6.13 Beispielgraph zur Berechnung der Degree Group Centrality 75
6.14 Beispielgraph zur Berechnung der Closeness Group Centrality 76
6.15 Beispielgraph zur Berechnung der Closeness Group Centrality 77

8.1 Netzwerk mit rot eingefärbtem Pfad für den Diameter 84

8.2 Netzwerk mit rot eingefärbtem Pfad für den Diameter 85
8.3 Beispielgraph zur Berechnung der Cluster Coeffizienten (lokal & global) 86
8.4 Beispielgraph zur Berechnung der Netzwerk-Balance 87

9.1 Netzwerk mit rot eingefärbter Bridge 89
9.2 Netzwerk mit rot eingefärbten Cut-Vertices 90
9.3 2-connected Graph 90
9.4 3-connected Graph, welcher auch eine Edge Connectivity von 3 besitzt. . 91

10.1 Liste mit Studenten: Angabe des SAT-Scores und des GPAs. 92
10.2 Scatterplot mit bivariaten Daten und der Regressionslinie 93
10.3 Richtungen der Korrelation 93
10.4 Scatterplot der Fibonacci-Zahlen bis 15 97
10.5 Fünf verschiedene Netzwerke mit jeweils 40 Knoten und 160 Kanten, die alle denselben globalen Assortativitäts-Wert von 0 aufweisen, jedoch sehr unterschiedliche lokale Muster zeigen. Die Verteilung unten zeigt, wie die lokalen Assortativitäts-Werte verteilt sind. 99
10.6 Beispiel-Netzwerk zur Erklärung der nummerischen Assortativität 99
10.7 Beispiel-Netzwerk zur Erklärung der kategorischen Assortativität 101

11.1 Zachary's Karate Club Netzwerk. 111
11.2 Resultat des Permutations-Tests der Club Assortativität auf dem Zachary's Karate Club Netzwerk 112

12.1 Beispiel-Graph für die Link-Prediction Algorithmen (aus [Rom]) 114
12.2 Grösse der Trainings-Netzwerke sowie der jeweiligen Kerne 119
12.3 Tabellarische Darstellung der Resultate der Link-Prediction Evaluation . 119
12.4 Grafischer Vergleich verschiedener Link-Prediction Algorithmen 120

13.1 Retweet-Netzwerk zum Suchbegriff „GTA 5“ 121
13.2 5 Adopter Kategorien nach Rogers. 123
13.3 ICM-Diffusionsprozess in einem Netzwerk 125
13.4 Information Cascade Maximierung Beispielgraph 127

14.1 Graphlets und Orbits von Subgraphen der Grösse von 2 bis 5 Knoten. . 130
14.2 Beispiel-Netzwerk 1 zur Berechnung der Relative Graphlet Frequency Distance 131
14.3 Beispiel-Netzwerk 2 zur Berechnung der Relative Graphlet Frequency Distance. 132

14.4 Berechnung des Graphlet Degree Vectors für ein Beispiel-Netzwerk aus [ARS17] 134
14.5 Karateclub als Beispiel-Netzwerk 134
14.6 Mit t-SNE reduzierte Graphlet Degree Vektoren des Karate-Club Netzwerks. 135

Teil I

Einführung

Kapitel 1

Aspekte der Soziologie

Dieses Kapitel beschäftigt sich mit soziologischen Aspekten der Menschen. Die Soziologie ist eine Wissenschaft, welche sich mit dem Verhalten der Menschen auseinandersetzt. In diesem Kapitel steht die Frage im Zentrum, weshalb Menschen überhaupt soziale Beziehungen aufbauen und unterhalten. Die Autoren des Buches *Social Network Analysis with Applications* [MAJ13, 109 ff] haben eine wunderbare Vorarbeit geleistet. Der Inhalt und Aufbau dieses Kapitels orientiert sich stark an deren und wurde noch mit zusätzlichen Informationen angereichert.

1.1 Symbolischer Interaktionismus

Die beiden Soziologen George Herbert Mead und Herbert Blumer gelten als Begründer des *symbolischen Interaktionismus*. Die ins Deutsche übersetzte Definition lautet[1]:

> Der symbolische Interaktionismus ist eine soziologische Theorie aus der Mikrosoziologie, die sich mit der Interaktion zwischen Personen beschäftigt.

Personen haben von Natur aus das **Verlangen nach Wertschätzung**. Dies kann nur von anderen Personen erwidert werden. Deshalb wird unser Verhalten immer auch (indirekt) von anderen beeinflusst. Um dies zu veranschaulichen, werden in den nachfolgenden Abschnitten verschiedene Theorien genauer erläutert.

1.1.1 Looking Glass Self

Charles Horton Cooley[2] (1864 - 1929) war ein amerikanischer Soziologe. Er sieht in seiner *Looking Glass Self* Theorie die menschliche Natur als ein „Produkt der Kommunikation“. Der Mensch wird erst durch die Interaktion mit Mitmenschen zur menschlichen Person und entwickelt somit eine Identität („Self“). Für diese Entwicklung sind vor allem die engen Bekannten (z.B: gute Freunde oder Familie), welche Cooley als *Primärgruppe* bezeichnet, wegweisend.

[1] Artikel zu Symbolischem Interaktionismus auf Wikipedia, `https://de.wikipedia.org/wiki/Symbolischer_Interaktionismus`, [31.07.2017]

[2] Wikipedia-Artikel zu Charles Cooley, `https://de.wikipedia.org/wiki/Charles_Cooley` [31.07.2017]

Cooley definierte in seiner *Looking Glass Self* Theorie drei Elemente, durch dessen Gesamtheit und Wechselwirkung sich die eigene, **erlebte** Identität herausstellt[3]. Dabei nimmt eine Person an, dass sie von anderen beobachtet wird und stellt sich die folgenden Fragen:

- Wie werde ich von anderen Menschen gesehen / erlebt?
- Wie werde ich von diesen anderen Menschen daraufhin bewertet?
- Was für Gefühle erlebe ich aufgrund dieser Bewertung?

Die tatsächliche Bewertung der anderen ist bedeutungslos. Es geht ausschliesslich darum, was ich selbst zu wissen glaube, wie andere über mich urteilen. Bei der Bewertung der eigenen Person wird die Sicht von aussenstehenden eingenommen. Deshalb auch die Metapher des „eigenen Spiegelbilds". Laut Cooley definieren sich Menschen von Geburt an selbst anhand der sozialen Interaktionen.

Auch wenn die Theorie des *Looking Glass Self* bereits über 100 Jahre alt ist, hat sich an der Sehnsucht nach Bestätigung bis heute nichts geändert.

1.1.2 Me, Self & I

George Herbert Mead (1863 - 1931)[4] war ein amerikanischer Philosoph, Soziologe und Psychologe. Er und Charles Cooley waren befreundet und beeinflussten sich gegenseitig. Mead teilt das *Selbst* (die Identität eines Menschen) in zwei Bestandteile auf:

I Das „I" ist die Reaktion des Organismus auf die Haltung anderer. Das Individuelle im Menschen, Selbstbehauptung der Sonderheiten

Me Organisierte Gruppe von Haltungen anderer, die von einem selbst eingenommen werden. Dies beinhaltet auch Werte und Normen der Gesellschaft.

Das Me wird also durch die Haltung anderer gebildet und das I reagiert darauf. Im Unterschied zur *Looking Glass Self* Theorie von Cooley ist die Persönlichkeit nicht ausschliesslich nur von der Wechselwirkung mit anderen beeinflusst worden, sondern wird auch durch das I geprägt. Unter dem I versteht Mead im Wesentlichen die menschliche Kreativität, Spontanität und dessen biologisch veranlagten Triebe. Das I reagiert auf das Me, indem es aus den Normen und Werten die Regeln entnimmt.

Die Abbildung 1.1 veranschaulicht die Wechselwirkung von Me, Self und I:

[3] Wikipedia-Artikel zu Looking Glass Self, `https://en.wikipedia.org/wiki/Looking_glass_self` [31.07.2017]

[4] Wikipedia-Artikel zu George Herbert Mead, `https://en.wikipedia.org/wiki/George_Herbert_Mead`, [07.08.2017]

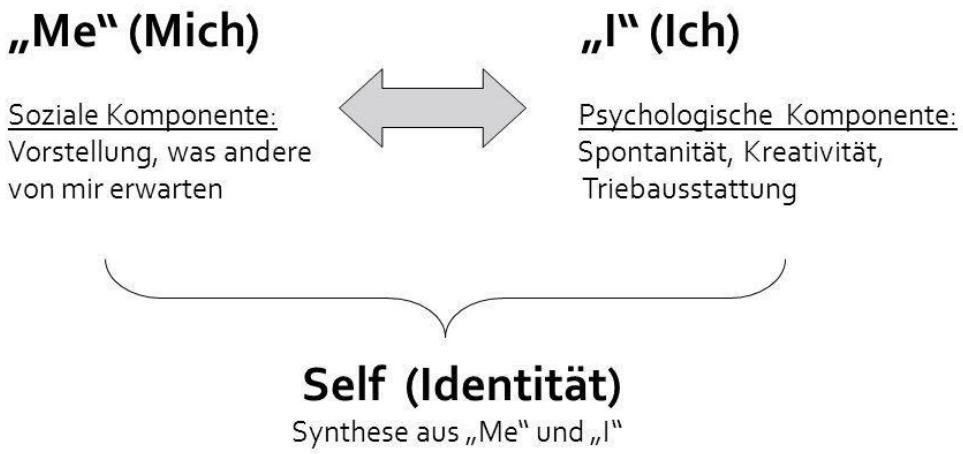


Abbildung 1.1: Zusammenspiel von Me, Self und I[5]

Zum einen wird das I durch das Me zurechtgewiesen, kann aber auch durch seine individuelle Reaktion die Gesellschaft verändern. Das Me wird durch die Gesellschaft geprägt und gibt dem I seine Form. Das Me ist der objektive Teil des Selbst. Durch unterschiedliche Soziale Kreise, können viele unterschiedliche Mes entstehen, da jeder Kreis unterschiedliche Erwartungen an das Individuum hat. Alle diese Mes müssen dann vom I berücksichtigt werden. Verschiedene Rollen und (erwartete) Verhaltensweisen müssen übernommen und miteinander vereinbart werden, damit sich ein einheitliches Selbstbild des Individuums ergibt. Ist diese Vereinbarung erfolgt, kann laut Mead von einem Self gesprochen werden (Wechselwirkung zwischen I und Me). Die Entstehung dieses Selfs war jedoch nur dank anderen Gesellschaftsmitgliedern möglich. Beim Self handelt es sich auch keinesfalls um ein abgeschlossenes Konstrukt, sondern es entwickelt sich in einem fortlaufenden Prozess. Durch neue Bekanntschaften, respektive das Eintreten oder Verlassen sozialer Kreise, ändern sich die Mes und folglich auch das Self.[6]

1.1.3 Maslowsche Bedürfnispyramide

Der Psychologe Abraham Maslow[7] (1908 - 1970) hat die Bedürfnisse von Menschen in der sogenannten *Maslowsche Bedürfnispyramide* (siehe Abbildung 1.2) abgebildet:

[5]Grafik aus der Präsentation von Ju Lian über „Social Media" (Folie 9), `https://prezi.com/qn46w2x7l_gf/social-media/`, [31.07.2017]

[6]Wikipedia-Artikel zu I, Me and Self, `https://de.wikipedia.org/wiki/George_Herbert_Mead#Das_Selbst_und_seine_strukturellen_Bestandteile_.E2.80.93_I.2C_me.2C_self_und_mind`, [31.07.2017]

[7]Wikipedia-Artikel zu Abraham Maslow, `https://de.wikipedia.org/wiki/Abraham_Maslow`, [31.07.2017]

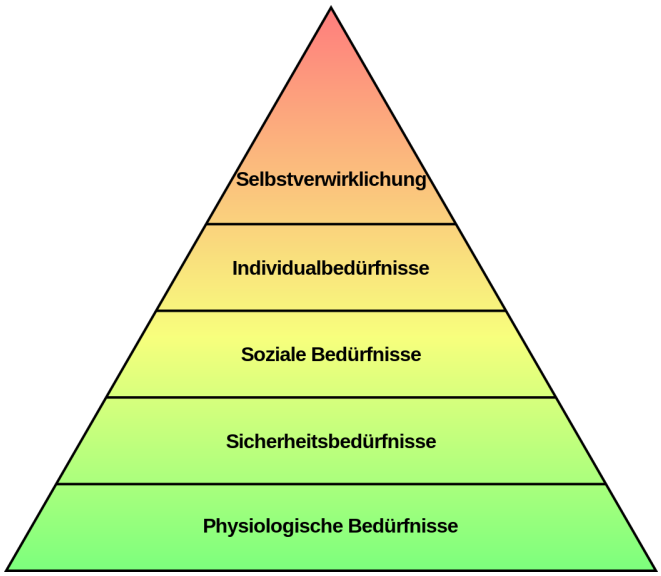


Abbildung 1.2: Maslowsche Bedürfnispyramide

Hier werden bereits auf der dritten Stufe die „Sozialen Bedürfnisse“ erwähnt. Dies bedeutet, dass sich Menschen nach der Erfüllung der physiologischen Bedürfnisse (z.B. Nahrung, Wärme) und der Sicherheits-Bedürfnisse (Verlangen nach Strukturen, Ordnung, Regeln, Grenzen, Stabilität) bereits nach den Sozialbedürfnissen sehnen. Diese beinhalten das Verlangen nach *sozialer Anerkennung und Zugehörigkeit, Liebe und Zuneigung*. Die vierte Stufe mit der Überschrift *Individualbedürfnisse* geht dann einen Schritt weiter. Maslow unterscheidet hier zwei Unterkategorien:

- Der Wunsch nach Stärke, Erfolg und Unabhängigkeit.
- Der Wunsch nach Ansehen, Wertschätzung, Achtung und Wichtigkeit, was **nur von anderen Menschen entgegengebracht werden kann.**

Auch wenn Maslow seine Bedürfnispyramide 1970 kurz vor seinem Tod nochmals erweitert hatte, blieben die ersten vier Stufen gleich. Es macht nochmals aus einem anderen Blickwinkel deutlich, wie wichtig es für Menschen ist, ein Teil eines sozialen Gefüges zu sein (Stufe 3) und auch schnell der Wunsch entsteht, nicht nur Teil davon zu sein, sondern auch ein gewisses Ansehen innerhalb dieser Gruppe (Stufe 4) zu erlangen.

1.2 Vernetzung

Der vorherige Abschnitt hat gezeigt, wie zentral der Kontakt zu anderen Personen für die eigene Persönlichkeitsentwicklung ist. Die Bewertung anderer sowie die Normen verschiedener Sozialer Kreisen haben Einfluss auf die eigene Persönlichkeit. Aus zeitlichen, aber auch aus kognitiven Beschränkungen, können nicht beliebig viele Beziehungen zu anderen Menschen gleichzeitig aufrechterhalten werden. Dies führt dazu, dass die unterhaltenen Beziehungen auf den maximalen persönlichen Nutzen optimiert werden [MAJ13, 110]. Häufig haben Personen Verbindungen zu mehreren sozialen Gruppen

aufgebaut, da jede soziale Gruppe auch einen anderen Nutzen hat und somit auch von unterschiedlichen Vorteilen profitiert werden kann. Zugang zu Wissen oder Ressourcen, Unterhaltung sowie gemeinsame Hobbys/Aktivitäten sind nur ein paar mögliche Motivationen, um Teil eines sozialen Kreises zu werden. Es ist selten, dass zwei Personen Beziehungen zu den genau gleichen Sozialen Kreisen unterhalten. Die Interaktions-Wahrscheinlichkeit zwischen zwei Personen steigt jedoch mit der Anzahl gemeinsamer Sozialen Kreisen. Dieses Konzept nennt sich *Homophilie* und wird im Abschnitt 1.3 genauer erläutert.)

1.3 Social Forces

Das Buch *Social Network Analysis with Applications* [MAJ13, 113] beschreibt sieben Schlüsselfaktoren, die Personen motivieren, soziale Beziehungen miteinander einzugehen. Diese werden hier ebenfalls aufgezeigt und beschrieben.

Homophilie

Der Kern von Homophilie (engl. Homophily) lässt sich sehr gut mit dem Sprichwort „*Gleich und gleich gesellt sich gern*“ beschreiben. Wenn Personen Gemeinsamkeiten aufweisen (Hobbies, Herkunft, Politische Gesinnung, Geschlecht...), ist die Wahrscheinlichkeit für Interaktion wesentlich grösser, als wenn keine Gemeinsamkeiten gefunden werden. Auch die ersehnte Wertschätzung von Mitmenschen ist bei gleichgesinnten wahrscheinlicher. Homophilie ist einer der grössten Motivatoren für die Vernetzung mit anderen Personen.

Reziprozität

Der Begriff „Reziprozität“ (engl. Reciprocity) beschreibt die Erwiderung einer sozialen Interaktion, die von jemand anderem initiiert wurde. Wenn eine Person A der Person B einen Brief schreibt und Person B der Person A antwortet, dann wird von Reziprozität gesprochen. Ob eine Person B antwortet, ist von verschiedenen Faktoren abhängig. Handelt es sich beispielsweise um eine prominente Persönlichkeit, ist die Wahrscheinlichkeit eine Antwort zu erhalten um einiges kleiner. Grundsätzlich ist es weniger aufwändig, lediglich auf eine Kontaktaufnahme zu antworten, als selbständig den aktiven Teil zu übernehmen.

Reziprozität ist vor allem auf Sozialen Netzwerk Plattformen im Internet ersichtlich. Die eigene Aktivität auf der Plattform wird von anderen erkannt und erwidert. Fehlt es in einer homogenen Gruppe an Reziprozität, dann ist davon auszugehen, dass die Gruppe einen weniger starken Zusammenhalt hat.

Nähe

Hierbei geht es um die Distanz zwischen zwei Personen (engl. Proximity). Der Begriff Nähe kann aus verschiedenen Aspekten betrachtet werden:

Organisatorische Nähe: Personen, die in derselben Abteilung arbeiten, sind sich innerhalb des Unternehmens näher. Dies kommt davon, dass die überschneidende Arbeitstätigkeit Interaktionen erfordern (z.B. gemeinsame Meetings organisieren oder Ziele und Aufgaben festlegen). Auch wenn ein Bereich über mehrere Standorte verteilt ist, kann deren organisatorische Nähe grösser sein als zum Beispiel die physikalische Nähe zu einem anderen Bereich, mit welchem es aber keine gemeinsamen Tätigkeiten gibt.

Physikalische Nähe: Die physikalische Nähe misst sich an der Distanz zwischen zwei Personen. Schon nur bei Sichtdistanz hat sich gezeigt, dass Leute Interaktionen mit Personen in ihrer unmittelbaren Nähe bevorzugen. Umso grösser die Distanz zwischen Personen ist, desto grösser sind auch die (gefühlten) Kosten, um mit der Person zu interagieren (Zeit, um dahin zu kommen oder extra einen anderen Kommunikationskanal wählen).

Ansehen

Personen, welche in einem Sozialen Kreis die sozialen Normen und Werte verkörpern, geniessen ein hohes Ansehen (engl. Prestige) und können sogar die Einstellung und Ansichten anderer Personen beeinflussen. Andere Mitglieder des gleichen sozialen Kreises bevorzugen die Vernetzung mit Personen, die bereits ein hohes Ansehen geniessen, da dies das eigene Selbstwertgefühl stärkt. Dieses Verhalten ist auch vorteilhaft für die Person, die bereits ein hohes Ansehen geniesst. Zum einen steigt das Ansehen mit den Anzahl Verknüpfungen und es fallen nur „geringe Kosten“ an, da er angefragt wird und nur reagieren muss (siehe Reziprozität). Personen mit einem tiefen Status in einer Gruppe können über die Zeit einen höheren Status-Wert erhalten, wenn sie gruppenorientiert handeln. Tun sie dies nicht, behalten sie einen tiefen Status. Eine Person kann innerhalb einer Gruppe auch einen höheren Status erhalten, indem sie sich strategisch geschickt vernetzt. Ist eine Person zusätzlich mit anderen Sozialen Kreisen vernetzt, kann ihr dies Zugriff auf nützliches Wissen und/oder Ressourcen bieten, was das eigene Ansehen wieder steigert. Durch die Vernetzung mit vielen Sozialen Kreisen kann aber ein Verhaltens-Konflikt entstehen, weil unterschiedliche Gruppen möglicherweise gegensätzliche Normen von einer Person verlangen.

Soziale Anpassung

Soziale Anpassung (engl. Social Conformity) beschreibt, wie fest sich das Verhalten einer Person demjenigen der Gruppe anpasst. Entspricht das Verhalten einer Person nicht der Gruppen-Norm, dann reduziert sich auch die Chance, dass dieser entsprechende Wertschätzung entgegengebracht wird. In mehreren Studien wurde gezeigt, wie stark der Einfluss einer Gruppe auf einzelne Individuen sein kann. Diese Gruppendynamik geht sogar so weit, dass extreme Ansichten angenommen werden können und Fakten, die entgegen der Gruppenmeinung sind, einfach ignoriert werden. In Experimenten wurde gezeigt, dass Leute Fragen bewusst falsch beantworten, wenn diese bereits von mehreren anderen Gruppenmitgliedern falsch beantwortet worden waren. Im Konformitäts-Experiment von Solom Asch (1955)[8] zeigte, dass 37% der Personen

[8]Wikipeida-Aritkel zum Konformitäts-Experiment von Asch, `https://en.wikipedia.org/wiki/Asch_conformity_experiments`, [31.07.2017]

der Meinung der Mehrheit zugestimmt haben, obwohl diese offensichtlich falsch war. Umso höheres Ansehen / zentralere Stellung eine Person innerhalb eines Netzwerks hat, desto eher wird dessen Meinung übernommen.

Transitivität

Wenn eine Person A mit einer Person B und C befreundet ist, dann besteht die Tendenz, dass sich auch Person B und C direkt miteinander befreunden. Diese Tendenz, eine Verbindung über eine bereits gemeinsame Bekanntschaft einzugehen, wird als Transitivität (engl. Transitivity) bezeichnet. Transitivität kann nicht immer strikt von anderen *Social Forces* abgetrennt werden. Wird angenommen, dass sich die Personen A, B und C aus dem vorherigen Beispiel alle im selben Sozialen Kreis befinden, dann könnte die Verbindung zwischen B und C auch durch „Homophilie“ vorangetrieben worden sein. Oder falls sich die Personen B und C aufgrund des gemeinsamen Freundes A häufiger sehen, könnte auch die (physikalische) Proximity Motivator für die Verbindung sein.

Balance

Beziehungen zwischen Personen können eine positive oder negative Neigung haben. Bei Balance wird untersucht, ob die Neigungen in einer Dreiecks-Beziehung (Triade, engl. Triad) balanciert sind. Folgende Konstellationen führen zu balancierten Dreiecks-Beziehungen:

Alle drei Beziehungen sind positiv Es ist balanciert, weil sich alle drei Personen mögen.

Es gibt genau eine positive Beziehung Auch diese Neigungs-Konstellation führt gemäss dem Motto „Der Feind meines Feindes ist mein Freund“ zu einer „balancierten“ Dreiecks-Beziehung.

In der Abbildung 1.3 ist ersichtlich, welche Konstellationen zu balancierten und unbalancierten Dreiecks-Beziehungen führen:

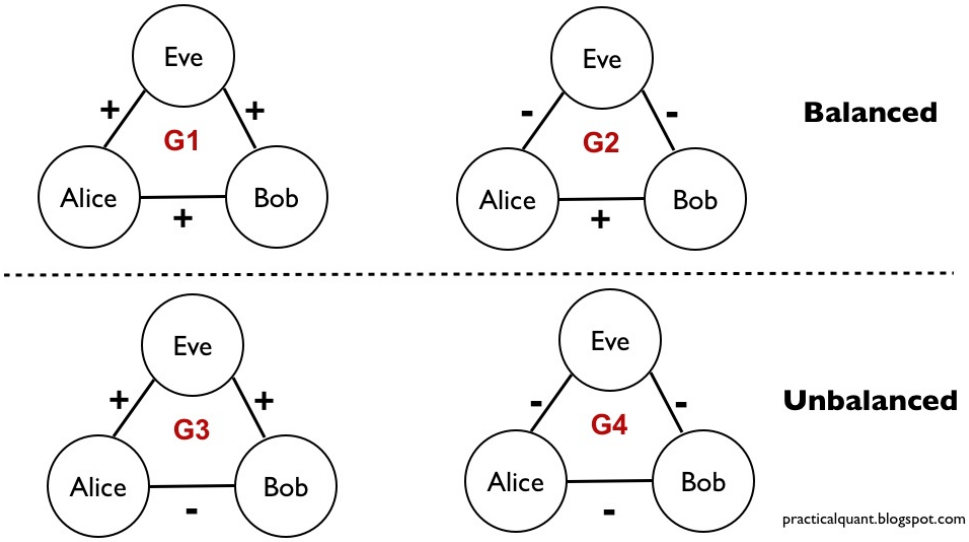


Abbildung 1.3: Balancierte und unbalancierte Triaden.[9]

Hat eine Person A zu B und C jeweils eine positive Beziehung, sich aber B und C nicht mögen, führt dies dazu, dass A in eine unangenehme Situation geraten kann, weil B und C versuchen A auf ihre Seite zu ziehen, so dass wieder ein balanciertes Dreieck entsteht. Dieses Phänomen kann auch in Freundschaftskreisen auftreten, wo plötzlich Unstimmigkeit zwischen zwei Personen herrscht und diese dann versuchen, die restlichen Personen ebenfalls von ihrer Meinung zu überzeugen. Dies kann in sehr grossen Unruhen führen und das Netzwerk destabilisieren.

1.4 Tie Strength

Ein Konzept, welches in der Sozialen Netzwerkanalyse zum Grundwissen gehört, wurde vom Soziologen Mark Granovetter[10] eingeführt. Er bezeichnete die Intensität der Beziehung zwischen Personen als Tie Strength. Diese Stärke einer Beziehung wurde anhand von vier Komponenten definiert:

- Wie viel Zeit zwei Personen miteinander verbringen
- Grad der emotionalen Intensität der Beziehung
- Gegenseitiges Vertrauen
- Art der bidirektionalen Hilfeleistungen

Granovetter teilte die Tie Strength grob in zwei Kategorien ein:

[9] Social Network envolve into two, `http://practicalquant.blogspot.ch/2011/02/social-networks-evolve-into-two.html`, [31.07.2017]

[10] Wikipedia-Artikel zu Mark Granovetter, `https://de.wikipedia.org/wiki/Mark_Granovetter`, [31.07.2017]

Strong Ties Familie und sehr enge Freunde (sehen sich häufig, teilen gleiche Interessen)

Weak Ties Weniger enge Freunde wie z.B. Arbeitskollegen

Personen, mit denen man überhaupt keinen persönlichen Kontakt pflegt (z.B. Verkäufer), werden in diesem Modell nicht abgebildet. Es wird in diesem Fall auch von *absent Tie* gesprochen. Die Untersuchung der Tie-Stärke spielt in der Sozialen Netzwerk Analyse eine bedeutende Rolle. Gruppen von Personen, welche über *Strong Ties* verbunden sind, pflegen ein grosses Vertrauensverhältnis und sind eng miteinander verbunden. Da sich diese Personen stark vertrauen, ist bereits eine Person alleine sehr einflussreich auf deren enge Freunde. *Weak Ties* eignen sich zur Verbreitung von Informationen über grosse Strecken im Netzwerk. Die Weak Ties eröffnen die Möglichkeit Informationen aus verschiedenen Gruppen zu beziehen.

Das Konzept ist sehr ähnlich zu den Primär- und Sekundärgruppen von Charles Cooley.

Die Zahl der Strong Ties ist sehr viel kleiner als der Weak Ties. Der Anthropologe Robin Dunbar[11] hat herausgefunden, dass Menschen im Durchschnitt maximal 150 Weak Ties (Dunbar's Number) haben. Er definierte die Weak Tie Beziehung so, dass mindestens der Name der Person und die wesentlichen Beziehungen zu dieser Person bekannt sein müssen.

1.5 Vernetzungs-Strategien optimieren

Personen tendieren dazu, den Nutzen des eigenen Beziehungsnetzwerks zu maximieren. Dazu gibt es verschieden Strategien. Zum einen kann durch optimale Adaption des Gruppenverhaltens das Ansehen innerhalb der Gruppe gesteigert werden. Zum anderen besteht aber auch die Möglichkeit, dass durch Verbindungen mit anderen Sozialen Kreisen eine Person (exklusiven) Zugriff auf Ressourcen und Wissen erlangt und somit das eigene Ansehen in anderen Gruppen gesteigert wird. Da beides zeitintensive Unterfangen sind, muss abgeschätzt werden, welche Strategie optimal ist. Zusätzlich müssen bestehende Beziehungen unterhalten werden. Die nachfolgenden zwei Unterabschnitte beschäftigen sich mit Vernetzungs-Strategien, entnommen von [MAJ13, 121 ff]

1.5.1 Exchange Theory von Homans

Leute in vorteilhaften Positionen (z.B. direkter Zugriff auf Wissen und Ressourcen) innerhalb des Netzwerkes nutzen dies häufig aus. Es erhöht ihre soziale Stellung, vor allem, je exklusiver und wertvoller die entsprechende Ressource / Wissen für die anderen ist. Der Soziologe George Homans[12] (1910-1989) sieht in seiner „Exchange Theory"[13] alle menschlichen Beziehungen als Austausche, die anhand einer Kosten-Nutzen-Analyse unter Berücksichtigung von Alternativen gemacht wurden. Beginnen die Kosten den

[11] Wikipedia-Artikel zu Robin Dunbar, `https://de.wikipedia.org/wiki/Robin_Dunbar`, [31.07.2017]

[12] Wikipedia-Artikel zu George Homans, `https://de.wikipedia.org/wiki/George_C._Homans`, [31.07.2017]

[13] Exchange Theory, `http://infed.org/mobi/george-c-homans-the-human-group-and-elementary-social-behaviour/`, [31.07.2017]

Nutzen zu übersteigen, bricht die Beziehung ein. Zusätzlich muss der Austausch gegenseitig sein, so dass auch beide davon profitieren. Ist dies nicht (mehr) der Fall, bricht die Beziehung ebenfalls ein.

Auch die Position eines Aktors innerhalb eines Netzwerks hat Einfluss auf den Austausch sowie den Zusammenhalt des Netzwerks. Ist ein Knoten mit zwei anderen verbunden (diese jedoch nicht direkt miteinander), ist er in einer grösseren Machtposition. Er kann auf beide zurückgreifen und auch dazwischen vermitteln. Er kann daraus Profit schlagen oder die Kommunikation unterbinden.

1.5.2 Structural Holes

Wenn zwei Netzwerke nur über eine Person miteinander verbunden sind, resultiert daraus ein Netzwerk-Muster, welches auch als *Structural Hole* bezeichnet wird. Die Abbildung 1.4 visualisiert ein solches Strctural Hole:

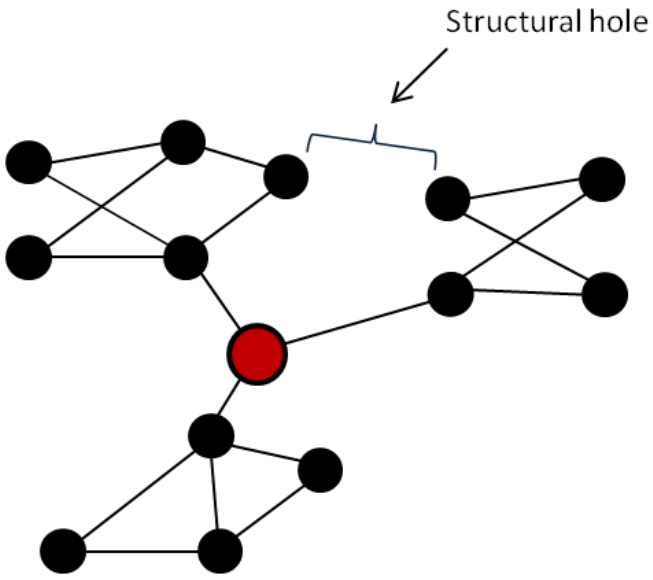


Abbildung 1.4: Structural Hole, da die Teilnetze nur über einen Knoten miteinander verbunden sind[15]

Die „vermittelnde Person“ ist eine sehr mächtige Position innerhalb des Gesamt-Netzwerks (auch „Cutpoint Position“ oder „Brokerage Position“ genannt). Meistens ist die *Structural Hole* Netzwerk-Struktur von den meisten Personen, ausser der zentralen Person selbst, nicht erwünscht. Da nur eine Person Zugriff auf das andere Netzwerk verfügt, ist die komplette Kommunikation von ihm abhängig und kann auch entsprechend gefördert, unterbunden oder manipuliert werden. Deshalb versuchen die restlichen Leute im Netzwerk ebenfalls Verbindung zwischen den Teilnetzwerken aufzubauen, was natürlich von der zentralen Person nicht gewollt ist, da so die Machtposition reduziert wird. Deshalb kann diese gewillt sein, dies zu verhindern. Das braucht nicht nur Zeit, sondern ist auch destruktiv für einen gesunden Zusammenhalt des Netzwerks.

[15] Grafik aus dem Artikel „How Structural Holes in Entrepreneurs Social Networks Impact Early Venture Growth“, `https://timreview.ca/article/828`, [31.07.2017]

1.5.3 Soziales Kapital

Für den Begriff *Soziales Kapital* existieren verschiedene Definitionen. Pierre Bourdieu[16], einer der bedeutendsten Soziologen des 20. Jahrhundert, hat *Soziales Kapital* in [Bou12] wie folgt definiert:

> Das Sozialkapital ist die Gesamtheit der aktuellen und potenziellen Ressourcen, die mit dem Besitz eines dauerhaften Netzes von mehr oder weniger institutionalisierten Beziehungen gegenseitigen Kennens oder Anerkennens verbunden sind; oder, anders ausgedrückt, es handelt sich dabei um Ressourcen, die auf der Zugehörigkeit zu einer Gruppe beruhen.

Grosses soziales Kapital ist in vielen Lebenssituationen sehr hilfreich und kann laut Bourdieu wichtiger als die eigentliche Leistung sein. Folgender Abschnitt kommt aus [Bra02]:

> Soziales Kapital entsteht Bourdieu zufolge aus dem "Netz von Beziehungen, die dazu beitragen, dass Karrieren, Macht und Reichtum nicht nur auf individuellen Leistungen basieren, sondern auch auf herkunftsbedingten Gruppenzugehörigkeiten und anderen vorteilhaften Verbindungen im Sinne des 'Vitamin B'."

Beispielsweise ist eine gute Vernetzung für die berufliche Karriere von grossem Vorteil. Sind ihre Qualitäten bekannt, dann werden sie noch vor der offiziellen Jobausschreibung von guten Bekannten empfohlen. Dies steigert auch gleich die Chancen den Job zu bekommen, weil Sie von einer internen Person empfohlen wurden. Nicht nur die Empfehlung des Kollegen ist ein grosser Vorteil, sondern auch überhaupt vom entsprechenden Jobangebot zu erfahren. Die meisten Personen, welche nur die Jobbörsen nach Jobs durchsuchen, bekommen laut einer Studie von *Marketingjobs.ch*[17] nur ungefähr einen Drittel aller öffentlich ausgeschriebenen Jobs zu Gesicht. Zusätzlich hat der Stellenmarkt-Monitor-Schweiz der Universität Zürich bestätigt, dass rund 19% - 28% der Jobangebote gar nie öffentlich ausgeschrieben werden, sondern unter der Hand weggehen[18].

Gleiches gilt beispielsweise für den Wohnungsmarkt. In der Schweizer Grossstadt Zürich gehen schätzungsweise ein Drittel aller Wohnungen unter der Hand weg[19]

1.5.4 Link Optimierung

Das Konzept der „Link Optimierung“ wurde vom Soziologen Matthew Brashears vorgeschlagen.[MAJ13, 122 f] Es geht darum, dass bei einer Beziehung zwischen Personen zwei Aspekte berücksichtigt werden:

[16] Wikipedia-Artikel zu Pierre Bourdieu, `https://de.wikipedia.org/wiki/Pierre_Bourdieu`, [31.07.2017]

[17] Die meisten Stellen werden nicht auf Jobbörsen ausgeschrieben, `http://blog.markenjobs.ch/die-meisten-stellen-in-der-schweiz-werden-nicht-auf-jobboersen-ausgeschrieben-wie-markenjobs-hilft-diese-jobs-zu-finden/`, [31.07.2017]

[18] MyJob.ch - Stellensuche mal anders,`https://www.myjob.ch/ratgeber/stellensuche-mal-anders/324`, [31.07.2017]

[19] Artikel aus 20min.ch über günstige Wohnungen in Zürich, `http://www.20min.ch/schweiz/zuerich/story/Hier-gibts-in-Zuerich-noch-Wohnungen-unter-2000-Fr-15788018`, [31.07.2017]

Häufigkeit: Wie häuft wird mit einer Person kommuniziert. Zum Beispiel findet täglich Kommunikation mit den Arbeitskollegen statt.

Intimität: Wie intim der Kontakt / Gesprächsinhalt ist. Dies ist bei einem langjährigen Freund grösser als bei einem Arbeitskollegen.

Die beiden Aspekte werden in Abbildung 1.5 zweidimensional abgebildet:

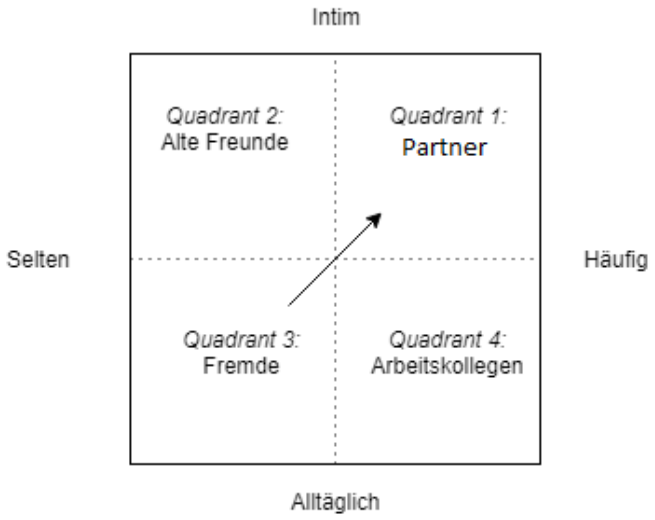


Abbildung 1.5: Die zwei Dimensionen der Link-Optimierung: Häufigkeit und Intimität

Die **Stärke der Beziehung** wächst von Quadrant 3 entlang der Pfeilrichtung zu Quadrant 1. Mit „Stärke“ der Beziehung wird der daraus gewonnene Vorteil und Nutzen referenziert. Jedoch wächst nicht nur der Nutzen, sondern es bedarf auch mehr Zeit, die Beziehung zu unterhalten (z.B. regelmässige Treffen / Aufrechterhaltung von Traditionen, Gefälligkeiten wie z.B. Hilfe beim Umzug usw.).

Entgegengesetzt zur Stärke der Beziehung ist die **Latenzzeit der Interaktion** angesiedelt. Alte Freunde (Quadrant 2) benötigten für die Aufrechterhaltung der Bekanntschaft weniger Zeit, aber können nach wie vor kontaktiert werden. Voraussetzung ist, dass einmal ein vertrautes Verhältnis bestanden hat. Ansonsten fällt bei einer Reduktion von der Interaktions-Häufigkeit eine Person von Quadrant 1 nicht in Quadrant 2 (Alte Freunde), sondern eher in Quadrant 3 (Fremde).

Die virtuellen Sozialen Netzwerke ermöglichen es, einen Kontakt mit minimalem Aufwand aufrecht zu erhalten. Es muss einfach berücksichtigt werden, dass diese Art von Kommunikation (z.B: ein „Like“ oder Kommentar auf einem Foto, einfaches „Happy Birthday“ auf der Pinnwand) sehr alltäglich ist und weniger die „Intimität“ fördert.

1.6 Soziale Netzwerke im Internet

„*Soziale Netzwerke*“ haben ihre Ursprünge in den 1930er Jahren. Da haben Leopold

von Wiese[20] (1876 - 1969) und Georg Simmel[21] (1858 - 1918) die *formale Soziologie* gegründet. Dabei ging es um die Untersuchung von sozialen Verbindungen und deren Beziehungen (z.B. Hierarchien in sozialen Gefügen wie Familie, Staat usw.)

Der Begriff *Soziale Netzwerke* erreichte erst mit dem Internet und vor allem dem Erfolg von Facebook Bekanntschaft in der breiten Masse. Werden die Leute nach bekannten „Sozialen Netzwerken" gefragt, fällt häufig der Begriff „Facebook" ganz am Anfang. Unterstützend war sicher auch der Film *The Social Network*, welcher die Entstehungsgeschichte von Facebook zeigt. Die Allgemeinheit ist sich jedoch bewusst, dass es noch andere *Soziale Netzwerke* gibt. Reddit (teilen von Beiträgen), Youtube (Video-Portal), LinkedIn (Geschäftskontakte), Twitter (Kurzmitteilungen), Pinterest (teilen von Fotos (eher langlebig)), Instagram (teilen von Fotos, eher kurzlebig), WhatsApp / Snapchat (Messanger) oder Badoo (Dating-Netzwerk) ist nur ein Ausschnitt der aktuell bekanntesten und hierzulande am häufigsten genutzten Sozialen Netzwerken im Internet.

Obwohl das Internet inzwischen mit sehr viel verschiedenen Soziale Netzwerk Plattformen übersät ist, sind die Grundfunktionalitäten der verschiedenen Plattformen sehr ähnlich. Der Fokus ist aber jeweils verschieden (Video-Sharing, Business-Netzwerk, Dating-Plattformen, usw.).

Gemeinsamkeiten, die auf verschiedenen Plattformen erkennbar sind:

- Angabe von persönlichen Informationen wie Alter, Wohnort usw.
- Sich mit anderen Personen vernetzen (z.B. „befreunden").
- Anderen Leuten eine Nachricht schicken (privat oder öffentlich)
- Andere Personen abonnieren, so dass deren Aktivitäten für einen selbst ersichtlich werden.
- Inhalte (Nachrichten, Fotos, Videos, Links...) veröffentlichen, so dass diese für vernetzte Personen und Abonnenten ersichtlich werden.
- Auf Inhalte anderer reagieren (Kommentieren, Befürworten („Liken"), Verneinen („Disliken")) sowie auch wieder auf Reaktionen anderer reagieren.
- Personen in Beiträgen (z.B. Fotos) markieren
- Interessensgruppen gründen oder diesen beitreten

Doch die Verwendung von sozialen Netzwerken birgt auch Nachteile, resp. sogar Gefahren. Gewisse negative Aspekte sind so subtil, dass diese den meisten Benutzern gar nicht bewusst sind.

- Es kann zu einem persönlichen Image-Schaden kommen, wenn unvorteilhafte Fotos oder Bemerkungen von einer Person ohne deren Zustimmung im Sozialen Netzwerk verbreitet werden. Dies kann sich dann beispielsweise bei Bewerbungsverfahren rächen, da ein Unternehmen auf keinen Fall jemanden einstellen möchte, der den Ruf des Unternehmens gefährden könnte.

[20] Wikipedia-Artikel zu Leopold von Wiese, `https://de.wikipedia.org/wiki/Leopold_von_Wiese`, [31.07.2017]

[21] Wikipedia-Artikel zu Georg Simmel, `https://de.wikipedia.org/wiki/Georg_Simmel`, [31.07.2017]

- Mobbing unter Schülern und Jugendlichen fand früher auf dem Pausenplatz statt. Zu Hause war man jedoch in einem „geschützten Bereich“. Heutzutage ist diese Grenze verschwunden. Über Mobiltelefone und Soziale Netzwerke besteht die Möglichkeit, dass die Opfer rund um die Uhr belästigt werden. Innert Kürze ist ein unvorteilhaftes Foto oder ein Spruch in den Sozialen Netzwerken abgegeben und für alle sichtbar, die dann wieder „Likes“ und weitere Kommentare anfügen können.

- Beleidigungen in Sozialen Medien ist schneller und mit geringerer Überwindung geschrieben als persönlich ausgesprochen. Die Existenz solcher Plattformen soll mitverantwortlich sein, dass sich die Anzahl der Strafanzeigen in der Schweiz wegen "Übler Nachredeïnnert 8 Jahren verdoppelt hat. Im Jahr 2009 wurden 760 Fälle registriert; im 2017 1440.[22] Niedergeschriebene Beleidigungen sind natürlich auch einfacher zu beweisen als ausgesprochene.

- In Teil Ländern werden die Internet-Aktivitäten stark überwacht. Beispielsweise wird in Thailand Majestätsbeleidigung mit bis zu 15 Jahren Gefängnis bestraft. Ein „Like“ zur falschen Zeit auf Facebook hat dazu geführt, dass eine Thailänderin verhaftet und ihr vorgeworfen wurde, den König beleidigt zu haben[23].

- Dank all den persönlichen Angaben (inkl. „Likes“ und Gruppenzugehörikeiten) können sehr genaue Persönlichkeitsprofile erstellt werden. Besonders heimtückisch ist, dass hier nicht nur die eigenen Angaben, sondern auch diejenigen von Freunden berücksichtigt werden. Auch wenn man selbst nur Freundschaftsbeziehungen eingeht und sonst keine weiteren Angaben gemacht werden, kann relativ einfach durch die Analyse dieser Freunde Rückschlüsse auf Alter, Hobbys und Beruf gemacht werden. Diese Daten sind für das Marketing sehr wertvoll.

- Die künstliche Intelligenz ist auf dem Vormarsch. Die riesige Menge an Daten in Sozialen Netzwerken beinhalten wertvolle Informationen, welche diese Systeme zum Erlernen ihrer Fähigkeiten benötigen. Nur schon aufgrund der Markierungen von Personen auf Bildern hat Facebook ein riesiges Archiv an nützlichen Daten, die es ermöglichen, ein Gesicht sehr zuverlässig maschinell erkennen zu können. Der wohl populärste Fall war die gross angelegte Datenanalyse der Firma *Cambridge Analytica*, die mehrere zehn Millionen Personenprofile eingesammelt und analysiert hat. Mehr Informationen zu diesem Fall finden Sie im Abschnitt 1.6.1.

Viele Nutzer von Sozialen Netzwerken sind sich den negativen Seiten bewusst. Trotzdem sind die meisten Leute inzwischen Teil von mindestens einem Sozialen Netzwerk. Das hängt unter anderem auch damit zusammen, dass für einen selbst kein unmittelbarer und direkter Nachteil ersichtlich ist und das Verlangen nach der Vernetzung mit anderen gross ist, wie es ausführlich im Abschnitt 1.1 auf der Seite 10 beschrieben wurde. Menschen möchten miteinander verbunden sein und über eine gemeinsame Plattform im Internet geht das mit geringem Aufwand. Mit der zunehmenden Globalisierung ist die Pflege von sozialen Kontakten auch entsprechend schwieriger. Sich

[22] Artikel der Aargauer Zeitung über die Eskalation eines Familienstreits in WhatsApp, `https://www.aargauerzeitung.ch/schweiz/eskalation-im-familien-chat-wie-ein-streit-auf-whatsapp-mit-einem-strafbefehl-endete-132379480`, [02.09.2018]

[23] Artikel aus der Berner-Zeitung, `https://www.bernerzeitung.ch/ausland/asien-und-ozeanien/Ein-falsches-Like-reicht-fuer-Haft/story/20637496`, [29.7.2017]

persönlich zu treffen erfordert bei entfernt lebenden Freunden Koordination und wird umso komplizierter, wenn sich ein über die Welt verstreuter Freundeskreis treffen möchte. Eine virtuelle Soziale Netzwerkplattform wie Facebook ist enorm hilfreich, diese physische Distanz zu überwinden. Gruppenchats ermöglichen eine aktive Kommunikation und durch das Veröffentlichen von Bildern und Kommentaren können andere Personen über aktuelle Geschehen informiert werden, ohne mit allen Personen direkt in Kontakt zu treten. Man wird automatisch über das Leben der eigenen Freunde informiert und das mit minimalem Aufwand. Gruppen, die Personen mit Gemeinsamkeiten zusammenbringen, erleichtern die Organisation von Events enorm und fördern das Gemeinschaftsgefühl. All die bisher genannten Faktoren befriedigen die Bedürfnisse der 3. Stufe in der Maslowschen Bedürfnispyramide (siehe Unterabschnitt 1.1.3 auf der Seite 12). Ist dieses Bedürfnis gedeckt, dann wird fast automatisch versucht, das in der Ebene darüber angesiedelte Individualbedürfnis *Anerkennung* ebenfalls in Sozialen Netzwerken zu erfüllen. Anerkennung kann direkt an den Reaktionen zu veröffentlichten Beiträgen und Fotos gemessen werden. Um die Jagd nach den meisten „Likes“ und Kommentaren zu gewinnen, muss dem „Publikum“ auch etwas geboten werden. Das Teilen von Urlaubsfotos bringt gewisse Anerkennung, doch wer wirklich oben hinaus will muss mehr bieten, um sich von den anderen abzuheben. Umso waghalsiger, desto lauter sind die Reaktionen. Dies beginnt bei einem Rennstrecken-Training auf dem Motorrad und endet bei waghalsigen Aktionen, wo Leute wie beispielsweise Angela Nikolau[24] dem Trend *Rooftopping*[25] folgen und unter dem Hashtag *#rooftopping* oder *#chasingrooftops* Selfies von Hochhaus-Dächern schiessen[26]. Mit der Angabe des Hashtags *#dangerousselfie* bestätigen die Leute, dass sie sich den ausgesetzten Gefahren durchaus bewusst sind. Das kann sogar so weit gehen, dass ein virtueller Gruppendruck entsteht. Wenn alle in einer Gruppe auf der Jagd nach Anerkennung etwas riskieren, dann ist man indirekt selbst auch gezwungen etwas zu wagen, um den Anschluss in der Gruppe nicht zu verlieren und auch die ersehnte Anerkennung zu erhalten.

Doch diese waghalsigen Situationen sind nicht die einzige Möglichkeit, wie Soziale Netzwerke das eigene Wohlbefinden gefährden resp. negativ beeinflussen können. In einer Studie von Hanna Krasnova (Humboldt-Universität) wurde gezeigt, dass Personen nach dem Besuch von Facebook unglücklicher sind als zuvor[27]. Die Studie kam zum Schluss, dass Facebook den Vergleichsdruck hervorrufe. Benutzer von Facebook sehen ständig Fotos und Statusmeldungen anderer. Da die meisten Leute nur sehr positive Dinge veröffentlichen, wird der Eindruck erweckt, dass *alle anderen ein glücklicheres, erfolgreicheres und erfüllteres Leben führten als man selbst.* Dies führt dann zu Eifersuchts- und Minderwertigkeitsgefühle. Vor allem passive Facebook-Benutzer sind betroffen und werden häufiger Opfer einer sogenannten Facebook-Depression. Auch Personen, denen es eigentlich gut geht, können darunter leiden. Seiten wie „Rich Kids of Instagram“[28] zeigen, was für ein ausgelassenes Leben die Kinder von sehr reichen Eltern geniessen. Fotos vor wunderschönen Anwesen, Sammlung teurer Luxusautos oder Privatjets gehören da zur Tagesordnung.

[24] Angela Nikolau (Instagram), `https://www.instagram.com/angela_nikolau/`, [31.07.2017]

[25] Artikel von MTV über den Trend Rooftopping , `http://www.mtv.ch/news/102427-rooftopping-ein-schwindelerregender-trend-erobert-instagram` [31.07.2017]

[26] Bilder mit dem Hashtag *rooftopping* auf dem Portal Intagram, `https://www.instagram.com/explore/tags/rooftopping`, [31.07.2017]

[27] Bericht der NZZ, weshalb Facebook unglücklich macht, `https://www.nzz.ch/feuilleton/die-bilder-und-die-leere-1.18169218`, [31.07.2017]

[28] Webseite „Rich Kids of Instagram“, `http://richkidsofinstagram.com`, [31.07.2017]

Zusammengefasst kann gesagt werden, dass sich wohl die meisten Personen über mindestens einen Teil der Gefahren in Sozialen Netzwerken bewusst sind. Dieser Einführungstext, auch wenn er vor allem auf die negativen Aspekte fokussiert, soll keineswegs urteilend wirken. Virtuelle Soziale Netzwerke sind eine wunderbare Erfindung. Jedoch ist es wichtig, dass man sich auch den negativen Seiten bewusst ist und auch weiss, wieso die Firmen grosses Interesse haben, möglichst viel über den Benutzer zu erfahren und wie sie dieses Wissen wieder einsetzen. Im Kapitel 2 werden ein paar Anwendungsfälle von Sozialer Netzwerkanalyse detaillierter beschrieben.

1.6.1 Detaillierte Persönlichkeitsanalyse durch Cambridge Analytica

Die Firma *Cambridge Analytica* wurde beschuldigt, die Daten von bis zu 87 Millionen Facebook-Nutzern abgegriffen und für eigene Zwecke missbraucht zu haben; wie beispielsweise Microtargeting bei der Präsidentschaftswahl von Donald Trump im Jahr 2016.

Die Abbildung 1.6 bietet einen guten Überblick über das Geschehen (die Detailbeschreibung folgt im Anschluss).

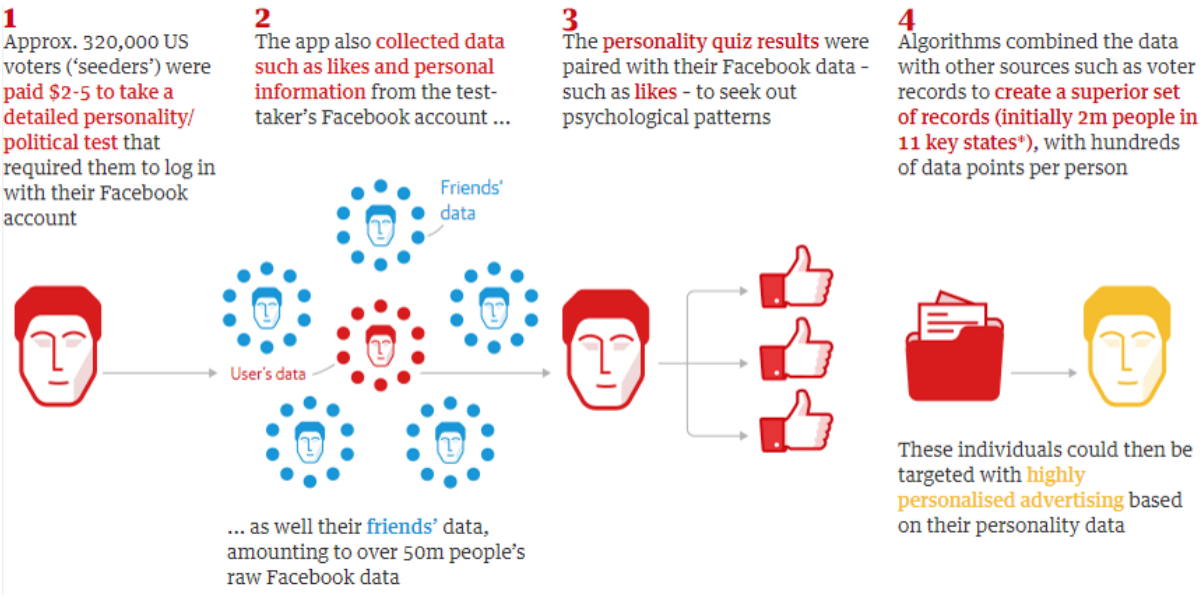


Abbildung 1.6: Analyse von 50+ Millionen Facebook-Profilen durch Cambridge Analytica.[30]

Alles begann mit der Facebook-App *this is your digital life*, mit welcher Facebook-Nutzer Persönlichkeitstests durchführen konnten. Doch auch die Entwickler dieser App, die Firma *Global Science Research (GSR)* von Aleksandr Kogan, erhielt alle ausgefüllten Informationen und sammelte zusätzlich noch weitere Daten über den Nutzer und deren Freunde. Dazu gehörten Informationen zu Aktivitäten, Likes und persönliche Angaben im Profil. Wichtig ist hier zu erwähnen, dass das Abgreifen dieser Daten über eine

[30] How Cambridge Analytica turned Facebook 'likes' into a lucrative political tool, `https://www.theguardian.com/technology/2018/mar/17/facebook-cambridge-analytica-kogan-data-algorithm`, [02.09.2018]

offiziell von Facebook angebotene Schnittstelle geschah, was ermöglichte, dass Profilinformationen einer Person ohne dessen Kenntnisse und Erlaubnis eingesammelt werden konnte (in diesem Fall die Freunde derjenigen Personen, welche die App benutzt haben). Das Ganze geschah 2014. Im darauffolgenden Jahr hat Facebook die Schnittstelle zum Abgreifen von Daten der Facebook-Freunde geschlossen.

Mit den gesammelten Daten der App-Benutzer wurden dann ganze Persönlichkeitsprofile anhand des *OCEAN-Modells* (auch unter dem Namen *Big-Five* bekannt) erstellt. Dieses Modell misst die Ausprägungen der folgenden fünf Eigenschaften:

Offenheit für Erfahrungen Ist die Person eher vorsichtig und konservativ oder neugierig?

Gewissenhaftigkeit Ist die Person eher nachlässig oder gut organisiert?

Geselligkeit Ist die Person eher zurückhaltend oder gesellig?

Verträglichkeit Ist die Person eher wettbewerbsorientiert oder kooperativ / mitfühlend?

Verletzlichkeit Ist die Person eher ruhig und selbstsicher oder emotional?

Um möglichst viele Daten zu sammeln, wurden sogar mehrere hunderttausend Personen für die Nutzung von *this is your digital life* bezahlt. Ursprünglich wurde angegeben, dass die Daten ausschliesslich zu wissenschaftlichen Zwecken verwendet werden. Die Daten wurden jedoch auch an die Firma *Cambridge Analytica* weiterverkauft.

Zur Verfügung stand schlussendlich eine riesige Menge an Daten. Dank den Nutzern der App, welche die eigenen persönlichen Daten liefern und dank des ausgefüllten Fragebogens jeweils auch ein detailliertes Persönlichkeitsprofil, konnte mit Hilfe von statistischen Methoden ein Modell erzeugt werden, um zu schlussfolgern, welche Profilangaben (z.B. Likes) zu welchem Persönlichkeitsprofilen führt. Die App-Nutzer lieferten jedoch noch alle Profildaten deren Freunde (eine Person hat laut einer Facebook-Studie[31] im Durchschnitt 340 Freunde). So kam eine riesige Menge an Personendaten zusammen. Mit Hilfe des trainierten statistischen Modells konnten nun auch von diesen Personen sehr detaillierte Persönlichkeitsprofile erstellt werden.

Diese Persönlichkeitsprofile können dann verwendet werden, um massgeschneiderte Werbung dem Benutzer anzeigen zu können (sogenanntes Microtargeting). Ein eindrückliches Beispiel zeigt der ehemalige CEO von Cambridge Analytica in der Präsentation auf `https://vimeo.com/212373587`. Dies wurde dann im Wahlkampf zum US-Präsident im Jahr 2016 von Team rund um Donald Trump laut Cambridge Analytica verwendet. Ob dies bei einem Wahlkampf einen signifikanten Vorteil bringt, wurde nie bewiesen. Es gibt auch Gegenstimmen die behaupten, dass der Einfluss nur sehr gering war [32].

Ob Ihre Facebook-Daten ebenfalls in den Händen von Cambridge-Analytica gelangt sind, kann auf der Webseite `https://www.facebook.com/help/yourinfo/` überprüft werden.

[31] Facebook-Studie, `https://t3n.de/news/1-million-user-analysiert-grose-461058/`, [02.09.2018]

[32] Artikel von Zeit.de zu „Big Data alleine entscheidet noch keine Wahl“,`http://www.zeit.de/digital/internet/2016-12/us-wahl-donald-trump-facebook-big-data-cambridge-analytica`, [31.07.2017]

Der Psychologe Michal Kosinski[33] behauptet, dass Aleksandr Kogan ihm das ganze Verfahren abgeschaut habe. Ein Ausschnitt aus *dasmagazin.ch* [34] zeigt, was Michal Kosinski behauptet mit seinen Modellen errechnen zu können:

> 2012 erbringt Kosinski den Nachweis, dass man aus durchschnittlich 68 Facebook-Likes eines Users vorhersagen kann, welche Hautfarbe er hat (95-prozentige Treffsicherheit), ob er homosexuell ist (88-prozentige Wahrscheinlichkeit), ob Demokrat oder Republikaner (85 Prozent). Aber es geht noch weiter: Intelligenz, Religionszugehörigkeit, Alkohol-, Zigaretten- und Drogenkonsum lassen sich berechnen. Sogar, ob die Eltern einer Person bis zu deren 21. Lebensjahr zusammengeblieben sind oder nicht, lässt sich anhand der Daten ablesen.

Was vielleicht auf den ersten Moment interessant klingt, kann sehr schnell auch gefährliche Züge annehmen. Homosexuelle werden auch in der heutigen Zeit in gewissen Ländern (z.B. Tschetschenien) verfolgt und gefoltert[35]. Sind Algorithmen zur frühzeitigen Erkennung von Homosexualität vorhanden und einsatzfähig, müssen sich alle Leute, die sich aus Sicht des Algorithmus „wie homosexuelle verhalten“ um ihre Sicherheit fürchten. Gleiches gilt auch für die Religionszugehörigkeit.

1.6.2 Influencer in Sozialen Medien: Vom Trend zum Beruf

Personen, welche in Sozialen Medien über eine grosse Anzahl aktiver Anhänger verfügen, werden auch als *Influencer* bezeichnet. Um ein interessantes Profil zu pflegen, muss entsprechend Zeit investiert werden. Influencer posten regelmässig, so dass deren Community auch unterhalten wird. Natürlich sind Stars ebenfalls auf diesen Plattformen als Influencer vertreten. Jedoch haben auch alle anderen Personen die Möglichkeit, sich in den Sozialen Medien um eine Influencer-Rolle zu bemühen und so Star-Privilegien wie Berühmtheit oder das Setzen von Trends zu geniessen. Diese Influencer werden inzwischen auch häufig von Firmen für Werbezwecke engagiert, sogenanntes *Influencer-Marketing*. Influencer beeinflussen somit das Kaufverhalten ihrer Community. Studien haben ergeben, dass 16% der 14- bis 29-Jährigen ein Produkt kaufen, welches von Influencern präsentiert wurde. Die Glaubwürdigkeit von Influencern ist viel grösser als diejenige von Werbespots im Fernsehen, da zumindest ein Teil von ihnen nur für Produkte werben, hinter denen sie auch stehen können. Verschiedene Influencer haben auch ihre Kerngebiete (z.B. Fitness, Kosmetik) und sind somit für Firmen aus diesen Bereichen noch interessanter, da so das angepriesene Produkt direkt bei der richtigen Zielgruppe platziert wird. Jedoch ist die Glaubwürdigkeit von Influencern nach wie vor tiefer als Kundenbewertungen oder die Empfehlung von Bekannten und Freunden.

Stars wie Kylie Jenner (Community-Grösse (Sep. 2018): 114 Millionen) verdienen im Durchschnitt 1 Million US-Dollar pro Werbepost[36]. Doch auch andere Stars wie Selena

[33] Webseite von der Stanford University über Michal Kosinski, `https://www.gsb.stanford.edu/faculty-research/faculty/michal-kosinski`, [31.07.2017]

[34] `https://www.dasmagazin.ch/2016/12/03/ich-habe-nur-gezeigt-dass-es-die-bombe-gibt/`

[35] Artikel in zeit.de über die Verfolgung von homosexuellen Männern in Tschetschenien, `http://www.zeit.de/gesellschaft/zeitgeschehen/2017-04/tschetschenien-homosexuelle-maenner-festnahmen-verschleppung`, [31.07.2017]

[36] Teuerste Influencer, `https://www.basicthinking.de/blog/2018/08/26/teuerste-influencer-weltweit/10/`, [03.098.2018]

Gomez, Christiano Ronaldo, Justin Bieber oder Dwayne Johnson kommen auf sehr hohe Werbeeinnahmen. Bei den Normalsterblichen sind die Einnahmen meistens aufgrund der kleineren Community geringer. Die Auswertungen der Zeitschrift *Beobachter* haben gezeigt, dass Influencer grösstenteils weniger als 500 Dollar pro Post verdienen (bis hin zu einfachen Werbegeschenken). Nur gerade 19% der Influencer verdienen mehr als 1'000 Dollar pro Werbepost; und nur gerade 3% mehr als 10'000 Dollar pro Werbepost. Jedoch ist Geld für viele Influencer nicht die Hauptmotivation, sondern:

1. Sie möchten etwas bewirken
2. Sie möchten ihre Berühmtheit steigern
3. Sie möchten als Meinungsmacher gelten
4. Sie möchten Geld damit verdienen

Seit anfangs 2018 ist der Beruf *Digital Influencer* sogar offiziell im Verzeichnis der Berufsberater eingetragen. Eine Ausbildung dazu fehlt jedoch in der Schweiz, jedoch bietet die *Influencer Academy* in Berlin für mehrere tausend Euro eine entsprechende Ausbildung an. Es gibt aber auch Zweifel, ob man „influencen" wirklich erlernen kann.

Hinweis: Wo nichts anders angegeben ist, stammen die Zahlen und Statistiken aus [uNH].

Kapitel 2

Anwendungsfälle von Sozialer Netzwerkanalyse

Die Anwendungfälle für Soziale Netzwerkanalyse sind sehr vielfältig. Hier eine Aufzählung, die zwar nicht abschliessend ist, jedoch einen guten, ersten Eindruck vermittelt, was mit Sozialer Netzwerkanalyse alles untersucht werden kann.

Persönlichkeitsprofile Für jeden Benutzer können anhand der aktiv und passiv zur Verfügung gestellten Informationen Persönlichkeitsprofile erstellt werden. Unter „aktiv“ zur Verfügung gestellt werden diese Informationen verstanden, welche der Benutzer selbst eingetragen und ausgelöst hat (z.B. Alter, Wohnort, Hobbies, „Likes“ usw.). Zu den „passiv“ zur Verfügung gestellten Informationen zählt alles, was indirekt abgeleitet werden kann. Beispiel: Person A macht eine Informatik Berufslehre, verzichtet jedoch auf jegliche persönlichen Angaben. Nur Freundschaftsbeziehungen geht er ein. Wird das komplette Netzwerk betrachtet, dann sind die meisten der Lehrlinge einer Klasse miteinander verknüpft. Es handelt sich dabei um einen Zusammenschluss (Cluster) einer sehr homogenen Gruppe. Die meisten werden etwa gleich alt sein und den gleichen oder einen sehr ähnlichen Beruf angegeben haben. Jetzt kann für die Person A mit grosser Sicherheit angenommen werden, dass diese etwa im gleichen Alter ist und in einem ähnlichen Beruf tätig ist. Möglicherweise ist Person A noch Teil von anderen Gruppen, wo gewisse Angaben nochmals überprüft werden können. Auf diese Weise können Informationen viel zuverlässiger angereichert werden. (Oder um es für den Data Science Bereich mit anderen Worten auszudrücken: Für das Feature-Engineering ist dies eine wunderbare Quelle. Zum Anreichern von „Missing Values“ ist die oben erwähnte Methode viel genauer als der häufig vorgeschlagene Mittelwert. Zusätzlich könnten in obigem Beispiel verschiedene Schreibweisen für das Konzept „Informatik Berufslehre“ extrahiert und wiederverwendet werden.). Persönlichkeitsprofile können dann für verschiedene Zwecke (z.B. Marketing) verwendet werden.

Marketing Die Soziale Netzwerkanalyse ist sehr hilfreich im Marketing. Zum einen können Persönlichkeitsprofile genutzt werden, um nur Werbeanzeigen aufzuschalten, die für diesen Benutzer auch von Interesse sind (finden geeigneter Zielgruppen). Zusätzlich können die Zielgruppen genauer auf Leute mit grossem Ansehen

(sogenannte Influencer) untersucht werden. Für diese kann dann das Marketing besonders attraktiv gestaltet werden. Die Hoffnung ist, dass diese dann ihre positive Meinung zum Produkt mit anderen teilen und somit neue Kunden generiert werden.

Trend- und Markt-Analysen Trend-Analysen (vom MIT-Professor Peter A. Gloor[1] auch „Coolhunting“ genannt) dienen dazu, Trends in den Sozialen Netzwerken frühzeitig zu erkennen. Dazu werden alle möglichen Informationen zu dem entsprechenden Thema gesammelt und ausgewertet. Wichtig ist nicht nur einen Trend selbst, sondern im gleichen Zug auch die Ursache dafür zu erkennen. Beispielsweise ist es leicht zu sehen, dass „vegane Ernährung“ ein Trend ist. Doch die Gründe, was Menschen dazu bewegt, sind viel spannender und aufschlussreicher, die Bewegung im Detail zu verstehen. So können beliebig tiefe Analysen gemacht werden. Genau gleich kann natürlich analysiert werden, wie ein veröffentlichtes Produkt in den Sozialen Netzwerken (dazu können auch Foren gezählt werden) Anklang gefunden hat. Dies sind wunderbare Quellen für Feedbacks geworden. Benutzer müssen nicht mehr mit Umfragen belästigt werden, sondern sie teilen ihre Meinung freiwillig mit den anderen. Für diese Form von Analysen ist die sogenannte Sentiment-Analyse zentral. Diese Form von Textanalyse gibt Auskunft darüber, ob und wie stark der Inhalt des Textes positiv oder negativ ist.

Verbrechensbekämpfung Das Kommunikationsnetz unter kriminellen kann einen Einblick in die interne Organisationsstruktur geben und aufzeigen, welche Personen in der Gruppierung zentral sind.

Firmenanalyse Das Kommunikationsverhalten in Firmen kann anhand von unterschiedlichen Aspekten untersucht werden. Interessant ist es, die Zentralität von einzelnen Personen im Kommunikationsnetzwerk mit dem Firmen-Organigramm zu vergleichen. Weiter kann untersucht werden, ob der Kommunikations-Stil angemessen für die Organisationsform des Unternehmens ist. In [MAJ13, 220] wird von *effizienten* und *lernenden / anpassenden* Organisationsformen gesprochen. Besteht die Arbeit hauptsächlich aus sich wiederholenden Aufgaben und nur wenige neuen Herausforderungen, ist eine zentral entscheidende Stelle die effizientere Kommunikationsstruktur. Ist jedoch die Arbeit mit vielen und regelmässigen neuen Herausforderungen verbunden, dann empfiehlt sich eine Netzwerk-Struktur, wo ein reger und direkter Austausch unter den Mitarbeitenden stattfindet. So verteilt sich das Wissen besser im ganzen Team und führt auch dazu, dass Entscheidungen dezentral gefällt werden. Ein anderer sehr interessanter Aspekt bei Firmenanalysen ist das Antwortverhalten. Dies kann zwischen Personen oder im Gesamtkontext der Firma / Abteilung / Gruppe analysiert werden. Forschungen von Peter Gloor [Glo17] haben gezeigt, dass je kürzer die Antwortzeiten von Kollegen sind, desto grösser ist deren *entgegengebrachter Respekt*. Analysiert man das Antwortverhalten nicht nur auf zwei Personen bezogen, dann können Personen identifiziert werden, die den gesamten Kommunikationsfluss verlangsamen.

Ausbreitung von Infos / Krankheiten Es kann abgeschätzt werden, wie sich die Informationen innerhalb eines Netzwerks verbreiten. Nach erfolgter Verbreitung

[1] Personenwebseite vom MIT über Peter Gloor, `http://cci.mit.edu/pgloor/about.html`, [31.07.2017]

kann gemessen werden, welche Personen zu welchem Anteil zur Ausbreitung beigetragen haben. Dies kann wieder unter dem Gesichtspunkt des Marketings angesehen werden, dass die einflussreichsten Personen für die eigenen Kampagnen gewonnen werden sollen. Auch ist es möglich, mit Hilfe von Netzwerk-Abbildungen den Ursprung von Krankheiten einzugrenzen oder sogar zu ermitteln.

Empfehlungssysteme / Link-Prediction Ein Empfehlungssystem kommt beispielsweise bei Facebook zum Einsatz. Da werden unter „Personen, die sie vielleicht kennen“ weitere Freunde vorgeschlagen. Wie dies genau funktioniert, ist nicht bekannt. Aber gemeinsame Kontakte oder andere Gemeinsamkeiten zwischen Personen (z.B. Wohnort) werden sicher berücksichtigt. Es ist auch mit überschaubarem Aufwand möglich, ein eigenes, simples Empfehlungssystem zu erstellen. Angenommen, es besteht ein Two-Mode Netzwerk zwischen Personen und Musiktiteln, wo diejenigen Personen mit ihren Lieblings-Musiktiteln verbunden sind. Nun kann analysiert werden, welche Personen viele gemeinsame Lieblingslieder haben. Diese scheinen einen ähnlichen Musikgeschmack zu haben. Im Anschluss können den Personen Lieder für die Liste mit Lieblingsliedern vorgeschlagen werden, die bei ihnen noch nicht drauf sind, aber bei anderen Personen mit ähnlichem Musikgeschmack schon.

Der Fokus wurde hier auch auf Anwendungsfälle mit „sozialem“ Aspekt gelegt. Natürlich können verschiedene hier betrachtete Analysen auch auf Graphen ohne „soziale“ Aspekte angewendet werden. Beispielsweise können in einem Transport-Netzwerk ermittelt werden, bei welchen Knoten ein Ausfall kritisch wäre.

Teil II

Analyse

Kapitel 3

Modellierung Sozialer Netzwerke

Im vorherigen Kapitel wurde beschrieben, weshalb Menschen ein starkes Bedürfnis haben, miteinander in Kontakt zu stehen. In diesem Kapitel wird gezeigt, wie (Soziale) Netzwerke modelliert werden, um sie im Anschluss analysieren zu können. Dazu existieren verschiedene Modellierungsmöglichkeiten. Wenn das Grundverständnis vorhanden ist, werden im anschliessenden Kapitel 2 ein paar Anwendungsfälle von Sozialer Netzwerkanalyse detaillierter beschrieben.

Im Teil II werden dann verschiedene Analysemöglichkeiten im Detail beschrieben.

3.1 Abbildung des Sozialen Netzwerks als Graph

Ein soziales Netzwerk wird zur späteren Analyse als Graph modelliert und besteht somit aus *Knoten* (auch Aktoren oder Nodes genannt) und *Kanten* (Edges, Ties), welche die Interaktion zwischen den Aktoren abbilden. Das Modellieren ist sehr intuitiv. Im folgenden kleinen Beispiel-Graphen in der Abbildung 3.1 sind die Knoten A bis D dargestellt. Die Kanten zwischen den Knoten sind hier ungerichtet was bedeutet, dass die Interaktion in beide Richtungen erfolgen kann.

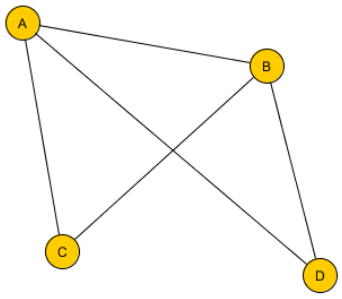


Abbildung 3.1: Ungerichteter Graph

Ein Beispiel für einen *ungerichteten Graphen* (ungerichtete Kanten, auch bidirektionale Kanten genannt) wäre das Facebook Freundes-Netzwerk. Da sind Personen miteinander befreundet oder nicht, aber eine Person A kann nicht mit der Person B befreundet

sein, wenn B nicht auch mit A befreundet ist. (Hingegen in Google Plus wäre so eine Konstellation denkbar, da eine Person A eine Person B in einen „Kreis“ hinzufügen kann, diese Person B muss Person A jedoch nicht in einen seiner Kreise hinzufügen). Im obigen Beispiel wäre die Person A mit allen drei anderen Personen befreundet. Die Person C und D jedoch nur mit 2 von den 3 möglichen Personen, da sie untereinander nicht befreundet sind.

Das Gegenstück dazu sind *gerichtete Graphen*. Ein Beispiel für gerichtete Graphen wäre ein E-Mail-Netzwerk. Hier visualisiert die Pfeilrichtung der Kante, wer wem eine E-Mail schreibt. Deshalb sind die Kanten in der Abbildung 3.2 gerichtet:

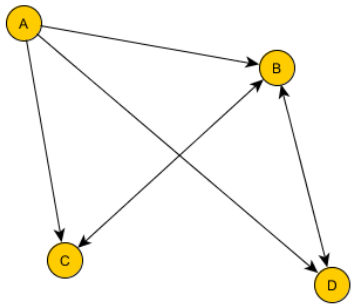


Abbildung 3.2: Gerichteter Graph

Es ist ersichtlich, dass die Person A nur E-Mails verschickt, aber keine empfängt. Dies wäre bei einem Newsletter-Konto denkbar, von dem aus nur informiert wird. Person B kommuniziert mit der Person C und D, die Personen C und D jedoch nicht miteinander. Ein solches Konstrukt könnte entstehen, wenn die Personen C und D zu verschiedenen Teams gehören (z.B. Teamleiter sind) und die Person B beide kennt. In der Sozialen Netzwerkanalyse stellen die Kanten eine direkte oder indirekte Kommunikation / Verbindung zwischen verschiedenen Aktoren dar. Einer Kante können dabei verschiedene Bedeutungen zugetragen werden. Mögliche Bedeutungen:

- Informations-Austausch
- Ressource-Austausch
- Beeinflussung
- Mitgliedschafts-Beziehung
- Verwandtschaft-Beziehung
- Persönliche Beziehung
- ...

Hier ein paar Beispiele, wie soziale Netzwerke anhand verschiedener Datenquellen konstruiert werden können:

Quelle	Bedeutung der Knoten	Bedeutung der Kanten
E-Mail-Kommunikation	Personen	E-Mails zwischen den Personen
Facebook Freundesbeziehungen	Personen (Freunde)	Freundschaftsbeziehungen zwischen Freunden
Tweets (Retweets)	Twitternde Personen	Tweets (zwischen der tweetenden und retweeteten Person)
Wikipedia Artikelnetzwerk	Wikipedia-Artikel	Beziehungen zwischen versch. Wikipedia-Artikeln
Webseiten Verlinkung	Webseiten	Links zwischen Webseiten

Knoten und Kanten können verschiedene Eigenschaften in Form von Attributen besitzen. Hier ein paar Beispiele:

- Facebook-Netzwerk: Personen (Knoten) können Herkunft, Alter, Geschlecht, Likes usw. als Eigenschaften hinterlegt haben.
- E-Mail-Netzwerk: Kanten (E-Mails) können Inhalt der Mails, Betreff und Datum beinhalten
- Twitter-Netzwerk: In den Knoten können Eigenschaften zur Person (Herkunft, Name, Beschreibung usw.), in den Kanten der Tweet selbst sowie das Datum abgelegt werden.
- Personen-Netzwerke: Als Kantengewicht kann angegeben werden, wie gut zwei Personen miteinander befreundet sind.

Oftmals beinhalten die Kanten ein Gewicht (z.B. Anzahl Benachrichtigungen untereinander). Bei solchen Graphen wird auch von *gewichteten Graphen* gesprochen. Die Netzwerk-Struktur sowie die Eigenschaften von Knoten/Kanten lassen interessante Analysen zu. Zum einen bietet die Netzwerk-Struktur bereits viel Potenzial, um Schlüsselpersonen und Gruppenzusammenschlüsse zu erkennen. Zum anderen kann das Netzwerk anhand der vorhandenen Eigenschaften der Knoten und Kanten gefiltert oder unterschiedlich dargestellt werden.

3.2 Netzwerk-Typen

Es gibt verschiedene Möglichkeiten, die gesammelten Daten als Soziales Netzwerk in einem Graphen zu modellieren. Aus einer Datenquelle können auch verschiedene Netzwerk-Modellierungen resultieren.

3.2.1 One-Mode Netzwerk

In einem *One-Mode Netzwerk* kann jeder Knoten mit jedem anderen verbunden sein. Es gibt nur ein Knotentyp. Ein paar Beispiele:

- E-Mail-Netzwerk: Knoten bilden Personen ab und alle Personen können miteinander verbunden sein, da alle die Möglichkeit haben, untereinander E-Mails auszutauschen.

- Freundschafts-Netzwerk: Knoten repräsentieren Personen, beliebige Personen können miteinander befreundet sein.
- Webseiten: Webseiten (hier als Aktoren verwendet) können mit beliebigen anderen Webseiten verlinkt sein.

3.2.2 Multirelationales Netzwerk

In einem *Multirelationalen Netzwerk* werden mehrere Beziehungstypen im selben Netzwerk abgebildet. Für eine genauere Analyse ist es dann erforderlich, die Relationstypen wieder zu reduzieren. Jedoch ist es interessant, aus einem ursprünglichen multirelationalen Netzwerk verschiedene Netzwerke mit unterschiedlichen Relationstypen zu extrahieren und die Analysen dieser einzelnen Subnetzwerke wieder miteinander zu vergleichen.

Signed Netzwerk

Ein *Signed Graph* ist ein Graph, dessen Kanten entweder in positives oder negatives Vorzeichen haben. In der Abbildung 3.3 ist ein solcher Signed Graph ersichtlich:

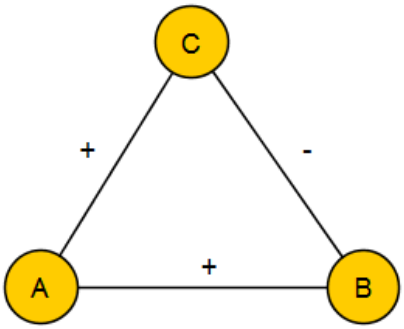


Abbildung 3.3: Signed Graph

3.2.3 Two-Mode Netzwerk

Bei *Two-Mode Netzwerken* existieren im Gegensatz zu den One-Node Netzwerken zwei verschiedene Typen von Knoten. Kanten existieren nur **zwischen** Knoten verschiedener Typen (auch Bipartites Netzwerk genannt). Ein paar Beispiele für Two-Mode Netzwerke:

- Personen-Event-Netzwerk: Es wird modelliert, welche Personen an welchen Events teilnehmen.
- Personen auf Webseiten: Personen-Knoten sind verknüpft mit denjenigen Webseiten-Knoten, auf welchen deren Namen erscheint.

Interessant ist, dass die Anzahl Kanten eines Knotens angeben, wie viele Verbindungen zum anderen Knotentyp bestehen unter der Voraussetzung, dass keine parallelen

Kanten existieren. Beachten Sie, dass später bei verschiedenen Analyse-Algorithmen zwischen One- und Two-Mode Netzwerken unterschieden werden muss. Im weiteren Verlauf des Scripts wird immer von einem One-Mode Netzwerk ausgegangen. Diese Analysen (Netzwerk-Metriken, Zentralitätsmasse usw.) für das One-Mode Netzwerk können nicht ohne Anpassung auf ein Two-Mode Netzwerk angewendet werden.

Ein Two-Mode Netzwerk lässt sich jedoch in ein One-Mode Netzwerk transformieren. Dazu gibt es verschiedene Möglichkeiten, welche in den nachfolgenden Unterabschnitten näher erläutert werden. Neben den aufgezeigten Varianten besteht zusätzlich auch die Möglichkeit, eine eigene Funktion für die Kantengewichtung zu definieren.

Einfache Transformation

Bei der einfachen Transformation werden im resultierenden Netzwerk alle Knoten eines Typ A miteinander verbunden, welche zu gemeinsamen Knoten des Typ B eine Kante haben.

Hier ein Beispiel: Es ist ein Two-Mode Netzwerk in Abbildung 3.4 abgebildet und visualisiert, welche Personen (gekennzeichnet mit Buchstaben) an welchen Events (gekennzeichnet mit Zahlen) teilnehmen:

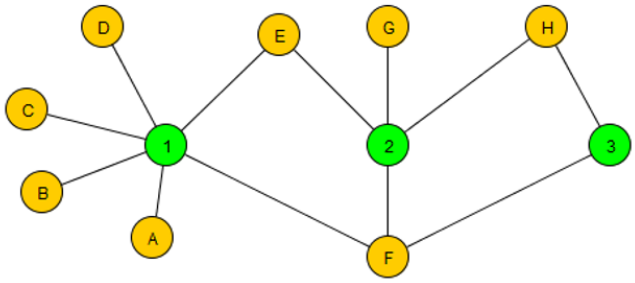


Abbildung 3.4: Two Mode Network

Nun wird dieses Two-Mode Netzwerk in Abbildung 3.4 nach obiger Beschreibung in ein One-Mode Netzwerk mit Personen-Knoten (Abbildung 3.5) umgewandelt:

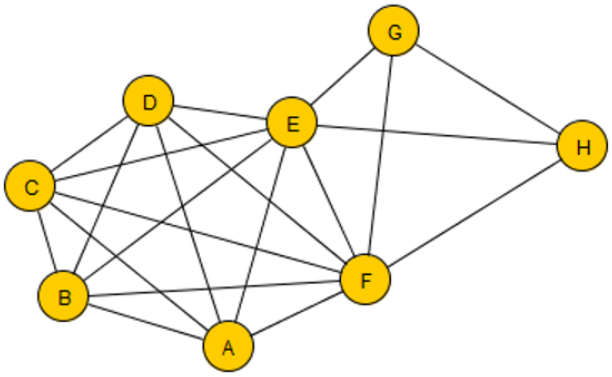


Abbildung 3.5: Umgewandeltes Two Mode Netzwerk in ein One-Mode Netzwerk

Da die Person E an beiden Events teilgenommen hat, ist sie nun mit allen anderen Knoten verbunden. Wie später noch ersichtlich wird, hat sie somit aus verschiedenen Gründen eine strategisch wichtige Position im Gesamtnetzwerk.

Gewichtete Transformation

Nachteilig bei der zuvor beschriebenen einfachen Transformation ist, dass alle Kanten im transformierten Netzwerk gleich gewichtet sind. Wird von einem Personen-Event Two-Mode Netzwerk ausgegangen, so entsteht im transformierten Personen-Netzwerk eine Kante zwischen zwei Personen, wenn diese mindestens an einem gemeinsamen Event teilgenommen haben. Haben Sie jedoch häufiger an gleichen Events teilgenommen, geht diese Information in der einfachen Transformation verloren.

Die gewichtete Transformation speichert die Information der Anzahl gemeinsamer Knoten (in diesem Beispiel Events) zwischen zwei Personen im transformierten Netzwerk. Die Transformation funktioniert genau gleich wie die einfache Transformation, es wird lediglich noch ein Kantenattribut *weight* abgeleitet, welche die gemeinsamen Vorkommnisse zählt. Das Mitführen dieser Information ist bei der weiteren Analyse des Netzwerks hilfreich, denn solche Transformationen führen zu Netzwerken mit sehr vielen Kanten. Mit einem Kantengewicht ist es dann möglich, das resultierende Netzwerk wieder zu filtern.

Ein konkretes Beispiel ist in Abbildung 3.6 ersichtlich, wobei die unbeschrifteten Kanten ein Kantengewicht von 1 haben:

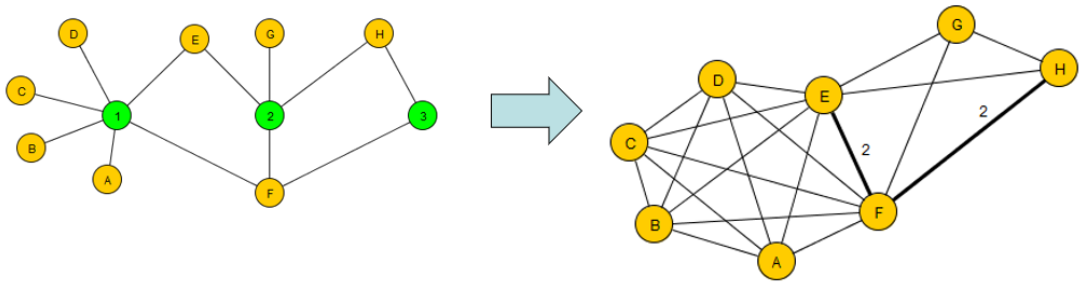


Abbildung 3.6: Transformation eines Two-Mode Netzwerks zu einem One-Mode Netzwerk mit der gewichteten Projection.

Newman's Weighted Projection

Newman hat eine spezielle Gewichtung für Kollaborations-Netzwerke definiert. Als fiktives Beispiel werden fünf Events angenommen; zwei Konzerte mit mehreren Tausend Personen, einen Info-Anlass einer Hochschule mit ein paar Dutzend Personen und zwei Geburtstags-Parties mit weniger als zehn Personen. Nun besuchen zwei Personen, die sich zuvor nicht kennen, die beiden Konzerte und den Info-Anlass. Im gewichteten transformierten Netzwerk erhalten diese beiden Personen ein Kantengewicht von 3. Zusätzlich gibt es zwei Personen, die sich ebenfalls zuvor nicht kennen, die beiden Geburtstags-Parties. Im transformierten One-Mode Netzwerk erhalten diese mit der

gewichteten Transformation ein Kantengewicht von 2. Dabei ist es sehr viel wahrscheinlicher, dass die letzten beiden Personen auf den Geburtstagsparties aufgrund der wenigen weiteren Personen miteinander in Kontakt kamen. Die *Newman's Weighted Projection* berücksichtigt bei der Gewichtung, wie viele Verbindungen die Knoten haben, über welche die Verbindung hergestellt wird. Umso mehr diese haben, desto kleiner das auf die Kante zu addierende Gewicht. Die Formel, um das Gewicht einer Kante zwischen den zwei Knoten u und v zu berechnen, ist wie folgt:

$$w_{u,v} = \sum_k \frac{d_k^u d_k^v}{d_k - 1} \tag{3.1}$$

Die Variablen in der Gleichung 3.1 haben dabei die folgende Bedeutung:

k**:** Knoten der Gruppe, über welche schlussendlich die Verbindung hergestellt wird und im resultierenden Netzwerk nicht mehr ersichtlich ist.

d_k^u**:** 1, falls eine Kante zwischen dem Knoten k und Knoten u existiert, ansonsten 0.

d_k^v**:** 1, falls eine Kante zwischen dem Knoten k und Knoten v existiert, ansonsten 0.

d_k**:** Anzahl Kanten des Knotens k

Nachfolgendes Zahlenbeispiel in der Abbildung 3.7 zeigt zwei Personen A und B, welche drei gemeinsame Knoten haben und anhand der Formel in 3.1 das resultierende Kantengewicht berechnet wird.

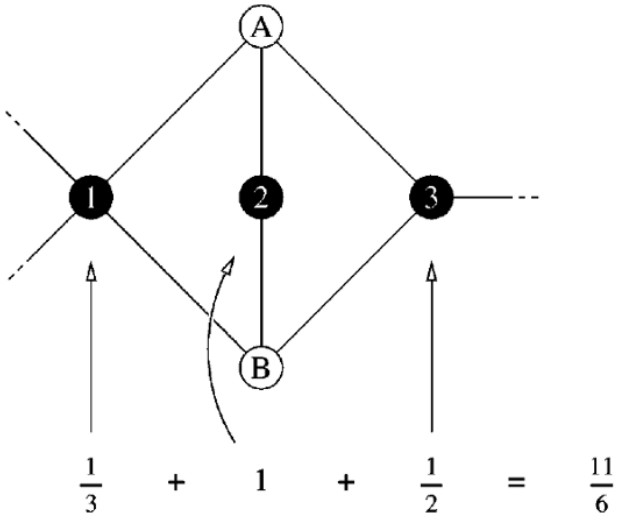


Abbildung 3.7: Berechnung des Kantengewichts mit der Newman's Weighted Projection Formel

Ein Beispiel eines komplett transformierten Netzwerks ist in Abbildung 3.8 ersichtlich:

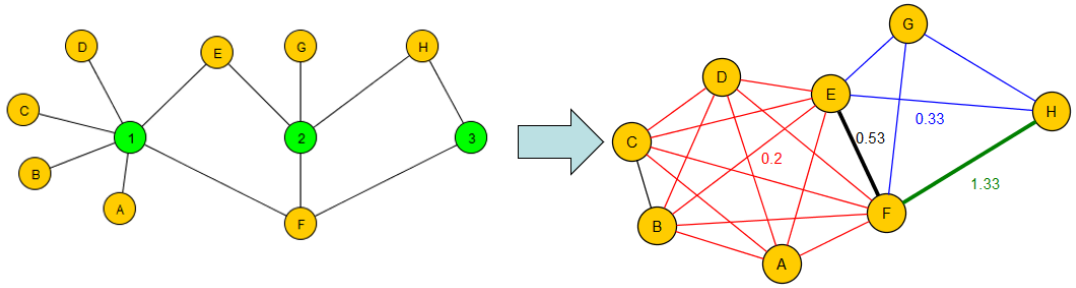


Abbildung 3.8: Transformation eines Two-Mode Netzwerks zu einem One-Mode Netzwerk mit der Newman's Weighted Projection, wobei alle Kanten der gleichen Farbe das gleiche Kantengewicht aufweisen.

Overlap Weighted Projection

Die *Overlap Weighted Projection* berechnet das Kantengewicht im transformierten Netzwerk anhand der *Jaccard-Similarity* der Nachbarsknoten im Ursprungs-Netzwerk. Ist die Überlappung der Nachbarn zweier Knoten im Ursprungsnetzwerk deckungsgleich, dann resultiert eine *Jaccard-Similarity* von 1.0. Die Formel für das Kantengewicht $w_{v,u}$ im Zielnetzwerk errechnet sich wie folgt:

$$w_{u,v} = \frac{N(u) \cap N(v)}{N(u) \cup N(v)} \tag{3.2}$$

Die Funktion $N(u)$ und $N(v)$ in der Gleichung 3.2 geben die direkten Nachbarsknoten des Knotens u resp. des Knotens v zurück.

Wenn grosse Unterschiede in der Verteilung der Anzahl Nachbarsknoten bestehen und von Interesse ist, wie gross die Überschneidung relativ zu dem Knoten mit dem kleineren Anzahl Nachbarn ist, kann auch folgende Formel verwendet werden:

$$w_{u,v} = \frac{N(u) \cap N(v)}{min(|N(u)|, |N(v)|)} \tag{3.3}$$

Ein Beispiel eines komplett transformierten Netzwerks ist in Abbildung 3.9 ersichtlich:

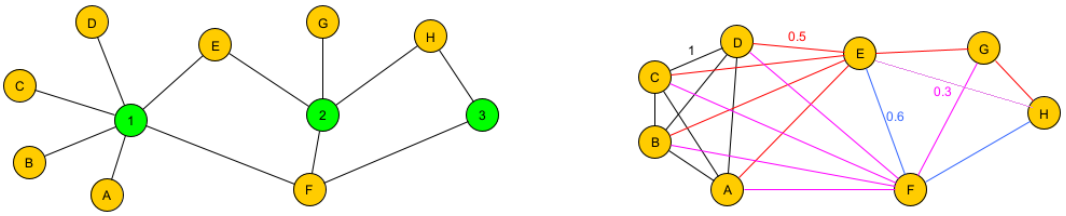


Abbildung 3.9: Transformation eines Two-Mode Netzwerks zu einem One-Mode Netzwerk mit der Overlap Weighted Projection (mit Jaccard-Similarity), wobei alle Kanten mit der gleichen Farbe das gleiche Kantengewicht aufweisen.

Individuelle Projektion

Es besteht auch die Möglichkeit, dass eigene Projektionen implementiert werden. Dies kann vor allem dann sinnvoll sein, wenn weitere Attribute in die Berechnung des Kantengewichts mitbeinbezogen werden sollten.

Kapitel 4

Reduktion des Netzwerks

Häufig sind die zu analysierenden Netzwerke sehr gross, was zur Notwendigkeit führt, das Netzwerk vor der Analyse zu reduzieren. Stellen Sie sich beispielsweise das E-Mail-Netzwerk einer grossen Firma vor. Darin hat es sehr viele Personen (Knoten) und über die Jahre sind auch verschiedene Personen miteinander in Kontakt getreten. Deshalb existieren im kompletten Netzwerk auch sehr viele Kanten. Im Anschluss werden verschiedene Verfahren zur Reduktion des Netzwerks grob beschrieben. Diese Verfahren können auch beliebig kombiniert werden.

Die meisten der vorgestellten Reduktionsmassnahmen basieren auf Knoten- und Kantenattributen. Deshalb ist es sehr empfehlenswert, nicht nur die Netzwerkstruktur, sondern auch die Attribute zu Knoten und Kanten einzusammeln. Es sollte darauf geachtet werden, dass die Daten möglichst vollständig und vereinheitlicht sind.

4.1 Local View

Eine einfache Möglichkeit das Netzwerk zu reduzieren ist das Filtern von Knoten anhand deren Attribute. So könnten die Knoten in einem Firmen-Netzwerk anhand deren Abteilung gefiltert und das Kommunikationsverhalten einzelner Abteilungen isoliert analysiert werden. Weitere Beispiele für das Filtern von Personen-Netzwerken wären Analysen anhand von Alter oder Herkunft. So wäre es auch möglich, dass die Vernetzung der Knoten untereinander (z.B. Density) für Männer und Frauen isoliert betrachtet und schlussendlich verglichen werden.

4.2 Global View

Die Global View erlaubt eine „allgemeine“ Sicht auf die Netzwerkstruktur. Dazu werden mehrere zusammengehörige Knoten anhand von gleichen Attributen zu einem einzelnen zusammengefasst; die detaillierte Sicht auf einzelne Knoten ist hier nicht von Interesse. Im Beispiel eines Unternehmens-Netzwerks, wo bei jeder Person das Attribut „Abteilung“ vorhanden ist, könnten die Knoten nach Abteilung gruppiert und das Kommunikationsverhalten zwischen den einzelnen Abteilungen analysiert werden.

4.3 Contextual View

Die Contextual View ist eine Kombination zwischen der Local und der Global View. Dazu werden die Knoten nach einem Attribut gruppiert (Global View). Danach wird eine einzelne Gruppe in der Local View angezeigt und der Rest in der Global View belassen. In unserem E-Mail-Beispiel mit den Angestellten und Abteilungen wäre somit ersichtlich, wie die einzelnen Personen in einer Abteilung mit allen anderen Abteilungen kommunizieren.

4.4 Ego Netzwerk

Ein Ego-Netzwerk beinhaltet einen spezifischen Knoten („Ego“), seine Nachbarn und die Kanten zwischen all diesen Aktoren. So ist ersichtlich, wie eine Person und deren Kontakte verknüpft sind. Anhand der Verbindungen zwischen den benachbarten Knoten können Rückschlüsse gezogen werden (z.B: Vereinszugehörigkeiten).

4.5 Filtern anhand von Kanten-Attributen

Eine sehr nützliche Reduktions-Massnahme ist das Filtern von Kanten anhand deren Attribute. Hier eignet sich das Gewicht der Kanten sehr gut. Wenn bei einem E-Mail-Netzwerk das Kantengewicht für die Anzahl E-Mails steht, können Kanten mit Gewicht unter einem definierten Schwellwert entfernt werden. Die Analyse der Verteilung der Kantengewichte ist sehr hilfreich, um einen solchen Schwellwert festzulegen. In unserem Firmenbeispiel ist davon auszugehen, dass gewisse Leute nur sehr wenig Kontakt miteinander hatten (z.B. Information über mitgebrachten Kuchen am Geburtstag).

Kapitel 5

Communities

Eine Community ist ein Subgraph innerhalb eines Graphen, in welchem die Knoten sehr stark untereinander verbunden sind. Aufgrund dieser engen Beziehung haben diese Personen ein grosses Vertrauensverhältnis zueinander und dadurch auch einen starken Zusammenhalt. Communities zeichnen sich durch einen starken Gemeinschaftssinn aus. Sie teilen in mindestens einem Punkt grosse Gemeinsamkeiten; sei dies eine Gesinnung, Hobbies, Beruf oder sonstige Interessen. Sie haben eine Tendenz zur gegenseitigen Angleichung und Konsensbildung. Communities bilden sich meistens um einen Kontext herum, z.B. Familie, Hobby, Berufskollegen usw. Dort gibt es auch häufig Kernmitglieder und periphere Mitglieder, die eher weniger Beziehungen zu anderen aufweisen.

5.1 Connected Components

Als *Connected Component* wird eine Menge von Knoten verstanden, die über beliebige Pfade miteinander verbunden sind. Ist ein Teilnetzwerk abgeschnitten, bildet es einen zweiten Component. Von allen vorgestellten Verfahren zur Gruppenfindung in einem Graphen sind die Bedingungen für einen Connected Component am wenigsten einschränkend.

Bei gerichteten Graphen wird zusätzlich zwischen *Strongly Connected Component* und *Weakly Connected Component* unterschieden. Wichtig ist: Bei beiden Connected Component Varianten befindet sich schlussendlich **jeder Node genau in einem Component**.

Ein Stronlgy Connected Components ist dadurch definiert, dass ich *alle Knoten entlang der Kantenrichtung* erreichen. Die Abbildung 5.1 zeigt Strongly Connected Components:

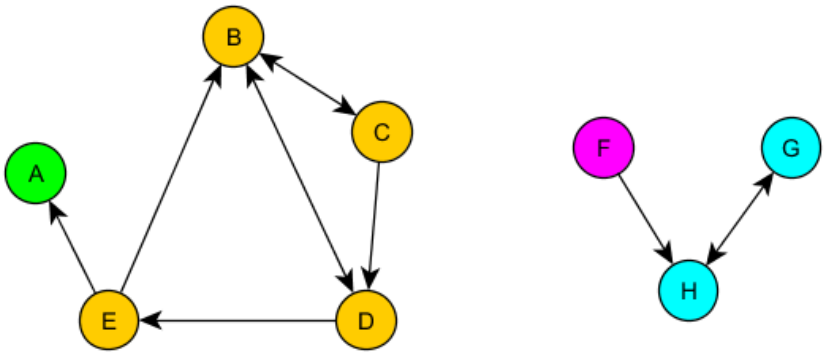


Abbildung 5.1: Strongly Connected Components

Darin befinden sich die folgenden Strongly Connected Components:

- B, C, D, E
- A
- G, H
- F

Bei Weakly Connected Components wird untersucht, welche Knoten einander erreichen, wobei die **Kantenrichtung ignoriert** wird und die Kanten einfach als bidirektional (in beide Richtungen zeigend) angesehen werden. Das Netzwerk aus Abbildung 5.1 wird nun in der Abbildung 5.2 als Weakly Connected Component angesehen:

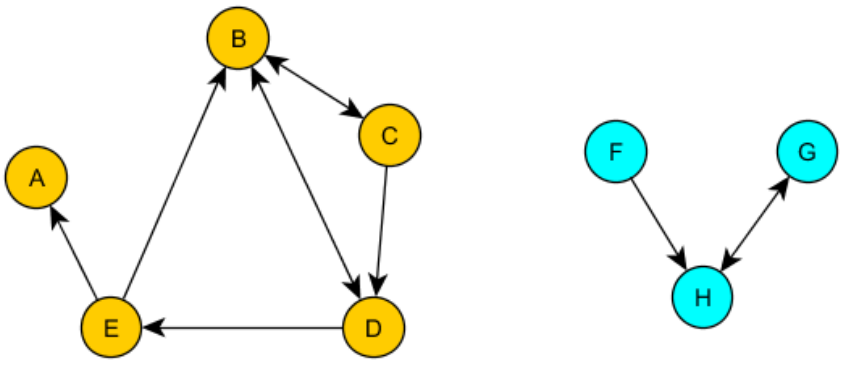


Abbildung 5.2: Weakly Connected Component

Deshalb entstehen schlussendlich die beiden folgenden Weakly Connected Components:

- A, B, C, D, E
- F, G, H

Bei ungerichteten Graphen wird nur von *Connected Components* gesprochen.

Wenn ein Component einen signifikanten Teil der Knoten des Netzwerks enthält, wird dieser *Giant Component* genannt. Abbildung 5.3 zeigt rot eingekreist einen solchen Giant Component:

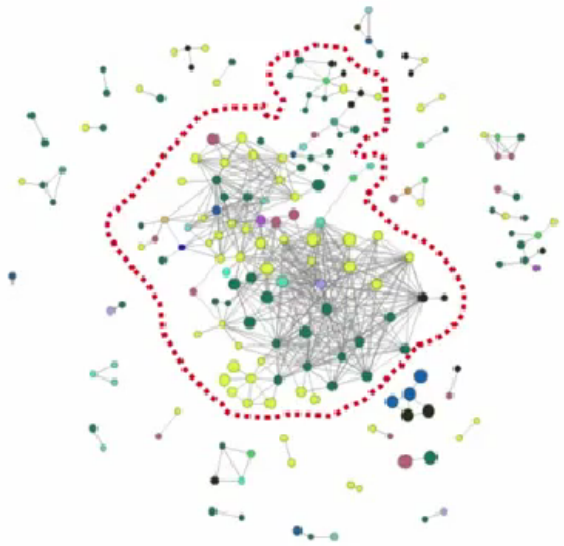


Abbildung 5.3: Giant Component

Interpretation

Falls der Graph aus mehreren Components besteht, kann dies dazu führen, dass Informationen nicht an alle Aktoren gelangen; der Informationsfluss ist also nicht mehr gewährleistet. Es zeigt, wie stark die Aktoren miteinander verbunden sind. Ebenfalls identifiziert die Analyse, welche Personen im Netzwerk gut miteinander verbunden sind und welche nicht, resp. welches das Kern-Netzwerk ist und welches die abgeschnittenen Teil-Netzwerke sind.

Ob in einem Netzwerk nach Strongly oder Weakly Connected Components gesucht wird, ist vom Anwendungsfall abhängig (Ist es wirklich wichtig, dass die Kommunikation entlang der Kantenrichtung erfolgt?). Weakly Connected Components sind einfacher zu finden, da diese Definition weniger restriktiv ist.

5.2 Cliquen

In Cliquen gibt es redundante Informations-Lieferanten, die Gruppe kann sich dank der *starken Verbundenheit* sehr schnell austauschen. Sie ist auch gegen aussen ein wenig abgeschottet und das Verlassen einer Clique kann auch der Verlust vieler Beziehungen zu Cliquen-Mitgliedern zur Folge haben. Mitglieder einer Clique entnehmen die Informationen aus dem gleichen Pool und sind gegenüber Innovationen und Entwicklungen von aussen eher abgekoppelt.

Es gibt verschiedene Möglichkeiten, wie eine Community identifiziert werden kann, die unterschiedlich „restriktiv“ sind. Hier ein paar davon:

Clique Ein kompletter (Sub-)Graph (alle Knoten kennen einander) wird häufig als *Clique* bezeichnet. Cliquen können sich auch überlappen, so dass ein Knoten in mehreren Cliquen gleichzeitig sein kann. Die *direkte Beziehung* zu anderen Mitgliedern steht im Vordergrund. Dies ist die am meisten einschränkende Definition einer Subgruppe.

k-Core Alle Knoten in einer Gruppe haben mindestens k Links zu anderen Gruppenmitgliedern. Hier besteht *nur ein gewisser Grad an Verbundenheit.*

n-Clique Alle Knoten in der Gruppe erreichen einander über maximal n Hops (= Distanz n). Hier wird die *Nähe der Cliquen-Mitglieder* in den Vordergrund gestellt.

Cliquen kommen meistens nur im Umfang von kleineren Knotenmengen (ca. 3-4 Personen) vor, da die Cliquen-Bedingung sehr restriktiv ist. Aufgrund der Struktur sind auch die Zentralitätsmasse innerhalb von Cliquen nicht sehr interessant (da alle gleich zentral), sehr wohl jedoch Überlappungen von Cliquen, da diejenigen Personen Informationen von beiden Gruppen erhalten. Diese Personen sind dann in einer Brokerage Position (siehe Kapitel 9):

In der Abbildung 5.4 ist ein Graph mit zwei Cliquen, grün und blau eingefärbt, ersichtlich. Der mittlere Knoten befindet sich in beiden Cliquen (Vermittler):

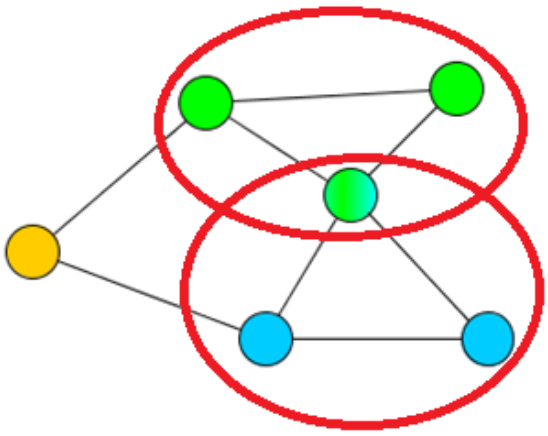


Abbildung 5.4: Netzwerk mit zwei eingekreisten Cliquen

5.2.1 k-Core

Ein k-Core hat eine weniger einschränkende Bedingung als Clique. Der k-Core ist ein *maximal grosser Subgraph*, wobei *jeder Knoten zu mindestens k andere Knoten des Clusters verbunden* sein muss.

In der Abbildung 5.5 bilden die grün eingefärbten Knoten einen 3-Core (resp. n-Core mit $n = 3$):

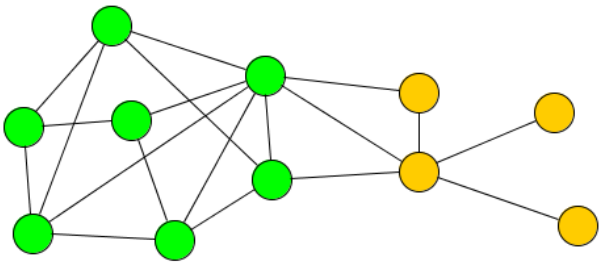


Abbildung 5.5: 3-core (grün eingefärbt)

Doch auch diese Definition hat einen entscheidenden Nachteil. Angenommen es gibt Knoten, welche weniger als k Kanten haben, aber nur zu Individuen einer Community verbunden sind, dann wären diese nicht Teil des k-Cores. (Oder der komplette Cluster wird auf einen geringeres k gestuft als eigentlich nötig). In der Definition der *p-Cliques* löst dieses Problem.

5.2.2 p-Cliques

Bei p-Cliques muss mindestens ein Bruchteil p (Angabe in Prozent) aller Kanten eines Knotens zu anderen Knoten führen, welche sich im selben Cluster befinden.

5.2.3 n-Cliques

Eine n-Clique ist eine *maximal grosse Gruppe von Knoten*, so dass *die Distanz aller Knotenpaare dieser n-Clique maximal n ist.* Eine übliche Anwendung ist die Berücksichtigung der direkten Kontakte von Knoten innerhalb einer Clique, also $n = 2$. Die Distanz zwischen zwei Knoten wird anhand des Ursprung-Netzwerks berechnet, so dass es passieren kann, dass schlussendlich der Graph Diameter der n-Clique grösser als n ist. Dies wird später noch grafisch veranschaulicht. Eine 1-Clique wäre somit eine Clique / kompletter Graph, wie sie vorher dargestellt wurde, wo jeder Knoten jeden anderen direkt erreichen kann.

Im Graphen in der Abbildung 5.6 befinden sich drei 1-Cliques, wobei die Knoten B,C und D zu zwei Cliquen gehören:

- A, B, C
- B, C, D
- D, E

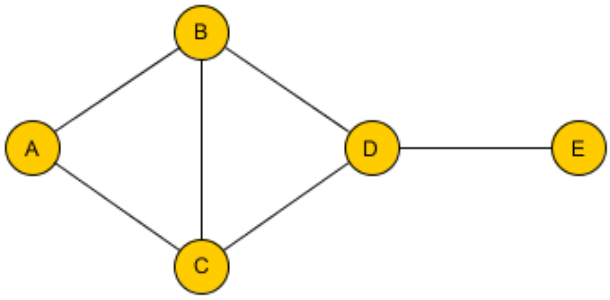


Abbildung 5.6: Beispielgraph für 1-Cliques und 2-Cliques

Gleichzeitig enthält der Graph in Abbildung 5.6 folgende 2-Cliques:

- A, B, C, D
- B, C, D, E

Bei n-Cliques können verschiedene Eigenheiten auftreten, welche alle dieselbe Ursache haben. Bei n-Cliques kann die definierte Distanz n über Knoten gehen kann, welche schlussendlich nicht im Cluster erscheinen. In der Tabelle 5.1 wird dies anhand von zwei Beispielen veranschaulicht:

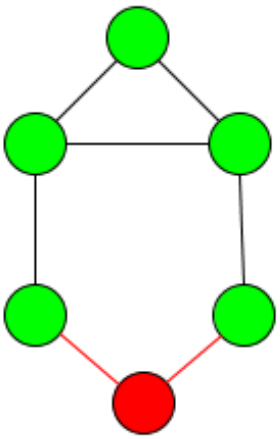
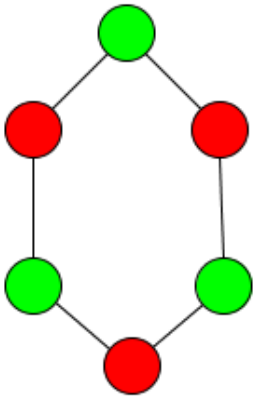
Der Durchmesser (Graph Diameter) der n-Clique kann grösser sein als das n. Grün ist die 2-Clique eingefärbt, deren beiden untersten Punkte sich aber nur über ein en Knoten ausserhalb des Clusters kennen:	Es kann passieren, dass die Knoten in der n-Clique nicht miteinander verbunden sind. Z.B können die roten und grünen Knoten als 2-Cliques interpretiert werden, deren Knoten aber nicht direkt miteinander verbunden sind:
	

Tabelle 5.1: Eigenheiten von n-Cliques beschrieben und grafisch dargestellt.

5.3 Clustering

Beim Clustering geht es darum, in einem Graphen Community Strukturen zu entdecken. Dazu gibt es verschiedene Vorgehensweisen, die zu verschiedenen Communities führen und unterschiedlich effizient in deren Ausführung sind.

5.3.1 Edge-Betweenness Clustering

Das Edge-Betweenness-Clustering, auch bekannt unter dem Namen Girvan-Neuman Clustering, ist ein Top-Down Clustering Verfahren. Dies bedeutet, dass sich zuerst alle Knoten im selben Cluster befinden und dann sukzessive aufgeteilt werden.

Wie der Name bereits vermuten lässt, wird als Ähnlichkeitsmass der Edge-Betweenness Centrality Wert berechnet. Die Edge-Betweenness-Centrality Berechnung funktioniert gleich wie bei die Node Betweenness Centrality, nur jetzt halt für Kanten.

Folgendes kleines Beispiel veranschaulicht die Berechnung der Edge Betweenness. Der rot eingefärbte Knoten ist immer der aktuelle Ausgangsknoten, grün die bereits verarbeiteten (kürzester Pfad zu diesen Knoten muss bei ungerichteten Graphen nicht mehr berücksichtigt werden) und die gelben sind noch ausstehend. Es wird mit dem Knoten A begonnen (Abbildung 5.7, links) und die kürzesten Pfade zu allen anderen Knoten gesucht. Nun wird bei *jeder Kante gezählt*, wie viele der kürzesten Pfade *über die entsprechende Kante verlaufen*. Wie bei der Node Betweenness-Centrality werden die kürzesten Pfade zu allen anderen Knoten auch für die verbleibenden Knoten berechnet (Abbildung 5.7, mitte, rechts). Schlussendlich hat die Kante zwischen den Knoten A und B den grössten Edge-Betweenness Wert. Diese Kante liegt am häufigsten auf den kürzesten Kommunikationspfaden zwischen allen Knotenpaaren.

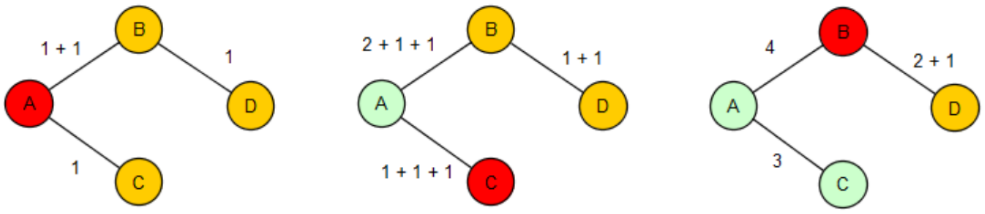


Abbildung 5.7: Berechnen der Edge-Betweenness Centrality

Ein hoher Edge-Betweenness Wert bedeutet, dass es sich um eine Kante zwischen zwei Knoten-Gruppen handelt. Umso grösser der Wert ist, desto stärker ist der Kommunikationspfad zwischen zwei Gruppen auf diese Kante beschränkt und hat deshalb umso mehr den Charakter einer Bridge. Bei diesem Clustering-Verfahren gibt es mehrere Iterationen, wobei in jeder Iteration diejenige(n) Kante(n) mit dem höchsten Betweenness-Wert entfernt wird, bis schlussendlich die gewünschte Anzahl Clusters erreicht worden ist. Dieses Verfahren ist sehr rechenintensiv, da nach jeder Iteration die Edge-Betweenness Werte neu berechnet werden müssen. Der komplette Algorithmus liegt in $O(n^3)$. Deshalb wird dieses Clustering-Verfahren selten eingesetzt (vor allem bei grossen Graphen).

Hier ein Beispiel für das Betweenness Clustering. Die Kante(n) mit dem höchsten

Betweenness-Wert sind jeweils rot eingefärbt und werden nacheinander entfernt.

Die Ausgangslage ist in Abbildung 5.8 abgebildet:

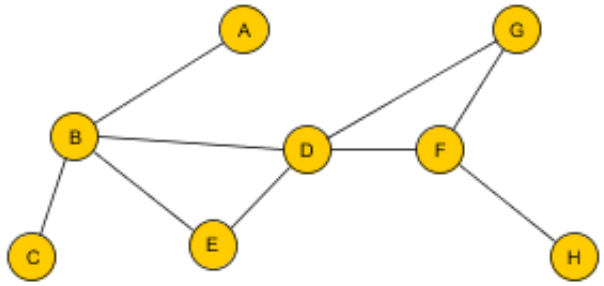


Abbildung 5.8: Edge-Betweenness Clustering: Ausgangslage

Nun werden die Edge-Betweenness Centrality Werte wie in der Abbildung 5.7 gezeigt, berechnet (siehe Abbildung 5.9). Diese müssen nicht normalisiert werden, da wir hier einfach nur den grössten Wert suchen:

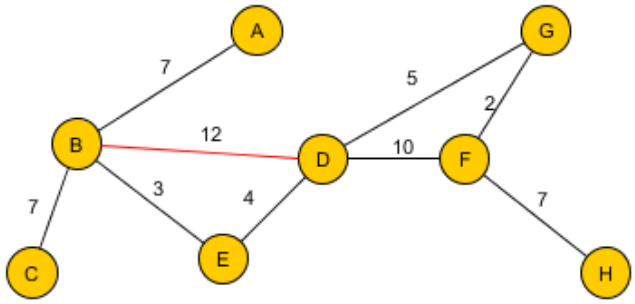


Abbildung 5.9: Edge-Betweenness Clustering: Berechnete Edge-Betweenness Werte

Nachdem die Kante mit dem höchsten Betweenness-Wert (B-D) entfernt wurde, werden die Kanten-Betweenness Werte in Abbildung 5.10 neu berechnet:

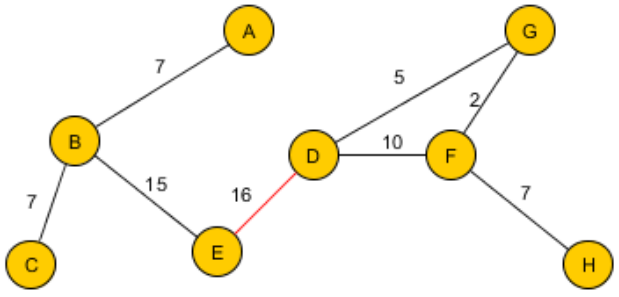


Abbildung 5.10: Edge-Betweenness Clustering: Neu berechnete Edge-Betweenness Werte

Nachdem wieder die Kante mit dem höchsten Betweenness-Wert (D-E) entfernt wurde, resultiert in Abbildung 5.11 den in zwei Clusters aufgeteilten Graphen:

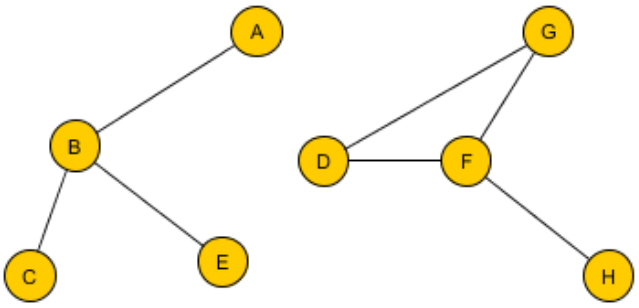


Abbildung 5.11: Edge-Betweenness Clustering: Aufgeteilt in zwei Clusters

5.3.2 Label Propagation

Der grosse Vorteil des Label Propagation Algorithmus ist, dass dieser auch auf grossen Netzwerken angewendet werden kann, wo das Edge Betweenness Clustering an seine Grenzen stösst. Der Label Propagation Algorithmus führt zu Beginn eine Färbung des Graphen durch und verwendet die Farben dann, um die Reihenfolge der Knoten im Algorithmus zu bestimmen. Würden die Knoten einfach in der bestehenden Reihenfolge abgearbeitet werden, dann wäre bei dichteren Netzwerken die Wahrscheinlichkeit gross, dass sich eine Farbe direkt in der ersten Iteration über das gesamte Netzwerk verbreitet und somit nur eine Community erkannt wird.

Der Algorithmus wird zuerst abstrakt beschrieben und dann an einem konkreten Beispiel ausgeführt:

1. Initialer Schritt: Graph Coloring. Der Graph wird so eingefärbt, dass keine zwei benachbarten Knoten haben die gleiche Farbe aufweisen. Es sollen jedoch möglichst wenig verschiedene Farben verwendet werden.

2. Jeder Knoten enthält zu Beginn ein eigenes Label: 0.. n – 1 (n = Anzahl Knoten). Schlussendlich gehören alle Knoten, welche dasselbe Label besitzen, zur gleichen Community. Zu Beginn startet jeder Knoten in einer eigenen Community.

3. Nun beginnt die Iteration, bis es zu keiner Label-Anpassung mehr kommt:

   3.1. Durchlaufe alle Farben und für jede Farbe immer alle Knoten. (Beides immer in derselben Reihenfolge)

      3.1.1. Betrachte die Labels (Zahlen, nicht Farben!) der Nachbarn des aktuellen Knotens.

      3.1.2. Zähle, wie häufig jedes Label (Zahl) in der Nachbarschaft erscheint

      - Falls es ein eindeutiges Label gibt, welches maximal häufig erscheint, dann ersetze das Label des aktuellen Knotens durch dieses.
      - Falls es mehrere Labels gibt, die maximal häufig erscheinen, dann behält der Knoten sein bisheriges Label, falls dieses in der Liste der maximal häufigen Labels erscheint. Ansonsten wird der grösste Wert in der Liste übernommen.

In der Abbildung 5.12 ist der Graph dargestellt, auf welchem mittels Label Propagation Communities identifiziert werden. Die Zahlen entsprechen dem Label (= initiale Community).

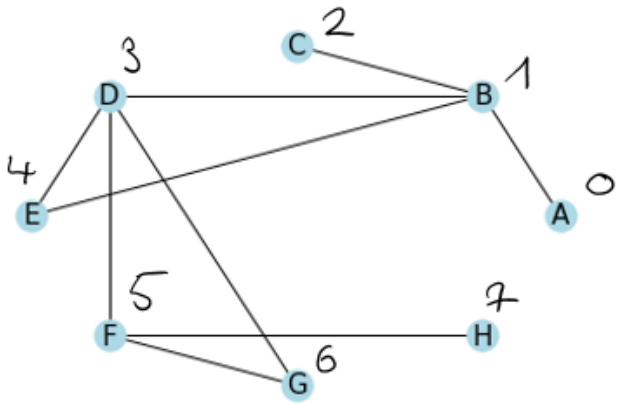


Abbildung 5.12: Initialer Graph mit bereits nummerieren Knoten, auf welchem der Label Propagation Algorithmus ausgeführt wird.

Der erste Schritt besteht darin, den Graphen einzufärben. In Abbildung 5.13 ist der eingefärbte Graph ersichtlich.

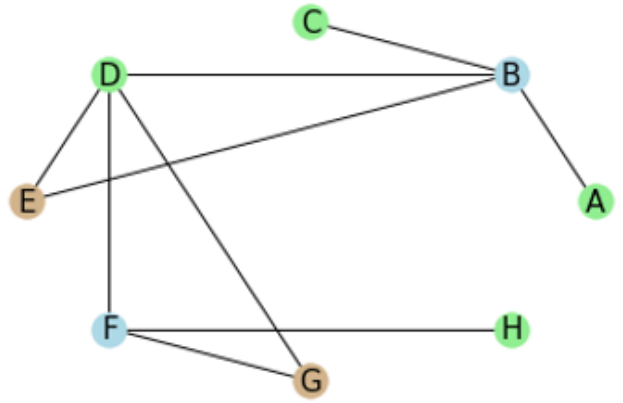


Abbildung 5.13: Initialer Färbung des Graphen.

Die Farben und Knoten werden in der nachfolgenden Reihenfolge abgearbeitet:

Blau mit den Knoten: B, F

Grün mit den Knoten: D, A, H, C

Braun mit den Knoten: E, G

Die Knoten wurden bereits in Abbildung 5.12 nummeriert.

Es beginnt die erste Iteration der Knoten der blauen Gruppe:

Knoten B Der Knoten B hat vier Nachbarn (A, C, D, E), welche die Labels 0, 2, 3, 4 haben. Jedes dieser Labels erscheint genau einmal, womit kein eindeutiges maximal häufiges Label existiert. Der Knoten B selbst hat das Label 1, welches nicht in der Liste der Nachbars-Labels erscheint. Deshalb wird gemäss der Beschreibung des Algorithmus Punkt 3.1.2. der grösste Wert in dieser Liste übernommen wird. Somit erhält der Knoten B neu das Label 4.

Knoten F Die Nachbarn des Knotens F haben die Labels 3, 6, 7. Der Knoten F selbst hat da Label 5. Somit haben wir den gleichen Fall wie beim Knoten B und der Knoten F erhält das Label 7.

Die blau eingefärbten Knoten wären nun abgearbeitet. Die angepassten Labels wurden in der Abbildung 5.14 nachgeführt.

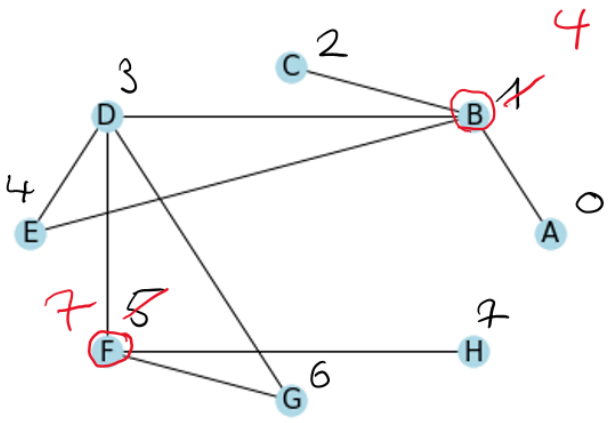


Abbildung 5.14: Angepasste Labels, nachdem die blau eingefärbten Knoten abgearbeitet wurden.

Die zweite Gruppe sind die grünen Knoten.

Knoten D Der Knoten hat die Nachbarn B, E, F, und G mit den Labels 4, 4, 7, 6. Wir haben mit der 4 ein eindeutig häufiges Label, weshalb dieses laut dem Algorithmus Punkt 3.1.2. dann auch für den Knoten D übernommen wird.

Knoten A Dieser hat nur einen Nachbarn mit dem Label 4, weshalb die 4 auch für den Knoten A übernommen wird.

Knoten H Dieser hat nur einen Nachbarn mit dem Label 7, weshalb die 7 auch für den Knoten H übernommen wird.

Knoten C Dieser hat nur einen Nachbarn mit dem Label 4, weshalb die 4 auch für den Knoten C übernommen wird.

Die grün eingefärbten Knoten wären nun ebenfalls abgearbeitet. Die angepassten Labels wurden in der Abbildung 5.15 nachgeführt.

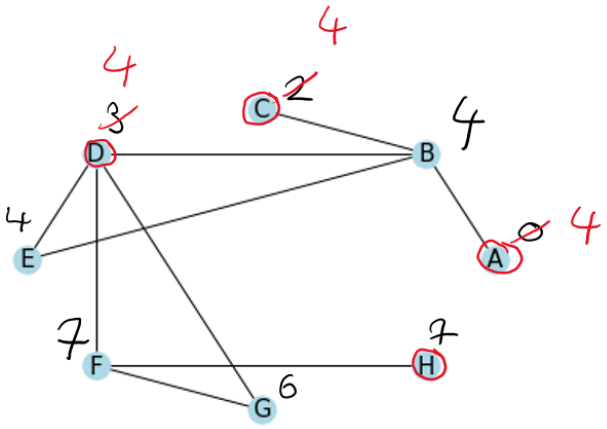


Abbildung 5.15: Angepasste Labels, nachdem die grün eingefärbten Knoten abgearbeitet wurden.

Die letzte Gruppe bilden nun noch die braunen Knoten.

Knoten E Die beiden Nachbarn des Knotens E haben das Label mit der Zahl 4, weshalb E ebenfalls die 4 als Label übernimmt.

Knoten G Der Knoten G hat zwei Nachbarn, den Knoten D mit dem Label 4 und den Knoten F mit dem Label 7. Der Knoten G selbst hat das Label 6, welches verschieden zu 4 und 7 ist. Deshalb wird die grössere Zahl übernommen, somit der Knoten G das Label 7 erhält.

Nachdem die braunen Knoten ebenfalls abgearbeitet wurden, ist die erste Iteration beendet. Die angepassten Labels wurden in der Abbildung 5.16 nachgeführt.

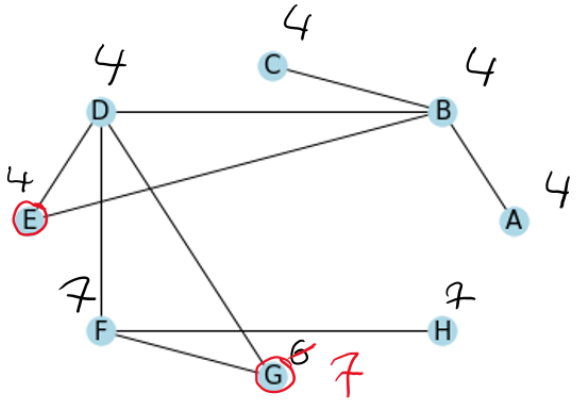


Abbildung 5.16: Angepasste Labels, nachdem die braun eingefärbten Knoten abgearbeitet wurden.

Dieser Prozess wird so lange fortgeführt, bis in einer Iteration keine Labels mehr angepasst werden. In diesem Beispiel kommt es schon bei der zweiten Iteration zu keiner

Anpassung mehr. Das Resultat ist eine Aufteilung in zwei Communities (siehe Abbildung 5.17).

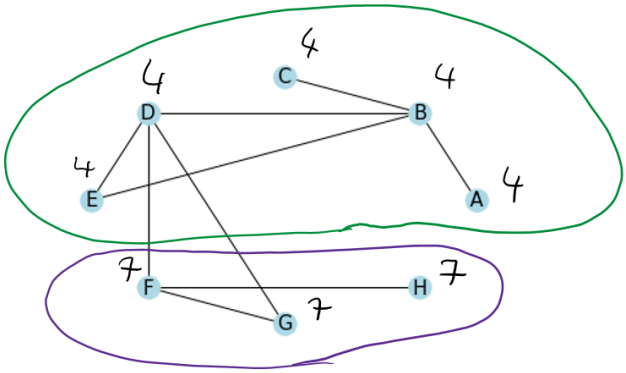


Abbildung 5.17: Communities, welche sich mit dem Label Propagation Algorithmus herauskristallisiert haben

5.3.3 Louvain Algorithmus für Community Detection

Der Louvain Algorithmus für Community Detection gehört zur Klasse der Greedy-Algorithmen. Dies bedeutet, dass der nächste Schritt nach dem Kriterium gewählt wird, was zum Zeitpunkt der Wahl am erfolgversprechendsten ist. Dies erfordert, dass der Algorithmus zu jedem Zeitpunkt entscheiden kann, was der beste nächste Schritt ist. Dazu wird eine Metrik benötigt, die es zu optimieren gilt. Beim *Louvain Algorithmus* wird die *Modularity* optimiert. Im nachfolgenden Abschnitt wird zuerst die *Modularity* genauer beschrieben und dann im Anschluss der darauf basierende Louvain-Algorithmus erklärt.

Modularity

Die *Modularity* ist eine Metrik, welche die Dichte von Kanten innerhalb der Communities mit den Kanten zwischen den Communities vergleicht. Umso mehr Kanten innerhalb der Communities und umso weniger zwischen den Communities erscheinen, desto höher ist der Modularity Wert. Es gilt, diesen Modularity-Wert zu maximieren. Die Modularity liefert immer einen Wert zwischen -0.5 und 1. Ein Wert > 0 bedeutet, dass die Anzahl Kanten innerhalb der Gruppen grösser ist, als es in einem zufällig angeordneten Graphen zu erwarten wäre. Ab einem Wert > 0.3 wurde eine signifikante Community-Struktur gefunden.

Die Formel zur Berechnung der Modularity in einem gewichteten Graphen über alle Knotenpaare hinweg ist in Gleichung 5.1 ersichtlich und wird im Anschluss noch im Detail erklärt:

$$Q = \frac{1}{2m} \sum_{ij} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j) \tag{5.1}$$

wobei die Variablen die folgenden Bedeutungen haben:

Q Modularity-Wert

A_{ij} Kantengewicht zwischen Knoten i und j aus der Adjazenzmatrix A

k_i **und** k_j Anzahl Kanten (=Degree) des Knotens i, resp. j.

m Summe aller Kantengewichte im Graphen resp. die Anzahl Kanten, wenn alle ein Gewicht von 1 haben.

c_i **und** c_j Die Communities, denen die Knoten i und j aktuell zugewiesen sind.

δ Die Kronecker Delta Funktion, welche 1 zurückgibt, falls beide übergebenen Werte gleich sind und sonst 0. Dies bedeutet hier, dass eine 1 zurückgegeben wird, falls beide Knoten zum selben Cluster gehören.

Das Kernstück der Formel in Gleichung 5.1 ist: $[A_{ij} - \frac{k_i k_j}{2m}]$. Zur bildlichen Erklärung wird als Beispiel der Graph in Abbildung 5.18 verwendet:

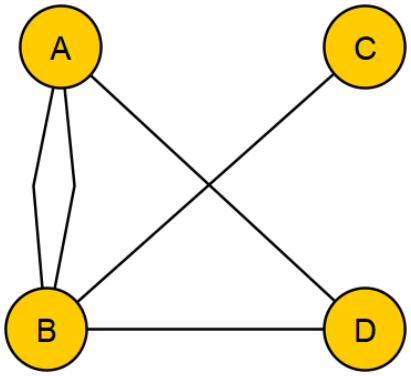


Abbildung 5.18: Beispiel für die Modularity-Berechnung, wobei das Kantengewicht zwischen den Knoten A und B zwei ist, aber hier zur Veranschaulichung als zwei Kanten dargestellt wird.

Das effektive Kantengewicht A_{AB} ist 2, weil zwischen den Knoten A eine Kante mit Gewicht 2 (hier als zwei einzelne Kanten abgebildet) besteht. Nun werden die zu erwartenden Anzahl Kanten (resp. Kantengewicht) zwischen den Knoten A und B berechnet, falls die Kanten im Graphen rein zufällig angeordnet werden. In der Formel wird dies mit dem Bruch $\frac{k_A k_B}{2m}$ notiert. Im Zähler werden die Degrees der beiden Knoten multipliziert. Im Nenner werden die Anzahl Kanten(gewichte) mit 2 multipliziert. Die zugrundeliegende Idee dabei ist, dass die Kanten alle in der Mitte durchgeschnitten werden, wodurch doppelt so viele „Kanten-Stummel“ entstehen wie Kanten. Dies ist in Abbildung 5.19 dargestellt:

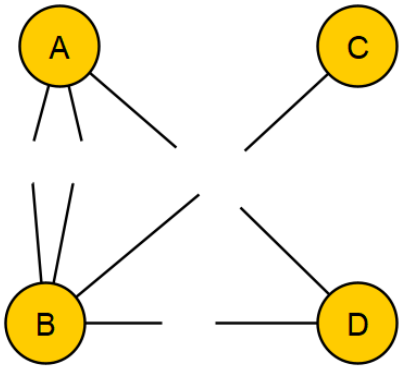


Abbildung 5.19: Durchtrennen aller m Kanten, so dass sich daraus $2m$ „Kanten-Stummel“ ergeben

Danach werden alle Stummel zufälligerweise mit anderen Stummeln verbunden. Von Interesse ist nun, welches Kantengewicht zwischen den Knoten A und B mit zufälligen Verbindungen zustande kommt. Im Graphen hat es eine Kante mit dem Gewicht 2 (zw. A und B als 2 Kanten dargestellt), und 3 Kanten mit einem Gewicht von 1. Somit haben wir schlussendlich 10 Stummel. Der Knoten A hat 3 Stummel (=Degrees), die zufällig neu verbunden werden (auch Self-Loops sind hier möglich). Der Knoten B hat 4 Stummel (= Degrees). Wenn nun einer dieser Stummel von A zufällig mit einem anderen Stummel verbunden wird, dann ist die Wahrscheinlichkeit, dass die Verbindung zu B hergestellt wird, folglich: $\frac{4}{10}$ und somit das zu erwartende Kantengewicht von 0.4 für diese eine Kante. Da wir aber beim Knoten A 3 Stummel haben, die zufällig verbunden werden, ändert sich der Erwartungswert des Kantengewichts zwischen A und B zu $\frac{3 \cdot 4}{10} = \frac{12}{10} = 1.2$.

Werden diese Werte nun ins Kernstück der Formel $[A_{ij} - \frac{k_i k_j}{2m}]$ eingetragen, ergibt sich: $[A_{AB} - \frac{k_A k_B}{2m}] = [2 - \frac{12}{10}] = [2 - 1.2] = 0.8$. Der Wert ist positiv, was bedeutet, dass im effektiven Graphen zwischen den Knoten ein grösseres Kantengewicht vorhanden ist, als bei einer rein zufälligen Anordnung zu erwarten ist. Dieser positive Wert findet aber nur Einzug in den totalen Modularity-Wert, wenn die Knoten A und B derselben Community zugeordnet sind. Verantwortlich dafür ist die Kronecker Delta Funktion $\delta(c_A, c_B)$, welche den vorherigen Wert von 0.8 mit 1 multipliziert, sofern die Knoten in der gleichen Community sind. Ansonsten mit 0. Folglich ist das Ziel, möglichst Knoten, deren effektives Kantengewicht grösser als das zu erwartende Kantengewicht ist, in die gleiche Community zu stecken und genau gegensätzliche Vorkommnisse in unterschiedliche Communities. Zur Bestimmung des Modularity-Wertes des kompletten Graphen werden alle Knotenpaare durchlaufen ($\sum_{ij}$) und die Werte aufsummiert. Der erste Teil der Formel $\frac{1}{2m}$ ist lediglich zur Normalisierung der Werte.

Hinweis: Auch wenn die Modularity hier im Abschnitt zum *Louvain-Algorithmus für Community Detection* erwähnt wird, kann das Verfahren unabhängig davon auch für die Beurteilung von Community-Strukturen verwendet werden, die durch andere Algorithmen gefunden wurden.

Die zwei Schritte des Louvain Algorithmus zur Erkennung von Communities

Die Abbildung 5.20[1] zeigt die beiden Phasen sehr schön, welche dann so lange durchlaufen werden, bis keine weitere Verbesserung des Modularity-Wertes mehr erreicht werden kann. Die detaillierte Beschreibung dazu folgt im Anschluss.

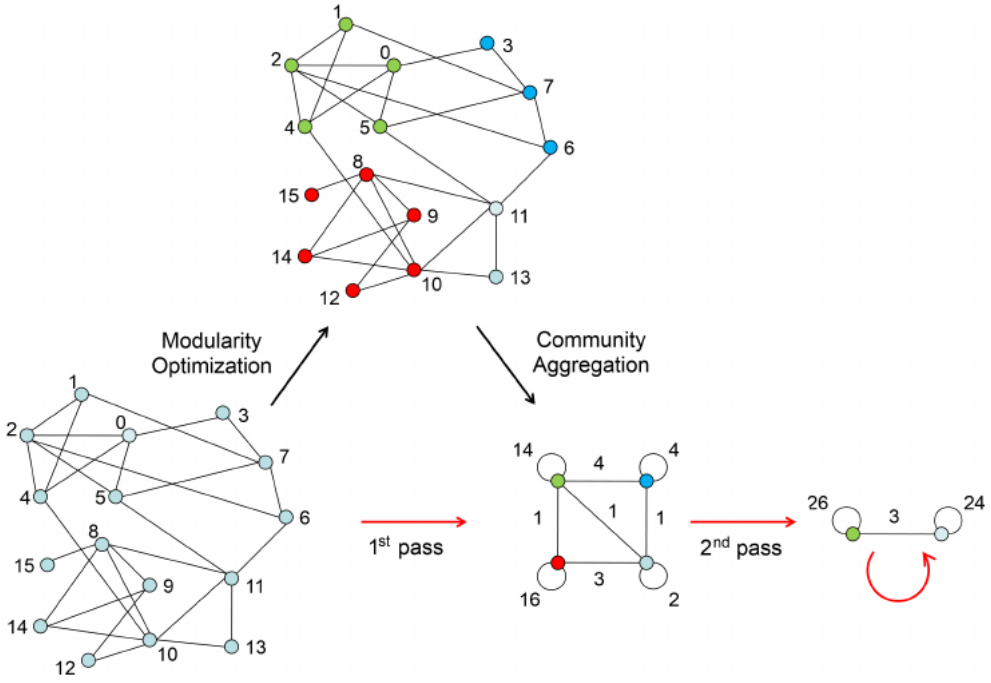


Abbildung 5.20: Die Schritte des Louvain Algorithmus

Beim *Louvain Algorithmus für Community Detection* werden iterativ zwei Schritte durchlaufen, bis keine Verbesserung der Modularity mehr erreicht werden kann. Die beiden Schritte sind:

1. **Modularity Optimization:** Jeder Knoten befindet sich zu Beginn in einer eigenen Community. Danach beginnt der iterative Prozess dieses Schrittes, wobei für jeden Knoten untersucht wird, wie sich die gesamte Modularity des Graphen verändert, wenn dieser aus seiner aktuellen Community entfernt und zur Community der Nachbarsknoten hinzugefügt wird. Falls keine Verbesserung der gesamten Modularity durch die Verschiebung des Knotens in die Community der Nachbarn möglich ist, dann bleibt der Knoten in seiner bisherigen Community. Ansonsten wird der Knoten derjenigen Community zugewiesen, die den grössten Zuwachs zur Modularity bringt. Sind alle Knoten durchlaufen, dann beginnt der nächste Durchlauf, bis die Modularity auf diese Weise nicht mehr verbessert werden kann.

2. **Community Aggregation:** Die Knoten befinden sich nun in der Community-Zuordnung mit maximaler Modularity. Nun werden alle Knoten der gleichen Community zu einem Knoten zusammengefasst. Die Kantengewichte zwischen den Knoten geben an, wie viele Verbindungen es zwischen den beiden Communities

[1] 2 Schritte des Louvain Algorithmus für Community Detection: `https://www.researchgate.net/figure/Louvain-algorithm-overview-Fig-1-in-10_fig1_263012166`, aufgerufen am 13.7.2021

vor der Zusammenführung gab. Die Self-Loops der Knoten geben an, wie viele Verbindungen zwischen den Knoten derselben Community existierten. Dabei wird das Kantengewicht mit dem Faktor 2 multipliziert. Befindet sich eine Kante zwischen zwei Communities, dann wird das Kantengewicht ausgehend von beiden Communities je einmal berücksichtigt. Befinden sich beide Kantenenden in derselben Community, wird das Kantengewicht verdoppelt, damit der Gesamtbeitrag über die Zeit gleich bleibt. Im Anschluss erfolgt wieder der erste Schritt.

Auf die mathematischen Details wird hier verzichtet. Da der Algorithmus eine Laufzeit von $O(n \cdot log\, n)$ hat, kann er auch auf sehr grosse Graphen angewendet werden.

Kapitel 6

Wichtigkeit von Knoten & Knotengruppen

6.1 Aktor-Zentralität

Zentralitätsmasse sagen aus, wie wichtig resp. „sichtbar“ ein einzelner Knoten im Netzwerk ist. Durch seine Position ist ein zentraler Aktor informiert und kann den Informationsfluss beeinflussen.

Es existieren verschiedene Zentralitätsmasse, welche die Wichtigkeit anhand unterschiedlicher Kriterien festlegen. Das Verständnis, wie die zu Grunde liegende Berechnung dieser Zentralitätsmasse funktioniert ist wichtig, um die Werte richtig zu interpretieren. Alle berechneten Zentralitätswerte können auch *normalisiert* werden. Dies bedeutet, dass der Zentralitäts-Wert des Knotens so normiert wird, dass dessen Wert zwischen 0 und 1 liegt. 0 bedeutet dann, dass der Knoten überhaupt nicht zentral ist und 1, dass der Knoten maximal zentral ist. Weil der Wert ins Verhältnis zur Netzwerkgrösse gesetzt wurde, können so Knoten unterschiedlicher Netzwerke verglichen werden.

6.1.1 Degree Centrality

Die Degree Centrality ist ein sehr einfaches Zentralitätsmass. Es zählt die Anzahl Kanten, die von einem Knoten weg gehen oder zu einem Knoten führen; also die Anzahl direkter Verbindungen zu seinen Nachbarn. Die Summe dieser Kanten bildet dann den Degree des Knotens. Die Degree Centrality kann als *lokales Mass* angesehen werden. Es sagt nichts über das komplette Netzwerk aus, sondern bietet lediglich eine isolierte Sicht auf einen Knoten.

Es gibt bei gerichteten Graphen auch die Möglichkeit, die *Indegree Centrality* resp. *Outdegree Centrality* zu berechnen. Dabei werden bei der Berechnung lediglich die eingehenden, resp. die ausgehenden Kanten gezählt. Abbildung 6.1 zeigt in Netzwerk, bei dem die Knotenbezeichnungen gerade dem Degree Centrality Wert entsprechen:

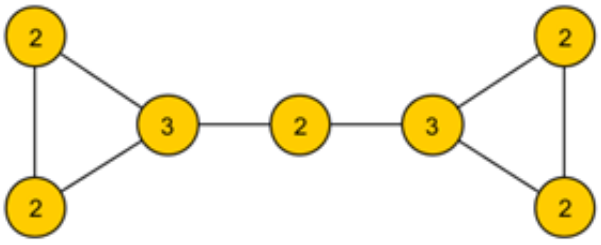


Abbildung 6.1: Knoten mit Degree Centrality als Bezeichnung

Normalisierung

Die Normalisierung wird für Degree Centrality eher weniger angewendet, da so oftmals sehr kleine Werte entstehen würden (grosse Netzwerke bestehen aus mehreren tausend Knoten). Zusätzlich steht häufig das Interesse an der absoluten Anzahl direkter Kontakte im Vordergrund.

Für die Normalisierung muss der Degree Centrality Wert des Knotens durch die maximale Anzahl möglichen Verbindungen dividiert werden. Dies sind:

- Bei ungerichteten Graphen: n-1
- Bei gerichteten Graphen: 2(n-1)

So entsteht für jeden Knoten einen Wert zwischen 0 und 1. Abbildung 6.2 zeigt die normalisierten für den Graphen aus der Abbildung 6.1.



Abbildung 6.2: Knoten mit **normalisierten** Degree Centrality Werten

Interpretation

Ein Aktor mit einem hohen Degree-Wert geniesst eine *hohe Wahrnehmung und Einfluss*. Er ist im Netzwerk sehr prominent. Beispielsweise erreicht eine Person mit hohem Degree-Wert in Facebook mit einer Statusmeldung sehr viele Leute. Solche Personen eignen sich, um Informationen zu verbreiten oder andere direkt zu beeinflussen (z.B bei Kaufentscheidungen). Ein hoher Degree-Wert bedeutet meistens auch eine *hohe (Kommunikations-)Aktivität*. Hat ein Aktor sehr viele Indegrees, gibt es auch viele Wege, über welche er informiert werden kann. Somit ist dieser im Allgemeinen sehr schnell informiert.

Ein grosser In-Degree Wert ist auch ein Zeichen für Prestige, da eine solche Person von anderen „gewählt“ wurde. Mehr zum den Prestige-Massen, wo auch der In-Degree nochmals erwähnt wird, ist im Abschnitt 6.2 ab der Seite 72 zu finden.

6.1.2 Closeness Centrality

Die vorangehend erläuterte Degree Centrality lässt sich leicht berechnen. Ein Schwachpunkt ist jedoch, dass es sich lediglich um ein lokales Mass handelt. Es betrachtet nur gerade die adjazenten Knoten und nicht das komplette Netzwerk. Möglicherweise ist es aber nicht wichtig, sehr viele direkte Kontakte zu besitzen, sondern *nicht zu weit vom Zentrum entfernt* zu sein. Ein Beispiel ist der grün eingefärbte Knoten in der Abbildung 6.3, welcher nur gerade 1 Hop vom zentralsten Knoten entfernt ist, jedoch lediglich eine Degree Centrality von 1 besitzt.

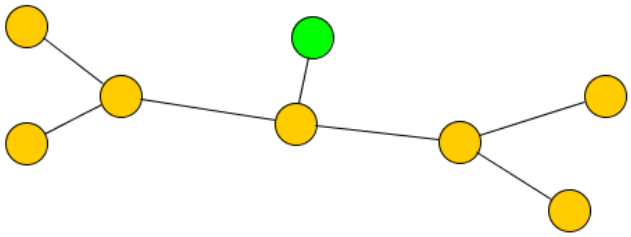


Abbildung 6.3: Der grün eingefärbte Knoten hat einen kleinen Degree-Wert, ist aber nahe am Zentrum

Die Closeness Centrality setzt da an. Sie berechnet für jeden Knoten, *wie effizient ausgehend von diesem Knoten alle anderen Knoten erreichbar sind.* Die Closeness Centrality für einen Knoten berechnet sich durch die Summierung aller Inversen der kürzesten Distanzen zu allen anderen Knoten. (Siehe Formel (6.6)). Die Berechnung der Closeness Centrality ist für grosse Graphen sehr zeitintensiv.

Nachfolgend ein Beispiel für die Berechnung der Closeness-Zentralität. Der Beispielgraph ist in Abbildung 6.4 und die Berechnungen ab (6.1) ersichtlich.

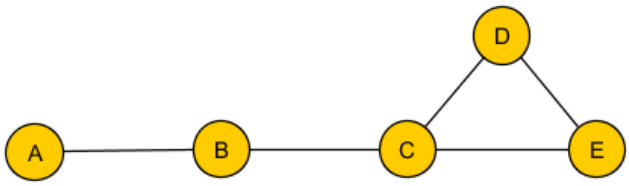


Abbildung 6.4: Beispielgraphen für die Berechnung der Closeness-Zentralität

$$C_C(A) = 1 + \frac{1}{2} + \frac{1}{3} + \frac{1}{3} = \frac{13}{6} \Rightarrow Normalisiert: \frac{1}{4} \cdot \frac{13}{6} = \frac{13}{24} = \underline{\underline{0.54}} \tag{6.1}$$

$$C_C(B) = 1 + 1 + \frac{1}{2} + \frac{1}{2} = 3 \Rightarrow Normalisiert: \frac{1}{4} \cdot 3 = \frac{3}{4} = \underline{\underline{0.75}} \tag{6.2}$$

$$C_C(C) = 1 + 1 + 1 + \frac{1}{2} = \frac{7}{2} \Rightarrow Normalisiert: \frac{1}{4} \cdot \frac{7}{2} = \frac{7}{8} = \underline{\underline{0.88}} \tag{6.3}$$

$$C_C(D) = 1 + 1 + \frac{1}{2} + \frac{1}{3} = \frac{17}{6} \Rightarrow Normalisiert: \frac{1}{4} \cdot \frac{17}{6} = \frac{71}{24} = \underline{\underline{0.71}} \tag{6.4}$$

$$C_C(E) = 1 + 1 + \frac{1}{2} + \frac{1}{3} = \frac{17}{6} \Rightarrow Normalisiert: \frac{1}{4} \cdot \frac{17}{6} = \frac{17}{24} = \underline{\underline{0.71}} \tag{6.5}$$

Formel

$$C_C(i) = \sum_{j=0}^{N} d(i,j)^{-1} \tag{6.6}$$

Die Formel aus 6.6 stammt aus der Coursera Vorlesung „Social Network Analysis“ von Lada Adamic ([Ada]). Viele Formeln aus der Literatur berechnen zuerst die Summe

und bilden erst am Schluss die Inverse davon. Das Problem dabei ist, dass Knoten in verschiedenen Components eine Distanz von ∞ haben. Wird die Summe der Distanzen aufgrund verschiedener Components ∞, dann ist die Closeness Centrality 0 (wegen $(\frac{1}{\infty})$). Mit der angegebenen Formel in 6.6 wird für die Distanz zwischen verschiedenen Components lediglich 0 als Summand verwendet.

Normalisierung

Für die Normalisierung wird die mit der Formel (6.6) berechnete Summe der inversen Distanzen dann noch durch die *Anzahl Knoten* − 1 geteilt.

Interpretation

Ein Aktor mit hoher Closeness Centrality kann alle anderen *Knoten im Netzwerk effizient erreichen*. Es kann als Mass für die sequenzielle Verbreitung von Informationen ausgehend von einem Knoten interpretiert werden, indem immer die kürzesten Pfade berücksichtigt werden.

6.1.3 Betweenness Centrality

Die Betweenness Centrality untersucht die Position eines Knotens unter Berücksichtigung des kompletten Netzwerkes. Nehmen wir dazu in eines unserer Beispiel-Netzwerke (Abbildung 6.5) mit eingetragenen Degree Centrality Werten:

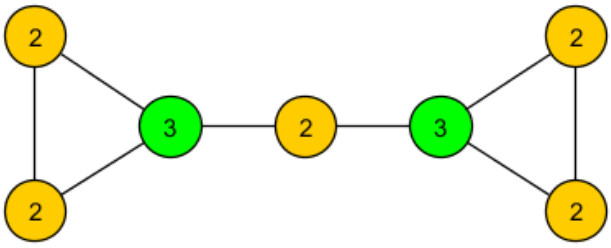


Abbildung 6.5: Netzwerk mit Degree Centrality als Knotenbezeichnungen

Aus der Sicht der Degree Centrality sind die grün eingefärbten Knoten in Abbildung 6.5 die wichtigsten. Der Knoten zwischen den beiden grünen scheint anhand der Degree Centrality weniger wichtig zu sein. Aus der Sicht des kompletten Netzwerkes ist er jedoch sehr wichtig, da er die *beiden Teilnetzwerke miteinander verbindet* (zusammen mit den beiden grünen Knoten). Immer wenn jemand vom linken Teilnetz mit dem rechten (und umgekehrt) in Kontakt tritt, geht die Kommunikation über den rot eingefärbten Knoten in Abbildung 6.6:

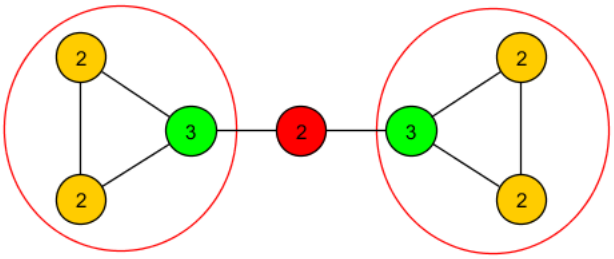


Abbildung 6.6: Der rot eingefärbte Knoten hat eine kleine Degree-Centrality, ist aber wichtig für den Zusammenhalt des kompletten Netzwerks.

Es wird in diesem Fall auch von *Brokerage Position* oder *Gatekeeper* (Vermittler-Position) gesprochen, einem „dazwischen sein“. Die Betweenness Centrality berechnet für jeden Knoten, *wie stark sich dieser in einer Brokerage Position befindet*. Dazu wird von jedem Knoten der kürzeste Pfad zu allen anderen Knoten berechnet. Für jeden Knoten wird gezählt, wie häufig dieser auf kürzesten Pfaden liegt. Umso häufiger dies der Fall ist, desto grösser seine Betweenness Centrality.

Der Algorithmus zur Berechnung der Betweenness Centrality wird anhand eines Beispiels erklärt. Die Ausgangslage ist wie folgt:

- Es handelt sich um ein ungerichtetes Netzwerk, die Pfeile veranschaulichen hier lediglich den kürzesten Pfad vom Start- zum Zielknoten und bedeuten nicht „gerichtete Kante“.
- Als Knotenlabel wird immer der aktuelle Betweenness Centrality Wert verwendet (initial 0)
- Die Knotenfarben haben folgende Bedeutungen:

  Rot: Bereits fertig verarbeitete Knoten

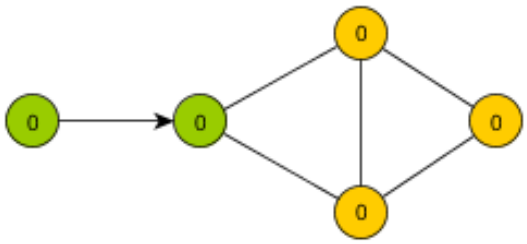
  Grün: Start- und Zielknoten für die Berechnung des kürzesten Pfades. Start- und Zielknoten lassen sich anhand der Pfeilrichtung unterscheiden.

  Grau: Über diese Knoten führt der kürzeste Pfad vom Start- zum Zielknoten.

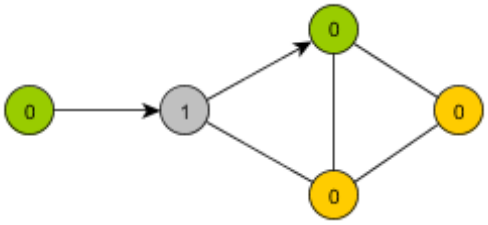
  Gelb: Diese Knoten sind im aktuellen Schritt nicht von Bedeutung

Die Berechnung der Betweenness Centrality für alle Knoten funktioniert wie folgt:

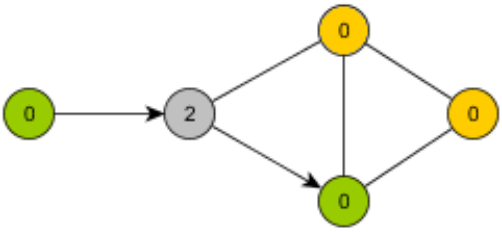
1. Jeder Knoten erhält zu Beginn den Betweenness Centrality Wert 0. Im Anschluss wird der kürzeste Pfad von allen Knoten zu allen anderen Knoten berechnet. Wir beginnen mit dem Knoten ganz links. Der kürzeste Pfad zum rechts daneben liegenden Knoten ist direkt. Es hat also keine anderen Knoten dazwischen.



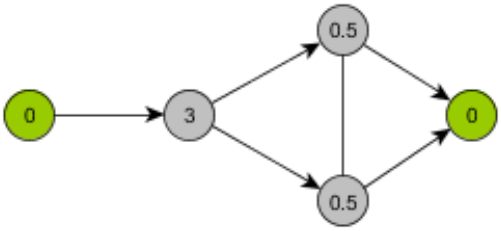
2. Der kürzeste Pfad zum Knoten oben geht über den vorherigen Zielknoten. Deshalb wird der Betweenness Centrality Wert dieses Knotens um 1 erhöht:



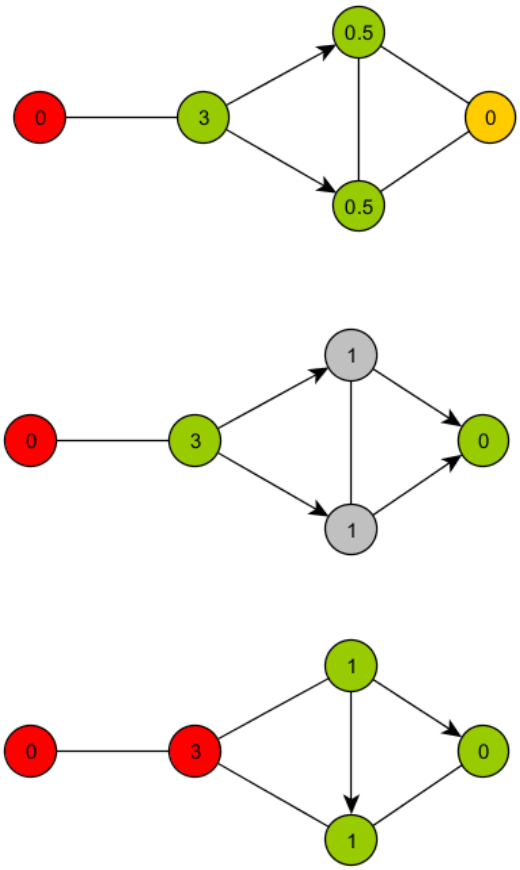
3. Beim unteren Knoten genau dasselbe wie zuvor:



4. Vom ersten zum letzten Knoten tritt ein Spezialfall auf. Es gibt zwei kürzeste Pfade! In diesem Fall wird jedem Knoten auf allen Pfaden jeweils $\frac{1}{\#\ kuerzeste\ Pfade}$ addiert. Im abgebildeten Fall haben wir zwei kürzeste Pfade vom Start- zum Zielknoten. Es werden beide kürzesten Wege berücksichtigt und da jeweils bei jedem Knoten $\frac{1}{2} = 0.5$ (weil 2 kürzeste Wege) addiert. Deshalb erhalten wir die folgenden Werte (der zweite Knoten von links hat nun den Wert 3, weil beide kürzeste Pfade über diesen verlaufen und somit 2 mal 0.5 addiert wurde):



5. Die restlichen Schritte werden nach dem gleichen Schema ausgeführt. Weil es sich um ein bidirektionales Netzwerk handelt, muss ein Knotenpaar lediglich einmal berücksichtigt werden. Ansonsten müssten jeweils auch die Wege „zurück“ zu bereits abgearbeiteten Knoten in Betracht gezogen werden.



Die Berechnung der Betweenness Centrality ist für grosse Graphen sehr zeitintensiv.

Hinweis: Es wurde erwähnt, dass bei ungerichteten Graphen der Weg zu bereits abgearbeiteten Knoten nicht mehr berücksichtigt werden muss. Dies ist so zu verstehen, dass bereits abgearbeitete Knoten nicht als Zielknoten verwendet werden, wenn es sich um einen ungerichteten Graphen handelt.

Aber: Es kann zu Situationen kommen, wo der kürzeste Pfad **über** einen bereits abgearbeiteten Knoten geht. Dann wird dessen Betweenness Centrality Wert ganz normal erhöht. Ansonsten hätte die Reihenfolge, in welcher die Knoten abgearbeitet werden, einen Einfluss auf die Betweenness Centrality Werte.

Formel

$$C_B(i) = \sum_{s \neq v \neq t \in V} \sigma_{st}(v) \tag{6.7}$$

Die Formel (6.7) zur Berechnung der Betweenness Centrality setzt sich wie folgt zusammen: Es werden zwischen allen Knotenpaaren s, t die kürzesten Wege σ_{st} berechnet. Für jeden Knoten v wird dann ermittelt, wie viele der kürzesten Pfade über ihn verlaufen. Die Summe der kürzesten Pfade durch einen Knoten für alle Knotenpaare bildet dann die Betweenness Centrality.

Normalisierung

Da diese Werte sehr gross werden können, macht eine Normalisierung Sinn. Dazu werden die berechneten Betweenness-Werte durch die Anzahl möglicher Verbindungen zwischen allen anderen Knotenpaaren geteilt: (n = Anzahl Knoten):

- Gerichtete Graphen: $(n-1) \cdot (n-2)$
- Ungerichtete Graphen: $\frac{(n-1) \cdot (n-2)}{2}$

Interpretation

Ein Aktor mit hohem Betweenness Centrality spielt eine zentrale Rolle, weil ein grosser Teil der Kommunikation des Netzwerks über diesen Knoten verläuft. Er hat auch die Möglichkeit, den *Informationsfluss* zu beeinflussen, indem er die Weiterleitung von Nachrichten verhindert oder fördert. Er kann die Nachrichten auch manipulieren oder Profit aus den Informationen schlagen. Aktoren mit einem hohen Betweenness Wert stellen zudem einen „kritischen" Punkt im Netzwerk dar, deren Ausfall die Gesamt-Kommunikation des Netzwerks markant beeinflussen kann.

6.1.4 Eigenvector Zentralität

Bei der Eigenvector-Zentralität berechnet sich die Wichtigkeit eines Knotens anhand der Wichtigkeit seiner benachbarten Knoten. Ein Knoten ist umso wichtiger, je wichtiger seine Nachbarn sind. Dies lässt sich auf gerichteten, wie auch auf ungerichteten Graphen berechnen. Bei ungerichteten Graphen werden zu dessen Berechnung alle Nachbarn berücksichtigt. Bei gerichteten Graphen werden normalerweise nur die In-Degrees berücksichtigt, so dass ein Knoten umso wichtiger ist, desto mehr andere wichtige Knoten auf diesen verweisen. Es ist jedoch auch einfach möglich, dies in die Gegenrichtung zu berechnen (die Wichtigkeit eines Knotens steigt, wenn dieser auf viele weitere wichtige Knoten verweist), indem die Kantenrichtung umgedreht wird. Das interessante an diesem Algorithmus ist, dass die initialen Werte für die Wichtigkeit eines Knotens anhand einer beliebigen kontinuierlichen Variablen definiert werden können (z.B. Einkommen).

Erklärt wird das Verfahren anhand eines Beispiels in Abbildung 6.7, dessen Bilder aus einem Blog-Eintrag entnommen wurden.[1]. Auf der linken Seite ist der Graph ersichtlich und rechts davon die Repräsentation dieses Graphen als Adjazenzmatrix.

[1] Eigenvector Centrality,`http://djjr-courses.wikidot.com/soc180:eigenvector-centrality`, [14.07.2020]

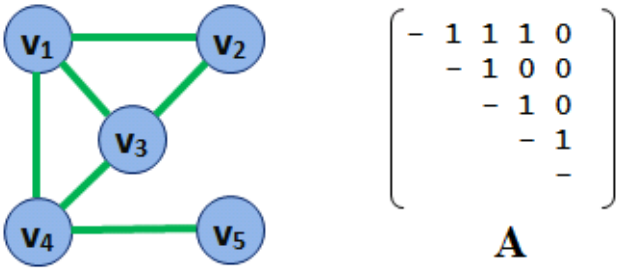


Abbildung 6.7: Beispielgraphen für die Berechnung der Eigenvector Zentralität mit Repräsentation als Adjazenzmatrix.

Nun muss noch festgelegt werden, wie die initiale *Wichtigkeit* der Knoten definiert ist. In diesem Beispiel in der Abbildung 6.8 wird der Degree der Knoten direkt als *Wichtigkeit* verwendet, welche in einem Vektor x abgelegt werden.

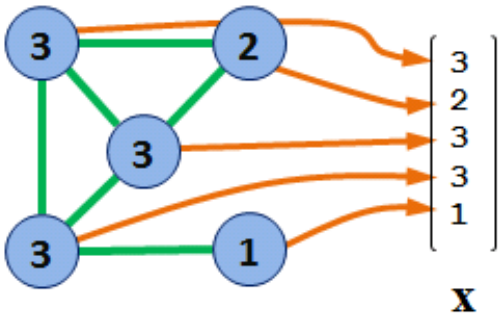


Abbildung 6.8: Initiale *Wichtigkeit* der Knoten anhand der Degree-Zentralität.

Das grundlegende Verfahren zur Berechnung der Eigenvector Zentralität ist nun, den Vector x mit der Adjazenzmatrix A zu multiplizieren. Abbildung 6.9 veranschaulicht dieses Vorgehen:

$$\mathbf{A} \times \mathbf{x} = \begin{pmatrix} - & 1 & 1 & 1 & 0 \\ 1 & - & 1 & 0 & 0 \\ 1 & 1 & - & 1 & 0 \\ 1 & 0 & 1 & - & 1 \\ 0 & 0 & 0 & 1 & - \end{pmatrix} \begin{pmatrix} 3 \\ 2 \\ 3 \\ 3 \\ 1 \end{pmatrix} = \begin{pmatrix} 0x3 + 1x2 + 1x3 + 1x3 + 0x1 \\ 1x3 + 0x2 + 1x3 + 0x3 + 0x1 \\ 1x3 + 1x2 + 0x3 + 1x3 + 0x1 \\ 1x3 + 0x2 + 1x3 + 0x3 + 1x1 \\ 0x3 + 0x2 + 0x3 + 1x3 + 0x1 \end{pmatrix} = \begin{pmatrix} 8 \\ 6 \\ 8 \\ 7 \\ 3 \end{pmatrix}$$

Abbildung 6.9: Multiplikation der Adjazenzmatrix A mit dem Vektor x

Wird der resultierende Vektor in Abbildung 6.9 nun genauer betrachtet fällt auf, dass jeder Knoten als Wert die Summe der Wichtigkeits-Werte dessen Nachbarn annimmt. Abbildung 6.10 zeigt dies deutlich.

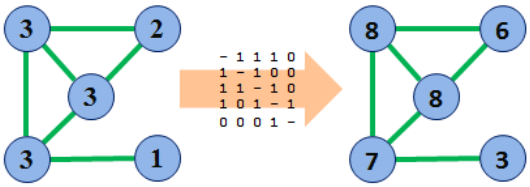


Abbildung 6.10:

Der Algorithmus wiederholt nun die bisher gezeigten Schritte, indem der resultierende Vektor aus der Abbildung 6.9 neu als Ausgangsvektor dient und mit der Matrix A multipliziert wird. So funktioniert das Prinzip zur Berechnung der Eigenvector Zentralität. Ein Problem ist, dass die Werte nun immer grösser werden. Um diesem Problem entgegenzuwirken, müssen die Vektoren vor jeder Matrix-Multiplikation wieder normalisiert werden. Die Gleichung 6.8 stellt die Normalisierung des initialen Vektors dar.

$$\hat{v} = \frac{v}{|v|} = \frac{\begin{pmatrix}3\\2\\3\\3\\1\end{pmatrix}}{\sqrt{3^2+2^2+3^2+3^2+1^2}} = \frac{\begin{pmatrix}3\\2\\3\\3\\1\end{pmatrix}}{\sqrt{9+4+9+9+1}} = \frac{\begin{pmatrix}3\\2\\3\\3\\1\end{pmatrix}}{5.65685} = \begin{pmatrix}0.53033009\\0.35355339\\0.53033009\\0.53033009\\0.1767767\end{pmatrix} \tag{6.8}$$

Wird der Vektor aus der Gleichung 6.8 wieder mit der Adjazenzmatrix A multipliziert und im Anschluss normalisiert, führt dies zum Vektor $\begin{pmatrix}0.53692\\0.40269\\0.53692\\0.46981\\0.20135\end{pmatrix}$

Der Algorithmus soll auch nicht unendlich lange fortgeführt werden. Deshalb gibt es bei der Konfiguration des Algorithmus eine Einstellung, wie häufig diese Iteration maximal ausgeführt wird. Zudem kann ein Schwellwert definiert werden, so dass die Iteration abgebrochen wird, sobald sich die Werte der Vektoren nur geringfügig ändern. Um die Veränderung zwischen den Iterationen zu messen, werden die Beträge der Vektor-Differenzen aufsummiert (siehe Gleichung 6.9).

$$|0.53033009 - 0.53692| + |0.35355339 - 0.40269| + |0.53033009 - 0.53692| + \tag{6.9}$$

$$|0.53033009 - 0.46981| + |0.1767767 - 0.20135| \tag{6.10}$$

$$= 0.00658991 + 0.04913661 + 0.00658991 + 0.06052009 + 0.0245733 = 0.14740982 \tag{6.11}$$

In der nächsten Iteration beträgt dann die Differenz nur noch 0.046863. Nach 20 Iterationen dieses Beispiels verbleibt der Vektor $\begin{pmatrix} 0.537074 \\ 0.406697 \\ 0.537074 \\ 0.474754 \\ 0.179746 \end{pmatrix}$ und noch eine Differenz von 0.00003555 zum Vektor der 19. Iteration.

Das Resultat dieser Iterationen ist der Eigenvector zur zum grössten Eigenwert der Adjazenzmatrix. Dies lässt sich auch schreiben als: $Ax = \lambda x$, wobei x der Eigenvector und λ den grössten Eigenwert darstellt. Der grösste Eigenwert der Matrix in Abbildung 6.7 beträgt 2.64119 mit dem zugehörigen Eigenvector $\begin{pmatrix} 2.98793 \\ 2.26257 \\ 2.98793 \\ 2.64119 \\ 1 \end{pmatrix}$. Nach der Normalisierung wird dieser Vektor zu $\begin{pmatrix} 0.537074 \\ 0.406698 \\ 0.537074 \\ 0.474754 \\ 0.179746 \end{pmatrix}$, was fast dem Vektor nach der 20. Iteration entspricht.

Der *Page Rank* von Google basiert auf der Eigenvector Zentralität. Zudem gibt es noch die *Katz Zentralität*, welche eine Generalisierung der Eigenvector Zentralität ist.

6.2 Prestige

Wenn in einem Netzwerk die Kanten gerichtet sind, dann kann auch das *Ansehen* (Prestige) der Personen untersucht werden. Voraussetzung dafür ist, dass die Kantenbedeutung diese Interpretation zulässt. Zwei Möglichkeiten zur Berechnung eines Prestige-Wertes werden in den kommenden Unterabschnitten genauer beschrieben.

6.2.1 Indegree (Popularity)

Das simpelste Prestige-Mass ist der Indegree eines Knotens, wo das Prestige-Mass sich einfach anhand der *Summe aller eingehenden Kanten* für einen Knoten bestimmen lässt. Der Nachteil dieses Masses ist, dass es nur gerade die direkten Nominationen berücksichtigt und dass in sehr dichten Netzwerken sehr viele Knoten einen hohen Indegree haben.

6.2.2 Proximity Prestige

Proximity Prestige Mass berücksichtigt nicht nur die direkten Indegrees, sondern *alle Knoten, welche direkt und indirekt auf einen Knoten zeigen.* Direkte und kurz entfernte Knoten haben dabei einen grösseren Einfluss als weit entfernte Knoten. Die Berechnung

des Proximity Prestiges Wertes funktioniert wie folgt:

$$ProxymityPrestige(v) = \frac{\frac{|I|}{(n-1)}}{\frac{\sum_{i \in I} d(i,v)}{|I|}} \tag{6.12}$$

Die Variablen in der Formel (6.12) haben die folgenden Bedeutungen:

I Menge aller Knoten, welche den Knoten v entlang der Kantenrichtungen erreichen können (direkt oder indirekt) (ohne den Knoten v selbst)

n Anzahl Knoten im Netzwerk insgesamt

d(i,v) Kürzeste Pfadlänge zwischen den Knoten i und v

Die Formel 6.12 in Worten ausgedrückt:

$P_P(v)$ = Anteil der Knoten, welche direkt oder indirekt auf den Knoten v verweisen (ohne Knoten selbst) [Zähler] dividiert durch den Durchschnitt aller Pfadlängen der auf den Knoten v verweisenden Knoten [Nenner].

Da die Definition sehr kompliziert klingt, folgt ein anschaulicheres Beispiel zur Berechnung der Proximity Prestige. Im Graphen in der Abbildung 6.11 haben die Pfeil-Richtungen die Bedeutung: „Hat um Rat gefragt“:

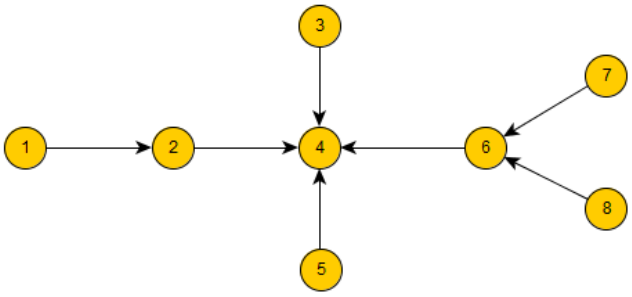


Abbildung 6.11: Beispielgraph zur Berechnung der Proximity Prestige. Die Kanten haben die Bedeutung: Hat um Rat gefragt

Im Netzwerk befinden sich insgesamt 8 Knoten. Alle Knoten ohne eingehenden Kanten haben eine Proximity Prestige von 0. Das wären die Knoten: 1, 3, 5, 7, 8.

Der Knoten 2 hat genau einen Knoten (1), welcher direkt auf ihn verweist. Daraus folgt:

$$P_P(2) = \frac{\frac{1}{(8-1)}}{1} = \frac{1}{7} = \underline{\underline{0.14}}$$

Der Knoten 6 hat 2 Knoten, die direkt auf ihn verweisen:

$$P_P(6) = \frac{\frac{2}{(8-1)}}{\frac{2}{2}} = \frac{2}{7} = \underline{\underline{0.29}}$$

Interessant wird es beim Knoten 4. Alle anderen Knoten (7 Stück) verweisen direkt oder indirekt auf ihn. Die Summe der (kürzesten) Pfadlängen beträgt 10 ($4 \cdot 1$ (Knoten 2, 3, 5, 6) plus $3 \cdot 2$ (Knoten 1, 7, 8) $= 4 + 6 = 10$).

$$P_P(4) = \frac{\frac{7}{(8-1)}}{\frac{10}{7}} = \frac{1}{\frac{10}{7}} = \underline{\underline{0.7}}$$

Derselbe Graph wie in Abbildung 6.11 mit den berechneten Proximity Prestige Werten als Knotenbzeichnungen ist in Abbildung 6.12 ersichtlich.

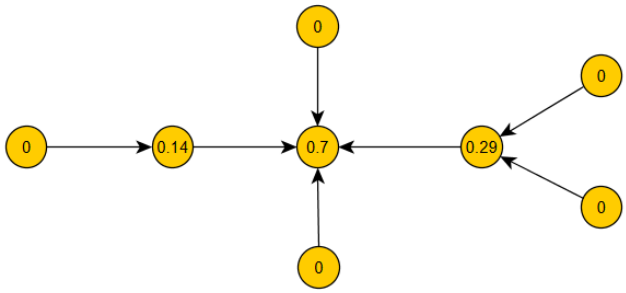


Abbildung 6.12: Proximity Prestige Beispiel: Berechnet

6.3 Actor Group Centrality

Im Abschnitt 6.1 wurde untersucht, wie zentral die Positionen einzelner Knoten innerhalb des Netzwerks war. Eine interessante Erweiterung ist die *Actor Group Centrality*, welche die Actor Zentralitätsmasse verwendet und untersucht, wie zentral eine Gruppe von Knoten ist. Dies kann beispielsweise interessant sein, wenn eine geeignete Personengruppe gefunden werden sollten, um eine Information möglichst im kompletten Netzwerk zu verbreiten.

6.3.1 Degree Group Centrality

Bei der Actor Degree Centrality wird untersucht, wie viele direkte Verbindungen ein Knoten zu anderen Knoten im Netzwerk hat. Bei der *Degree Group Centrality* wird von einer Gruppe von Knoten ausgegangen und untersucht, zu welchem Anteil der Knoten ausserhalb der Gruppe eine direkte Verbindung besteht.

Es wird vom Beispielgraph in Abbildung 6.13 ausgegangen:

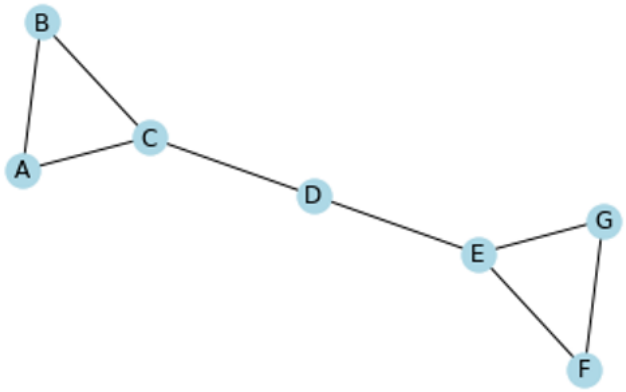


Abbildung 6.13: Beispielgraph zur Berechnung der Degree Group Centrality

Nehmen wir die Gruppe (D, E) an. Die Knoten D und E haben direkte Verbindungen zu den Knoten C, G, F, wobei nur diejenigen berücksichtigt werden, die nicht zur Gruppe gehören. Im Graphen gibt es jedoch noch die zwei weiteren Knoten A und B, welche weder in der Gruppe (D, E) sind, noch von den Knoten innerhalb der Gruppe direkt referenziert werden. Somit resultiert für die Gruppe (D, E) eine Degree Group Centrality von $\frac{3}{5} = 0.6$

Würden die Knoten C und E eine Gruppe bilden, dann ergibt sich eine Degree Group Centrality von 1, da diese beiden Knoten zusammen eine direkte Verbindung zu allen anderen Knoten im Netzwerk haben.

6.3.2 Closeness Group Centrality

Die Closeness Group Centrality misst, wie nahe eine Gruppe von Knoten den restlichen Knoten im Netzwerk ist. Dazu wird wie bei der Actor Closness Centralität die Inverse

der Distanzen aller Knoten ausserhalb der Gruppe aufsummiert. Die Distanz ist nun jedoch als Pfadlänge zum nächstgelegenen Knoten innerhalb der Gruppe definiert.

Der Graph in Abbildung 6.14 wird als Beispielgraph verwendet.

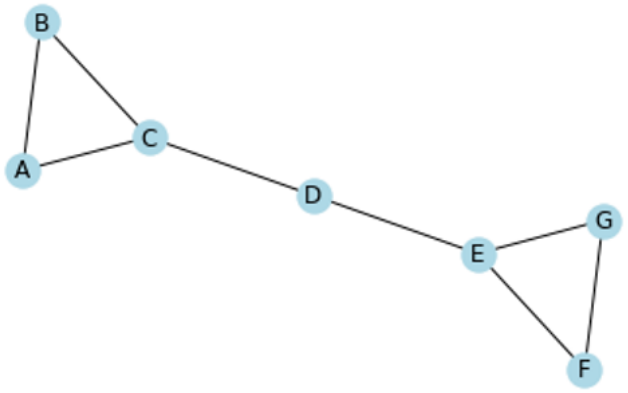


Abbildung 6.14: Beispielgraph zur Berechnung der Closeness Group Centrality

Die Knoten D und E bilden die Gruppe, für welche die Closeness Group Centrality berechnet werden soll. Die Knoten C, G und F sind direkt mit den Knoten innerhalb der Gruppe verbunden und haben somit eine Distanz von 1. Die Knoten A und B haben eine Distanz von 2 zum nächstgelegenen Knoten innerhalb der Gruppe (Knoten D). Somit ergibt sich für die nicht normalisierte Closeness Group Centrality der Knoten D und E:

$$GCC_{(D,E)} = 1 + 1 + 1 + \frac{1}{2} + \frac{1}{2} = 4 \tag{6.13}$$

Um diesen Wert zu normalisieren, wird der berechnete Wert in Gleichung 6.13 durch 5 dividiert, da es insgesamt 5 Knoten ausserhalb der Gruppe hat. Somit resultiert eine Closeness Group Centrality von $\frac{4}{5} = 0.8$.

6.3.3 Betweenness Group Centrality

Bei der *Betweenness Group Centrality* wird gemessen, welchen Anteil der kürzesten Wege zwischen allen Knoten, welche nicht zur untersuchenden Gruppe gehören, Knoten der Gruppe passieren.

Der Graph in Abbildung 6.15 wird als Beispielgraph verwendet.

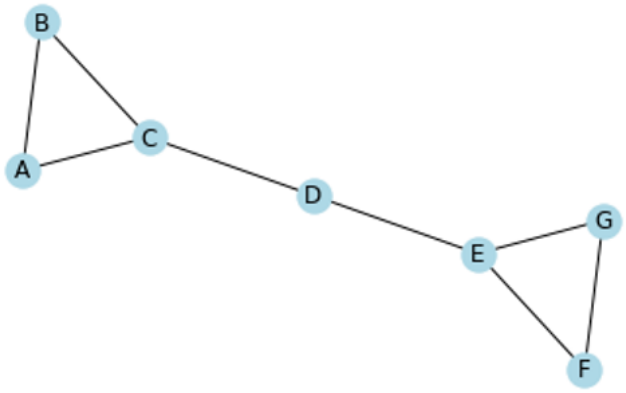


Abbildung 6.15: Beispielgraph zur Berechnung der Closeness Group Centrality

Es wird die Knotengruppe (C, E) untersucht. Somit müssen die kürzesten Pfade zwischen den Knoten A, B, D, F, G berücksichtigt werden. Es handelt sich um einen ungerichteten Graphen, weshalb nur eine Richtung zwischen zwei Knotenpaaren betrachtet werden muss (z.B. von A nach B, aber nicht mehr von B nach A).

Es existieren folgende Pfade für die kürzesten Verbindungen zwischen den Knoten A, B, D, F, G:

A -> B : Keine Knoten der Gruppe auf dem kürzesten Pfad

A -> C -> D : Knoten C gehört zur Gruppe

A -> C -> D -> E -> G : Knoten C und E gehören zur Gruppe

A -> C -> D -> E -> F : Knoten C und E gehören zur Gruppe

B -> C -> D : Knoten C gehört zur Gruppe

B -> C -> D -> E -> G : Knoten C und E gehören zur Gruppe

B -> C -> D -> E -> F : Knoten C und E gehören zur Gruppe

D -> E -> G : Knoten E gehört zur Gruppe

D -> E -> F : Knoten E gehört zur Gruppe

F -> G : Keine Knoten der Gruppe auf dem kürzesten Pfad

Von diesen 10 kürzesten Pfaden durchlaufen 8 Knoten der Gruppe und 2 nicht. Somit ergibt sich eine Betweenness Group Centrality von $\frac{8}{10} = 0.8$.

Kapitel 7

Netzwerk Zentralisierung

Die Aktor Zentralitäten aus Abschnitt 6.1 berechnen, wie zentral ein Aktor anhand lokaler Gegebenheiten oder seiner Position innerhalb des Netzwerks ist. Die Netzwerk-Zentralisierung kombiniert alle Aktor Zentralitäts-Werte zu einem einzelnen Wert, der aussagt, wie *gross die Ungleichheit* der Aktor Zentralitäts-Werte innerhalb des Netzwerkes sind. Der amerikanische Soziologe Linton Freeman[1] hat dazu eine allgemeine Zentralisierungs-Formel entwickelt ([Fre78]), welche die folgenden beiden Eigenschaften erfüllt:

- Es soll gezeigt werden, in welchem Masse der zentralste Aktor die Zentralität der anderen Akteure überschreitet
- Der berechnete Wert soll auf den maximal erreichbaren Wert (anhand der Netzwerkgrösse) bezogen sein.

Die allgemeine Formel von Freeman in (7.1) liefert einen Wert zwischen 0 und 1

0 bedeutet, dass alle Aktoren den gleichen Zentralitäts-Wert aufweisen. Dies ist bei einem Ring-Netzwerk (siehe Tabelle 7.1) der Fall.

1 bedeutet, dass der zentralste Aktor sich maximal von allen anderen unterscheidet. Dies ist bei einem Stern-Netzwerk (siehe Tabelle 7.1) der Fall.

Die Formel (7.1) zeigt die Formel von Freeman (aus [Fre78]), wie die Netzwerk-Zentralisierung berechnet wird:

$$Network\ Centralization = \frac{\sum_{i=1}^{n}[C_X(p*) - C_X(p_i)]}{max\sum_{i=1}^{n}[C_X(p*) - C_X(p_i)]} \tag{7.1}$$

Wobei die einzelnen Funktionen und Variablen folgende Bedeutung zugewiesen bekommen:

n Anzahl Aktoren

[1] Persönliche Webseite von Linton Freeman, `http://moreno.ss.uci.edu`, [31.07.2017]

$C_X(pi)$ Aktor-Zentralität für gegebenen Aktoren pi

$C_X(p*)$ Grösster im Netzwerk vorhandener Aktor Zentralitätswert, berechnet mit dem Zentralitätsmass Cx

$Nenner(max...)$ Theoretisch maximal mögliche Summe der Differenzen der Aktor-Zentralitäten für alle Aktoren in einem maximal zentralisierten Netzwerk mit der gleichen Anzahl Aktoren. Dies entspricht immer dem Stern-Netzwerk mit gleicher Knotenanzahl.

In Worte gefasst bedeutet die Formel:

Es wird im Zähler die Differenz zwischen dem höchsten Zentralitätswert zu allen Aktor-Zentralitätswerte aufsummiert. Der Nenner bekommt als Wert die Summe der theoretisch maximal möglichen Differenzen. So resultiert immer ein Wert zwischen 0 und 1.

Hinweis: Im Zähler führt die Differenz vom Knoten mit dem grössten Zentralitätswert zu sich selbst zum Summand 0. Deshalb kann dieser ignoriert werden.

Als Beispiele zur Veranschaulichung werden die zwei in der Tabelle 7.1 dargestellten Netzwerke verwendet, da beim *Stern-Netzwerk* der maximale Unterschied ersichtlich ist und beim *Ring-Netzwerk* alle Knoten gleich zentral sind:

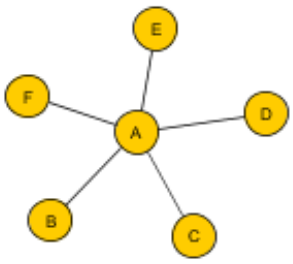
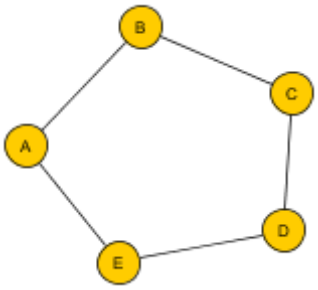
Stern-Netzwerk	Ring-Netzwerk
	

Tabelle 7.1: Gegenüberstellung von Stern- und Ringnetzwerk

In den folgenden Abschnitten wird für jedes der betrachteten Aktor-Zentralitätsmasse gezeigt, wie von den Aktor-Zentralitätsmassen das entsprechende Netzwerk-Zentralitätsmass berechnet werden kann. Die Formel in Gleichung 7.1 erfordert, dass für die Berechnung im Nenner (maximale Differenz) immer ein Stern-Netzwerk mit der gleichen Anzahl Knoten wie das zu analysierende Netzwerk erstellt wird. Dies ist aufwändig und auch nicht notwendig, da der Nenner für den allgemeinen Fall hergeleitet werden kann. Wie dies funktioniert, wird in den folgenden Unterabschnitten gezeigt.

7.1 Degree Zentralisierung

Die Degree Zentralisierung, ausgehend von den *nicht-normalisierten Degree Centrality Werten*, berechnet sich in einem *ungerichteten Graphen* mit der folgenden Formel:

$$C_D = \frac{\sum_{i=1}^{n}[C'_D(p*) - C'_D(p_i)]}{(n-1)(n-2)}$$

C'_D steht hier für den **nicht normalisierten Degree-Centrality Wert** des entsprechenden Aktors.

Der Nenner erklärt sich wie folgt: Das Stern-Netzwerk zeigt die höchstmögliche Ungleichheit. Dabei hat der zentrale Aktor (A im Stern-Netzwerk in der Tabelle 7.1) den Degree von $n-1$. Alle anderen haben lediglich den Degree 1. Daraus resultiert eine Differenz zwischen dem zentralsten Aktor und einem aussenstehenden von: $(n-1)-1 = n-2$. Diese Maximale Differenz befindet sich zwischen allen aussenstehenden Aktoren $(n-1)$ und dem zentralsten. Deshalb ist die maximal mögliche Differenz im Nenner $(n-1)(n-2)$.

Wird ein *gerichteter Graph* verwendet, muss der Nenner noch mit dem Faktor 2 multipliziert werden.

Beim Stern-Netzwerk hat der Knoten A den Degree von 5. Alle anderen Knoten (B-F) haben einen Degree von 1. Die Berechnung für die Degree Zentralisierung im Beispiel Stern-Netzwerk mit nicht normalisierten Werten funktioniert wie folgt (Gleichung 7.2)

$$C_D = \frac{(5-1)+(5-1)+(5-1)+(5-1)+(5-1)+(5-5)}{(6-1)(6-2)} = \frac{20}{20} = \underline{\underline{1}} \qquad (7.2)$$

Beim Kreis-Netzwerk hat jeder Knoten den Degree-Wert 2. Somit ergibt sich eine Degree-Zentralisierung für das Kreis-Netzwerk (Gleichung 7.3):

$$C_D = \frac{(2-2)+(2-2)+(2-2)+(2-2)+(2-2)}{(5-1)(5-2)} = \frac{0}{12} = \underline{\underline{0}} \qquad (7.3)$$

Sind bereits normalisierte Werte für die Degree-Centrality verfügbar, fällt im Nenner der Term (n-1) weg. Dann berechnet sich die Degree Zentralisierung nach Gleichung 7.4:

$$C_D = \frac{\sum_{i=1}^{n}[C'_D(p*) - C'_D(p_i)]}{(n-2)} \qquad (7.4)$$

7.2 Betweenness Zentralisierung

Für die Berechnung der Betweenness Zentralisierung wird die Gleichung 7.5 verwendet, welche von **bereits normalisierten Aktor-Zentralitäten** ausgeht:

$$C_B = \frac{\sum_{i=1}^{n}[C'_B(p*) - C'_B(p_i)]}{(n-1)} \qquad (7.5)$$

C'_B steht hier für den normalisierten Betweenness-Centrality-Wert des entsprechenden Aktors.

Das Sternnetzwerk zeigt wieder das maximal zentralisierte Netzwerk. Hier hat der mittlere Knoten einen normalisierten Betweenness Centrality Wert von 1, alle anderen einen Wert von 0. Zwischen einem aussenstehenden Knoten (z.B. B) und dem zentralsten

Knoten A ist die Differenz der Werte 1. Und diese Differenz kann maximal für alle aussenstehenden Knoten auftreten, also $n-1$ Mal. Somit ist der Nenner $1 \cdot (n-1)$.

Im Stern-Netzwerk hat der Knoten A einen normalisierten Betweenness-Centrality Wert von 1, alle anderen Knoten (B-F) haben den Betweenness-Centrality Wert von 0. In die Formel eingesetzt resultiert dies zur Formel in Gleichung 7.6

$$C_B = \frac{(1-0)+(1-0)+(1-0)+(1-0)+(1-0)+(1-1)}{(6-1)} = \frac{5}{5} = \underline{\underline{1}} \qquad (7.6)$$

Beim Kreis-Netzwerk hat jeder Knoten einen nicht-normalisierten Betweenness-Centrality-Wert von 1 und somit einen normalisierten Betweenness-Centrality Wert von 0.166. Der Netzwerk Betweenness Zentralisierungswert lautet also (Gleichung 7.7):

$$C_B = \frac{(0.16-0.16)+(0.16-0.16)+(0.16-0.16)+(0.16-0.16)+(0.16-0.16)}{(5-1)} = \frac{0}{4} = \underline{\underline{0}} \qquad (7.7)$$

7.3 Closeness Zentralisierung

Um die Formel für die Closeness Zentralisierung herzuleiten, muss ein wenig ausgeholt werden. Für die Berechnung der Aktor Closeness Centrality existieren verschiedene Formeln. Gleichung 7.8 zeigt eine häufig verwendete Formel in der Literatur:

$$C'_C(n_i) = \frac{n-1}{\sum_{j=i}^{n} d(n_i, n_j)} \qquad (7.8)$$

Der grosse Nachteil an dieser Formel ist, dass für Graphen mit verschiedenen Komponenten der Closeness Centrality Wert für alle Knoten 0 wird, da die Distanz zwischen zwei sich nicht erreichbaren Aktoren per Definition ∞ ist und somit der Nenner ebenfalls.

Leider referenzieren in der Literatur die meisten zur Berechnung der Closness Centrality die Gleichung 7.8. Deshalb wird nachfolgend die Berechnung der Closeness Zentralisierung mit unserer Formel aus dem Unterabschnitt 6.1.2 hergeleitet.

Der Graph mit der maximal möglichen Zentralisierung ist wieder das Stern-Netzwerk. Dabei ergibt sich für die Closeness Centrality der äusseren Aktoren (B - F) die allgemeine Formel:

$$C'_C(B) = \frac{\frac{1}{1} + (n-2)\cdot\frac{1}{2}}{n-1} = \frac{1+(n-2)\cdot\frac{1}{2}}{n-1} = \frac{1+\frac{n}{2}-1}{n-1} = \frac{\frac{n}{2}}{n-1} = \frac{n}{2(n-1)}$$

Der erste Summand im Zähler bezieht sich auf die direkte Verbindung von B zu A. Der zweite Summand berechnet die Distanz zu allen anderen aussenstehenden Knoten. Diese haben eine Pfadlänge von 2 und von einem aussenstehenden zu allen anderen aussenstehenden zu kommen muss dieser Weg $(n-2)$ Mal addiert werden. Das Ganze wird dann noch normalisiert, indem durch die *Anzahl Knoten* -1 geteilt wird.

Der zentralste Aktor A hat den Closeness-Wert 1, da er alle anderen Knoten direkt erreicht:

$$C'_C(A) = \frac{\frac{1}{1}(n-1)}{n-1} = 1$$

Nun muss die maximal mögliche Differenz zwischen dem zentralsten Knoten und einem aussenstehenden Knoten berechnet werden:

$$C'_C(A) - C'_C(B) = 1 - \frac{n}{2(n-1)} = \frac{2(n-1)-n}{2(n-1)} = \frac{2n-2-n}{2(n-1)} = \frac{n-2}{2(n-1)}$$

Diese maximal mögliche Differenz kann nun im kompletten Graphen genau $n-1$ Mal auftreten. Somit berechnet sich die maximale Differenz für alle Closeness Centrality Werte mit:

$$(n-1) \cdot \frac{(n-2)}{2(n-1)} = \frac{(n-1)\cdot(n-2)}{2(n-1)} = \frac{n-2}{2} \tag{7.9}$$

Für die Berechnung der Closeness Zentralisierung wird nun die maximal mögliche Differenz (berechnet in Gleichung 7.9) als Nenner eingetragen:

$$C_C = \frac{\sum_{i=1}^{n}[C'_C(p*) - C'_C(p_i)]}{\frac{n-2}{2}}$$

C'_C steht hier für den normalisierten Closeness Centrality Wert. Dieser wurde mit dem auf der Seite 63 beschriebenen Verfahren berechnet.

Für das Stern-Netzwerk ergeben sich folgende, normalisierte Closeness Centrality Aktor Werte:

$$C'_C(A) = \frac{5}{5} = \underline{1}$$

$$C'_C(B,C,D,E,F) = \frac{1 + 4 \cdot \frac{1}{2}}{5} = \frac{3}{5} = \underline{\underline{0.6}}$$

Nun werden die oben berechneten Closeness Centrality Werte in die Formel 7.1 eingefügt:

$$C_C = \frac{(1-0.6)+(1-0.6)+(1-0.6)+(1-0.6)+(1-0.6)+(1-1)}{\frac{6-2}{2}} = \frac{2}{\frac{4}{2}} = \frac{2}{2} = \underline{1}$$

Beim Kreis-Netzwerk hat jeder Aktor eine normalisierte Closeness Centrality von $\frac{3}{4} = 0.75$. Somit ergibt dies für das Kreis-Netzwerk eine Closeness Zentralisierung von:

$$C_C = \frac{(0.75-0.75)+(0.75-0.75)+(0.75-0.75)+(0.75-0.75)+(0.75-0.75)}{\frac{5-2}{2}}$$

$$= \frac{0}{1.5}$$

$$= \underline{0}$$

Kapitel 8

Netzwerk-Metriken

Die betrachteten Aktor Zentralitätsmasse sind Werte für einen bestimmten Knoten. Die einzelnen Werte sagen jedoch wenig bis nichts über die gesamte Netzwerkstruktur aus, sondern beziehen sich mehr auf die Position einzelner Aktoren innerhalb des Netzwerks. Bei den Netzwerk Zentralisierungen wurde verdeutlicht, wie gross die Unterschiede der Aktor Zentralitätswerte in einem Netzwerk sind. Die Netzwerk-Metriken liefern *Kennzahlen zur kompletten Netzwerkstruktur*, welche es auch ermöglichen, verschiedene Netzwerke miteinander zu vergleichen (resp. auch ein Netzwerk von einer Quelle zu unterschiedlichen Zeitpunkten) und diesbezügliche Schlussfolgerungen zu ziehen. Dabei steht der Aspekt der Kommunikation resp. des Zusammenhalts im Zentrum. Je indirekter die Kommunikation ist, desto grösser ist die Wahrscheinlichkeit und Gefahr für Manipulationen.

8.1 Graph Density

Die *Graph Density (Dichte)* beschreibt, wie komplett die Aktoren eines Graphen miteinander verbunden sind. Der Density-Wert liegt immer im Bereich zwischen 0 und 1. Der Density-Wert 0 steht für einen Graphen, in dem es gar keine Kanten gibt. Der Density-Wert 1 beschreibt einen Graphen, bei dem alle Knoten mit allen anderen Knoten verbunden sind. In der Graphentheorie wird dies auch als *Kompletter Graph* oder *Clique* bezeichnet.

Die Density für gerichtete Graphen berechnet sich mit der Gleichung 8.1, wobei $|E|$ für die Anzahl Kanten und $|V|$ für die Anzahl Knoten steht:

$$D_{Gerichtet} = \frac{|E|}{|V| \cdot (|V| - 1)} \tag{8.1}$$

In einem gerichteten Netzwerk gibt es $|V| \cdot (|V| - 1)$ mögliche Kanten (von jedem Knoten zu jedem anderen). Wenn die Anzahl vorhandener Kanten der Anzahl möglicher Kanten entspricht, dann resultiert daraus der Wert 1.

In einem ungerichteten Graphen gibt es zwischen einem Knotenpaar nur maximal eine Kante und nicht 2 wie bei gerichteten Graphen. Deshalb muss in ungerichteten Kanten die Anzahl der vorhandenen Kanten mit 2 multipliziert werden (oder der Nenner in der

Formel halbiert), wie in Gleichung 8.2 gezeigt:

$$D_{Ungerichtet} = \frac{2|E|}{|V|\cdot(|V|-1)} = \frac{|E|}{\frac{|V|\cdot(|V|-1)}{2}} \tag{8.2}$$

Interpretation

Die Dichte ist häufig ein Indikator, wie schnell sich Informationen in einem Netzwerk verbreiten. In einem dichten Netzwerk verläuft die Kommunikation sehr direkt. Mit steigender Anzahl der Knoten in einem grossen Netzwerk steigt auch die Anzahl der möglichen Kanten. Die Anzahl direkter Kontakte von Personen bleibt aber ungefähr konstant. Deshalb nimmt die Dichte mit der Grösse des Netzwerks ab. Dies ist auch ein Problem, wenn die Dichte verschiedener Netzwerke miteinander vergleichen werden.

Die Dichte gibt auch Auskunft über den *Zusammenhalt* eines Netzwerks, resp. einer Gruppe (Subnetzwerk), wenn nur ein Teil des Netzwerks untersucht wird.

8.2 Graph Diameter

Als Graph Diameter (Durchmesser) wird der *längste kürzeste Pfad* zwischen allen Knotenpaaren in einem Graphen bezeichnet. Falls es mehrere Components gibt, dann ist der Diameter laut Definition ∞.

Im der Abbildung 8.1 ist der Diameter d(1,6) = 2. Dies ist aber nur einer von vielen „längsten kürzesten Pfade“. Genauso gut könnte *d(2,3), d(2,7), d(1,5) usw.* als Referenz verwendet werden. Wichtig ist jedoch: Es gibt **keinen** längeren kürzesten Pfad!

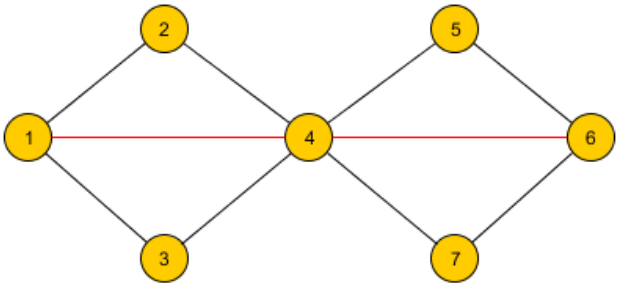


Abbildung 8.1: Netzwerk mit rot eingefärbtem Pfad für den Diameter

In der Abbildung 8.2 ist ein Graph abgebildet, dessen Diameter 4 ist.

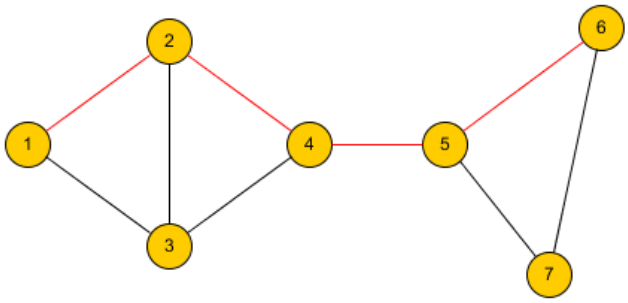


Abbildung 8.2: Netzwerk mit rot eingefärbten Pfad für den Diameter (einer von vier möglichen)

Die Berechnung des Durchmessers in gewichteten Graphen ist auf der Webseite von *GITTA, Geographic Information Technology Training Alliace)*[1] beschrieben.

Interpretation

Dieses Mass gibt Auskunft darüber, welches die grösste Entfernung zwischen zwei Knoten ist und somit auch, wie viele Kanten eine Nachricht innerhalb des Netzwerks auf den kürzesten Pfaden maximal passieren muss, um jeden Aktor zu erreichen.

Bei hohen Pfadlängen ist die Wahrscheinlichkeit grösser, dass die Nachricht unterwegs manipuliert wird. Auch die Dauer, bis sich etwas im kompletten Netzwerk verbreitet, ist länger. Deshalb sind kleinere Pfadlängen zu bevorzugen. Ein Vorteil von mehreren unterschiedlichen Pfaden zwischen zwei Knoten ist, dass Nachrichten mehrmals ankommen und Manipulationen so aufgedeckt werden können.

8.3 Cluster Coefficient

Der Cluster Coefficient ist ein *Mass für Cliquenbildung* in einem Graphen. Ein Wert von 1 bedeutet dabei, dass es sich um eine Clique handelt. Es wird zwischen dem *lokalen* und dem *globalen* Cluster Coefficient unterschieden, wobei es sich beim globalen Wert lediglich um den Mittelwert der lokalen Werte handelt.[2]

Der lokale Cluster Coefficient berechnet sich aus dem Quotienten der Anzahl direkten Kanten zwischen den Nachbarn eines Knoten (bei ungerichteten Netzwerken multipliziert mit dem Faktor 2) und der maximal möglichen Anzahl direkter Kanten.

Für ungerichtete Graphen wird der lokale Clustering Coefficient C_i für einen Knoten nach der Formel 8.3 berechnet:

$$C_i = \frac{2 \cdot d}{k_i(k_i - 1)} \tag{8.3}$$

[1] GITTA - Berechnung des Duchmessers bei gewichteten Graphen, `http://www.gitta.info/Accessibiliti/de/html/StructPropNetw_learningObject2.html`, 03.08.2017]

[2] In der Literatur existieren verschiedene Definitionen des *globalen Cluster Coeffizienten*.

Wobei d für die tatsächliche Anzahl direkter Kanten zwischen den benachbarten Knoten steht und k_i für die Anzahl benachbarter Knoten. Bei einem gerichteten Graphen entfällt der Faktor 2 bei den tatsächlichen Kanten.

Die Gleichung 8.4 zeigt, wie der globale Clustering Coefficient berechnet wird:

$$CC = \frac{1}{N} \sum_{i=1}^{N} C_i \tag{8.4}$$

Nehmen wir den Beispielgraphen in Abbildung 8.3:

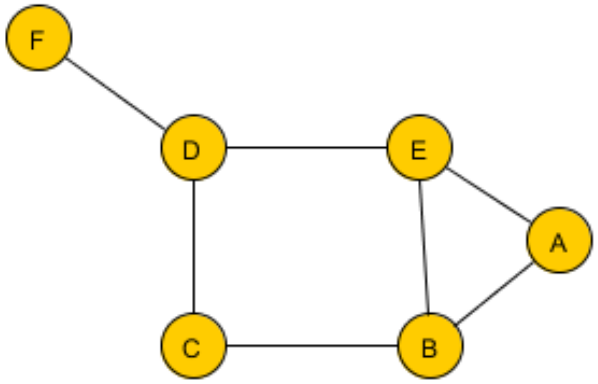


Abbildung 8.3: Beispielgraph zur Berechnung der Cluster Coeffizienten (lokal & global)

Der Knoten A besitzt zwei Nachbarn, B und E. Zwischen diesen existiert eine direkte Kante. Dies führt zum Cluster Coefficient für A:

$$C_A = \frac{2 \cdot 1}{2 \cdot 1} = 1$$

Die Berechnung des lokalen Cluster Coeffizienten für die weiteren Knoten:

$$C_B = \frac{2 \cdot 1}{3 \cdot 2} = \underline{\underline{\frac{1}{3}}}$$

$$C_C = \frac{0}{2 \cdot 1} = \underline{\underline{0}}$$

$$C_D = \frac{0}{3 \cdot 2} = \underline{\underline{0}}$$

$$C_E = \frac{2 \cdot 1}{3 \cdot 2} = \underline{\underline{\frac{1}{3}}}$$

$$C_F = \frac{0}{1 \cdot 0} = \underline{\underline{0}}$$

Für den globalen Clustering Coeffizienten CC ergibt sich dann der folgende Wert:

$$CC = \frac{1}{6} \cdot \frac{5}{3} = \underline{\underline{\frac{5}{18}}}$$

Hinweis: In einem gerichteten Graphen gelten alle Knoten als Nachbarn eines Knoten, falls zwischen den beiden Knoten eine Kante liegt (unabhängig von der Kantenrichtung).

Interpretation

Akteure mit einem hohen Clustering Coeffitienten sind stark lokal vernetzt und haben möglicherweise aufgrund längerer oder intensiverer Kontakte geschlossene Triaden gebildet (Der Freund meines Freundes ist mein Freund). Stark vernetzte Gruppen haben häufig gemeinsame Interessen und Wertvorstellungen.

8.4 Balance

Der Begriff *Balance* für eine Triade wurde im Abschnitt 1.3 beschrieben. Voraussetzung dafür ist ein Signed-Netzwerk. Dann werden alle Triaden (Dreiecksbeziehungen) betrachtet. Sind alle drei Kanten positiv oder nur eine der drei positiv, dann ist die Dreiecksbeziehung *balanciert*. Ansonsten ist sie *nicht balanciert*.

Der Balance-Wert kann auch als Netzwerk-Metrik berechnet werden, indem die Anzahl balancierten Triaden durch die Anzahl total vorhandener Triaden gerechnet wird (siehe Gleichung 8.5). Dabei entsteht ein Wert zwischen 0 und 1, wobei 0 für ein komplett unbalanciertes und 1 für komplett blanciertes Netzwerk steht.

$$NetzwerkBalance = \frac{\#\ Balanced\ Triaden}{\#\ Triaden\ total} \tag{8.5}$$

Als Beispiel dient der Graph in Abbildung 8.4. Die Triaden wurden farblich markiert, wobei blau die balancierten und rot die unbalancierten Triaden darstellen. Graue Kanten kommen sowohl in positiven und negativen Triaden vor.

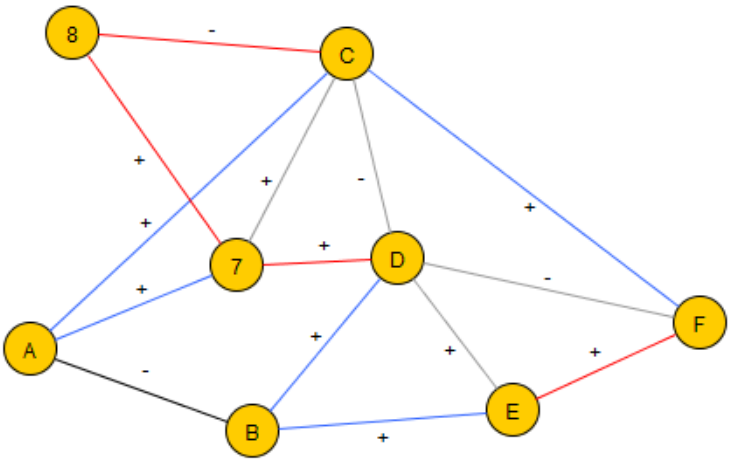


Abbildung 8.4: Beispielgraph zur Berechnung der Netzwerk-Balance

Die Netzwerk-Balance berechnet sich dann wie folgt:

$$NetzwerkBalance = \frac{\#\ Balanced\ Triaden}{\#\ Triaden\ total} = \frac{3}{6} = \underline{\underline{0.5}}$$

Interpretation

Die Balance ist ein Mass, wie stark ein Netzwerk harmonisiert. Umso näher der Wert bei 1 ist, desto besser harmonisiert es.

Kapitel 9

Graph Connectivity

Bei der Graph Connectivity (auch Graph Resilience genannt), wird untersucht, wie viele Elemente (Knoten oder Kanten) entfernt werden müssen, damit der Graph nicht mehr verbunden ist. Damit kann untersucht werden, wie anfällig ein Netzwerk auf Ausfälle von Knoten oder Kanten ist (z.B. Kommunikations-Netzwerk oder Transport-Netzwerk). Um eine Aussage über die Verbundenheit eines Graphes zu machen, gibt es verschiedene Gesichtspunkte, welche untersucht werden können.

Bridge: Von einer Bridge wird gesprochen, wenn das Löschen einer Kante die Anzahl der Connected Components (siehe Abschnitt 5.1) im Netzwerk vergrössern würde. Abbildung 9.1 zeigt eine Bridge-Kante:

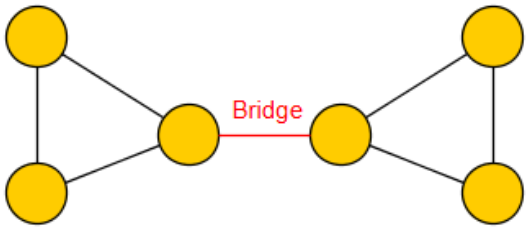


Abbildung 9.1: Netzwerk mit rot eingefärbter Bridge

Dasselbe Prinzip der Bridge lässt sich auch auf Knoten anwenden.

Cut-Vertex: Erhöhen sich die Anzahl Connected Components beim Löschen eines bestimmten Knotens, wird dieser Cut-Vertex genannt. Im Abbildung 9.2 sind die Cut-Vertices rot eingefärbt:

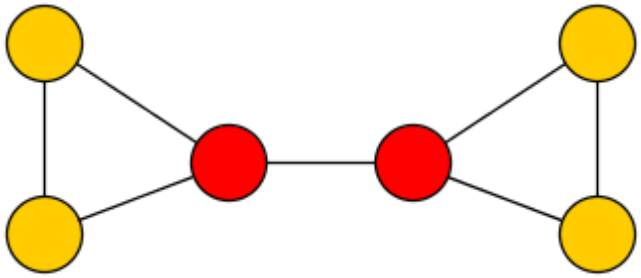


Abbildung 9.2: Netzwerk mit rot eingefärbten Cut-Vertices

Es ist unschwer zu erkennen, dass Aktoren an der rot eingefärbten Position eine sehr einflussreiche Position innerhalb des Netzwerks aufweisen. Sie können die Kommunikation verweigern oder gar manipulieren, ohne dass dies von der gegenüberliegenden Seite erkannt wird. Dieser Knoten wird auch als *Broker* (Vermittler) bezeichnet.

Die bisher betrachteten Metriken für die Connectivity eines Graphen können auch noch für mehrere Knoten oder Kanten verallgemeinert werden.

Ein Graph ist *k-Connected*, wenn dieser mindestens *k+1* Knoten umfasst und mindestens *k* Knoten entfernt werden müssen, damit der Graph unverbunden wird (Node Connectivity). Der Graph in Abbildung 9.3 ist 2-connected, da er nach wie vor verbunden bleibt, wenn nur ein Knoten entfernt wird. Er hat somit keinen Cut-Vertex. Falls beispielsweise die Knoten B und D entfernt werden, dann bildet der Knoten A einen eigenständigen Connected Component.

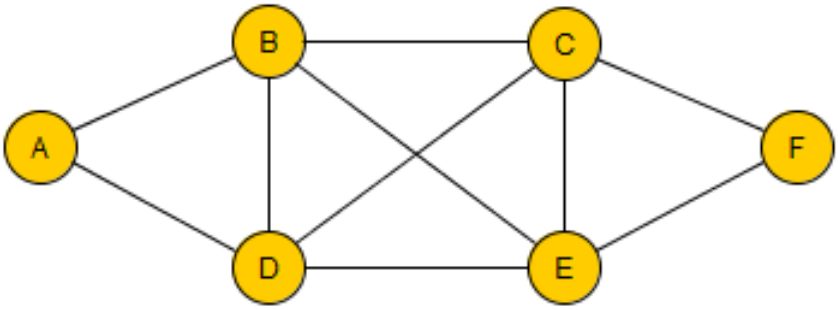


Abbildung 9.3: 2-connected Graph

Nach dem gleichen Prinzip wie *k-connected* für Knoten kann gemessen werden, wie viele Kanten mindestens entfernt werden müssen, damit der Graph nicht mehr verbunden ist (Edge Connectivity). In Abbildung 9.4 ist ein Beispiel eines Graphen, der eine Edge-Connectivity von 3 besitzt. Dies bedeutet, dass beliebige zwei Kanten entfernt werden können, ohne dass sich daraus zwei Connected Components ergeben.

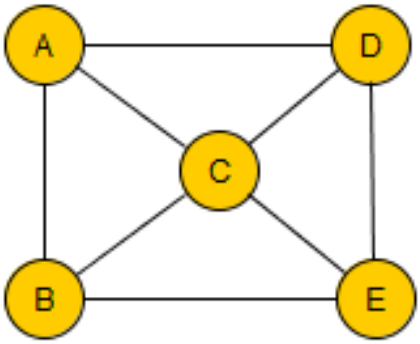


Abbildung 9.4: 3-connected Graph, welcher auch eine Edge Connectivity von 3 besitzt.

Kapitel 10

Korrelation in Netzwerken

In diesem Kapitel werden zuerst zwei Formen der Korrelation genauer betrachtet. Die Pearson Korrelation, welche die Stärke des linearen Zusammenhangs misst und die Rangkorrelation mit welcher untersucht wird, ob zwei Variablen einen statistischen Zusammenhang aufweisen, der jedoch nicht linear ist. Im Anschluss wird die Assortativität, die auf der Pearson Korrelation basiert, noch genauer beleuchtet. Die Assortativität untersucht, wie stark das Netzwerk dazu tendiert, dass sich ähnliche Knoten verbinden.

Eine Korrelation misst *die Stärke des Zusammenhangs zweier Variablen* und beziffert diesen mit Wert zwischen -1 und 1. In diesem Kapitel werden die Grundlagen zu zwei Korrelationsverfahren (Pearson und Spearman) genauer betrachtet. Zusätzlich wird der Begriff *Signifikanz* eingeführt und ein Verfahren vermittelt, wie gezeigt werden kann, dass eine gefundene Korrelation signifikant (= „nicht zufällig“) ist.

Eine Korrelation beschreibt, wie stark der Zusammenhang zwischen zwei nummerischen Variablen ist. In der Abbildung 10.1 ist von allen Studierenden der SAT-Score (Resultats eines US Tests, welcher die „Studierfähigkeit“ prüft) und dem GPA (Notendurchschnitt) ersichtlich[1]:

Student	SAT Score	GPA
1	595	3.4
2	520	3.2
3	715	3.9
4	405	2.3
5	680	3.9
6	490	2.5
7	565	3.5

Abbildung 10.1: Liste mit Studenten: Angabe des SAT-Scores und des GPAs.

Diese Werte wurden in Abbildung 10.2 in einem Scatterplot visualisiert:

[1] Aus dem Statistik-Script von CK-12, `http://manuelmath.wiki.conestogavalley.org/file/view/CK-12+Advanced+Probability+and+Statistics+Concepts.pdf`, [03.08.2017]

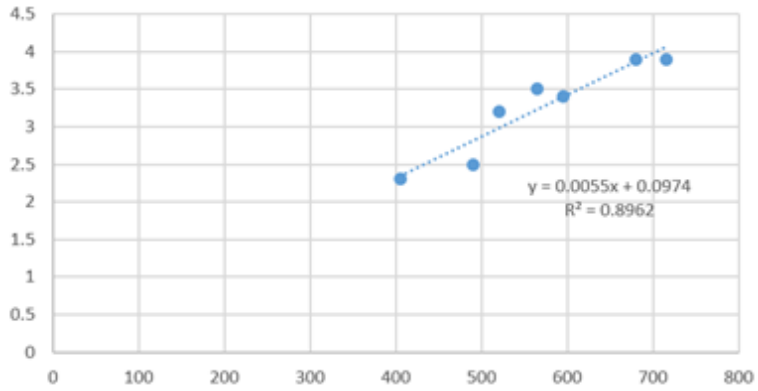


Abbildung 10.2: Scatterplot mit bivariaten Daten und der Regressionslinie

In der Abbildung 10.2 ist der Zusammenhang zwischen den beiden Variablen schon rein visuell ersichtlich. Umso höher der SAT-Score (X-Achsenwert) ist, desto höher ist auch der GPA-Score (Y-Achse). Es wird in diesem Fall von einer positiven Korrelation gesprochen. Es gibt auch negative Korrelationen, wenn der Zuwachs der einen Variable mit der Abnahme der anderen Variable zusammenhängt. Zum Beispiel der Zusammenhang zwischen „Gefahrenen Kilometern mit dem Auto“ und der „Menge von Benzin“. Zusätzlich ermöglicht die Visualisierung bereits sehr gut das Ausmass der Korrelation abschätzen. Befinden sich alle Punkte genau auf einer Linie, dann wird von einer perfekten (linearen) Korrelation gesprochen. Die Abbildung 10.3 zeigt verschiedene Richtungen der Korrelation:

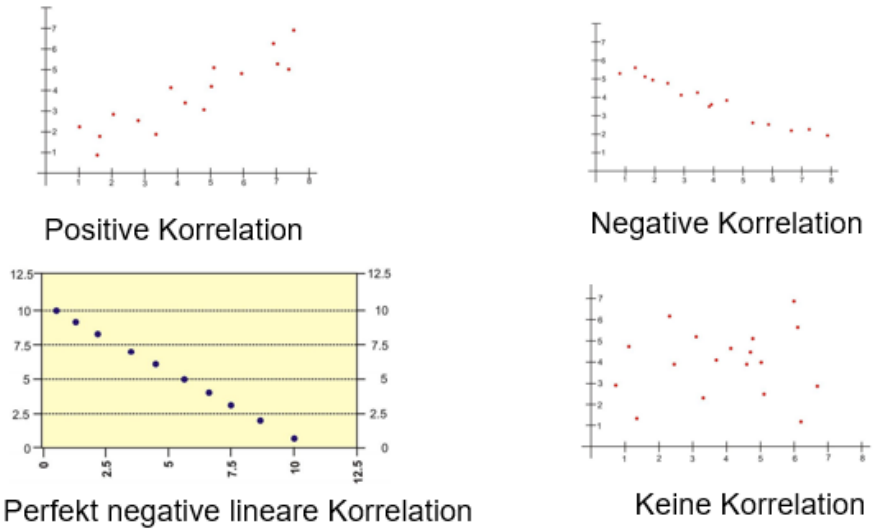


Abbildung 10.3: Richtungen der Korrelation

10.1 Korrelationskoeffizient

Der Korrelationskoeffizient r misst *die Stärke des Zusammenhangs zwischen zwei Variablen*. Dieser ist immer im Bereich $[-1, 1]$, wobei -1 für eine perfekt negative Korrelation und 1 für eine perfekt positive Korrelation steht. Bei 0 ist keine Korrelation erkennbar. Der Korrelationskoeffizient gibt jedoch **keine** Auskunft über Ursache und Wirkung. Ein Beispiel: Es besteht ein Zusammenhang zwischen der Niederschlags- und der Verdunstungsmenge. Es kann jedoch anhand des Korrelationskoeffizienten nicht gesagt werden, ob die Niederschläge aufgrund der höheren Verdunstung ansteigt oder die Verdunstung, weil die Niederschläge mehr Wasser liefern. Möglich wäre auch, dass eine gegenseitige Beeinflussung stattfindet.

Der Korrelationskoeffizient r kann wie folgt interpretiert werden:

- Das Vorzeichen gibt an, ob es sich um eine *positive* oder *negative* Korrelation handelt.
- Der Betrag $|r|$ gibt Auskunft über die Stärke der Korrelation. Hier eine grobe Richtlinie zur Interpretation von $|r|$ (kann nach Quelle und Anwendungsfall jedoch variieren):

  $|r| < 0.1$**:** Keine Korrelation

  $0.1 \leq |r| < 0.5$**:** Schwache Korrelation

  $0.5 \leq |r| < 0.8$**:** Moderate Korrelation

  $|r| \geq 0.8$**:** Starke Korrelation

10.2 Übliche Fehler im Zusammenhang mit Korrelation

Folgende Fehler und Fehlschlüsse werden häufig im Zusammenhang mit Korrelation gemacht:

Kausalzusammenhang : Ein sehr weit verbreiteter Fehler ist, dass aufgrund einer Korrelation auch automatisch auf einen Kausalzusammenhang geschlossen wird. Das ist nicht so! Eine Korrelation ist *kein* Indiz für einen Kausalzusammenhang. Wenn wir beispielsweise eine Korrelation zwischen „Investierte Zeit für Prüfungsvorbereitung“ und „Note“ erkennen, bedeutet das nicht, dass viel lernen automatisch zu einer guten Note führt (und dass eine gute Note automatisch viel Vorbereitungszeit erfordert hat).

Ausreisser: Werte, die sehr stark aus dem generellen Muster fallen, werden als Ausreisser bezeichnet. Vorhandene Ausreisser können den Korrelationswert stark beeinflussen. Deshalb sollten die Daten immer vorgängig visualisiert werden. Bei Ausreissern muss dann untersucht werden, ob es sich um einen korrekten Wert handelt und ob dieser schlussendlich berücksichtigt werden sollte. (Vor allem bei Regressionen kann es sinnvoll sein, diese Ausreisser zu entfernen).

Homogenität: Wenn nur eine sehr homogene Gruppe getestet wird, kann es sein, dass keine oder eine nur sehr schwache Korrelation erkannt wird. Deshalb sollte darauf geachtet werden, dass Messwerte aus der Grundgesamtheit entnommen

werden, denn nur so können auch verlässliche Rückschlüsse auf die Grundgesamtheit gemacht werden. Zum Beispiel: Falls eine Korrelation zwischen Einkommen und IQ berechnet wird, jedoch nur Personen aus dem Mensaclub (2% der Bevölkerung mit höchstem IQ) befragt werden, dann ist vermutlich keine oder nur eine schwache Korrelation zwischen IQ und Einkommen ersichtlich. Werden als Grundgesamtheit beliebige Personen ausgewählt, dann wird die Korrelation zwischen Einkommen und IQ stärker sein.

10.3 Korrelationsmasse

Es gibt verschiedene Masse für die Korrelation. In den nachfolgenden Unterabschnitten werden zwei Korrelationsmasse genauer betrachtet. Einerseits der *Pearson Korrelationskoeffzient*, welcher den linearen Zusammenhang zweier Variablen misst und anderseits die *Spearman Korrelation*, welche die Rangkorrelation misst.

10.3.1 Pearson Korrelationskoeffizient

Der Pearson Korrelationskoeffizient misst den **linearen** (stetig gleichbleibende Veränderung pro Intervall) Zusammenhang zwischen zwei Variablen. Der Pearson Korrelationskoeffizient liefert nur korrekte Werte, wenn die folgenden Bedingungen erfüllt sind:

Linearität: Der Zusammenhang der beiden Variablen muss linear sein. Wird dies ignoriert resultieren sehr niedrige Korrelationswerte, obwohl der Zusammenhang hoch ist (nur halt nicht linear).

Der Pearson Korrelationskoeffizient berechnet sich mit der Formel in 10.1:

$$r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}} \tag{10.1}$$

Auch wenn die Formel auf den ersten Moment sehr kompliziert wirkt, soll mit einem Beispiel gezeigt werden, dass sich die Komplexität in Grenzen hält. Dazu wird wieder das Beispiel mit den Studenten verwendet, wo nun der lineare Zusammenhang zwischen dem SAT- und GPA-Score untersucht werden soll. Die ursprüngliche Tabelle wurde um drei Spalten mit Produkten und eine Zeile mit Summen am Ende erweitert (siehe Tabelle 10.1). Danach sind bereits alle Elemente für die Formel 10.1 vorhanden.

SAT Sc.(X)	GPA(Y)	X - Avg(X)	Y - Avg(Y)	(X-Avg(X))(Y-Avg(Y))
595	3.4	595 - 567.14 = 27.86	3.4 - 3.24 = 0.16	27.86 · 0.16 = 4.458
520	3.2	520 - 567.14 = -47.14	3.2 - 3.24 = -0.04	-47.14 · -0.04 = 1.886
715	3.9	715 - 567.14 = 147.86	3.9 - 3.24 = 0.66	147.86 · 0.66 = 97.5878
405	2.3	405 - 567.14 = -162.14	2.3 - 3.24 = -0.94	-162.14 · -0.94 = 152.412
680	3.9	680 - 567.14 = 112.86	3.9 - 3.24 = 0.66	112.86 · 0.66 = 74.488
490	2.5	490 - 567.14 = -77.14	2.5 - 3.24 = -0.74	-77.14 · -0.74 = 57.084
565	3.5	565 - 567.14 = -2.14	3.5 - 3.24 = 0.26	-2.14 · 0.26 = -0.556
Avg: 567.14	**Avg: 3.24**	**SumSq: 69'842.86**	**SumSq: 2.397**	**Sum: 387.36**

Tabelle 10.1: Erweiterte Tabelle von 7 Studierenden mit SAT Score und GPA sowie zusätzlichen Berechnungen in der 8. Zeile resp. den drei zusätzlichen Spalten zur Berechnung der Pearson Korrelation. *SumSq* bedeutet die Summe aller Quadrate in der entsprechenden Spalte (Sum of Squares).

Nun werden die Zahlen in die Pearson Korrelationskoeffizient Formel 10.1 eingetragen. Das n entspricht der Anzahl Wertepaaren.

$$
\begin{aligned}
r_{xy} &= \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}} \\
&= r_{xy} = \frac{387.36}{\sqrt{69842.86 \cdot 2.397}} \\
&= r_{xy} = \frac{387.36}{\sqrt{167413.34}} \\
&= r_{xy} = \frac{387.36}{409.16} \\
&= r_{xy} = 0.9467
\end{aligned}
$$

Bestimmtheitsmass

Das Bestimmtheitsmass r^2 gibt an, wie viel Prozent der Varianz der einen Variable durch die Varianz der anderen Variable aufgrund des statistischen linearen Zusammenhangs erklärt werden kann.

Ein Beispiel: Der Zusammenhang zwischen Gewicht und Menge des Fressens bei einem Hund hat beispielsweise einen Korrelationskoeffizienten von $r = 0.73$. Somit ist $r^2 = (0.73)^2 = 0.53$. Dies bedeutet, dass 53% des Anstiegs bei der Fressmenge auf die lineare Beziehung zwischen Fressmenge und Gewicht zurückgeführt werden kann. Die restlichen 47 % haben andere Ursachen (Alter, Grösse usw.)

10.3.2 Spearman Korrelation

Die Spearman Korrelation misst, ob der *Zusammenhang zwischen zwei Variablen einer monoton steigenden Funktion entspricht.* Dies bedeutet, dass $f(x)$ immer dann wächst,

wenn x erhöht wird. Ein Beispiel dafür sind die Fibonacci-Zahlen (aufgezeigt ab n=2 in Tabelle 10.4):

n	**f(n)**		**n**	**f(n)**
2	1		7	13
3	2		8	21
4	3		9	34
5	5		10	55

Tabelle 10.2: Fibonacci-Werte

Werden die Fibonacci-Zahlen bis zu $n = 15$ visualisiert, ergibt sich die Kurve in Abbildung 10.4

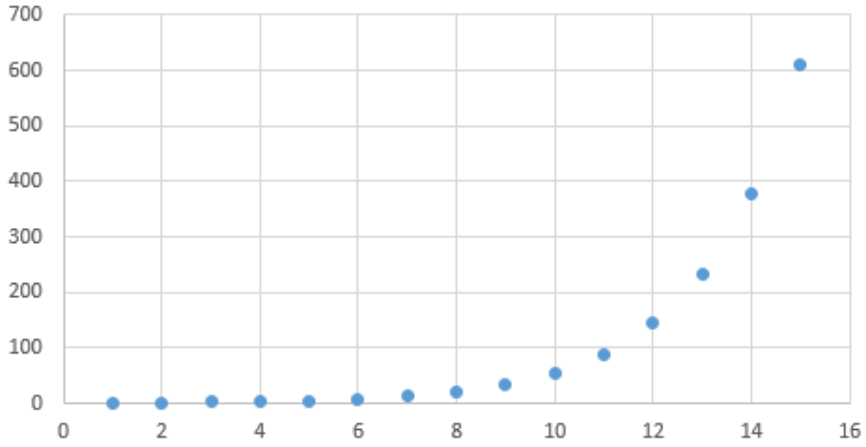


Abbildung 10.4: Scatterplot der Fibonacci-Zahlen bis 15

Der berechnete Pearson Korrelationskoeffizient dieser 15 Fibonacci-Zahlen ist 0.78. Der Spearman Korrelationskoeffizient jedoch 1.

Die Formel 10.2 zeigt die Berechnung des Spearman Korrelationskoeffizienten:

$$r_{X,Y} = 1 - \frac{6 \cdot \sum_{i=1}^{n} (R_X(x_i) - R_Y(y_i))^2}{n(n^2 - 1)} \tag{10.2}$$

wobei R_X und R_Y für die Ränge innerhalb von X, resp. Y stehen. Zur Veranschaulichung wird die Fibonacci-Tabelle von oben in Tabelle 10.3 erweitert. X entspricht dem n und Y dem Fibonacci-Wert von n. Nun wird eine zusätzliche Spalte $R(Y)$ angelegt, die den Rang des entsprechenden Fibonacci-Wertes innerhalb der Fibonacci-Werte abbildet. Auf die Spalte $R(X)$ wird hier verzichtet, da die Rangfolge auch so sehr gut erkennbar ist und gerade dem $n - 1$ entspricht.

n (=X)	**f(n) (=Y)**	R_Y		**n (=X)**	**f(n) (=Y)**	R_Y
2	1	1		6	8	5
3	2	2		7	13	6
4	3	3		8	21	7
5	5	4		9	34	8

Tabelle 10.3: Fibonacci-Zahlen ergänzt um Ranginformationen

Werden nun die Werte dieser Tabelle in die Formel eingetragen, dann wird $r = 1$. Der Teil der Summe $(R_X(x_i) - R_Y(y_i))^2$ ist immer null, weil X und Y jeweils den gleichen Rang haben. Somit wird der Zähler 0 und daraus resultiert schlussendlich $r = 1 - 0 = \underline{\underline{1}}$.

Hinweis: Die oben angegebene Formel funktioniert **nur**, wenn alle x_i und y_i untereinander verschieden sind, sprich, jeder Rang nur genau einmal vorkommt (Deshalb wurde n=1 nicht ins Beispiel aufgenommen). Ansonsten wird die Formel ein wenig komplizierter. Hier wird darauf verzichtet, die komplizierte Formel zusätzlich zu erwähnen. Interessierte können gerne die Formel in Wikipedia[2] nachschlagen.

10.4 Assortativität

Die *Assortativität* misst, wie stark die Tendenz besteht, dass sich eher *ähnliche* Knoten als *unähnliche* Knoten verbinden. Es kann damit beispielsweise untersucht werden, wie stark Homophilie im Netzwerk auftritt oder ob das Gegenteil (Heterophilie) der Fall ist. Der Effekt der Homophilie tritt sehr häufig in sozialen Netzwerken auf, wo sich Leute aufgrund von Gemeinsamkeiten (gemeinsame Hobbies, gemeinsamer Arbeitsort, gemeinsame Schulzeit, ...) miteinander verbinden.

Bei der Berechnung der Assortativität resultiert immer einen Wert im Bereich zwischen -1 und 1. Positive Werte bedeuten, dass eine Assortativität besteht und negative Werte, dass eine Disassortativität besteht. Der Betrag des Wertes gibt an, wie stark die (Dis)Assortativität ist.

Die Ähnlichkeit von Knoten kann unterschiedlich definiert werden. Die bekannteste Assortativitäts-Metrik ist die *Degree Assortativität*. Dabei wird mit der Assortativität untersucht, ob Knoten, welche einen hohen Degree aufweisen, eher mit anderen Knoten verbunden sind, die ebenfalls einen hohen Degree haben. Ist das Gegenteil der Fall (Knoten mit hohen Degree-Werten sind vor allem mit Knoten mit tiefen Degree-Werten verbunden), wird von *Disassortativität* gesprochen. Wie in den nachfolgenden Unterabschnitten zu sehen ist, können aber beliebige nummerische oder kategorische Knoten-Attribute zur Berechnung der Assortativität hinzugezogen werden.

Bei der Untersuchung der Assortativität und der Interpretation des Wertes ist vor Augen zu führen, dass es sich um einen globalen Wert handelt. Ein globaler Wert sagt nicht zwingend etwas über die feingranulare Struktur aus. Deshalb macht es Sinn, dies noch genauer zu untersuchen. In der Abbildung 10.5 aus der Publikation *Multiscale mixing patterns in networks* [PDL18] wurde sehr schön dargelegt, dass verschiedene Netzwerkstrukturen mit der gleichen Anzahl Knoten und Kanten zum selben globalen Assorativitäts-Wert führen, jedoch sehr unterschiedliche lokale Strukturen aufweisen.

[2] Quelle: `https://de.wikipedia.org/wiki/Rangkorrelationskoeffizient`

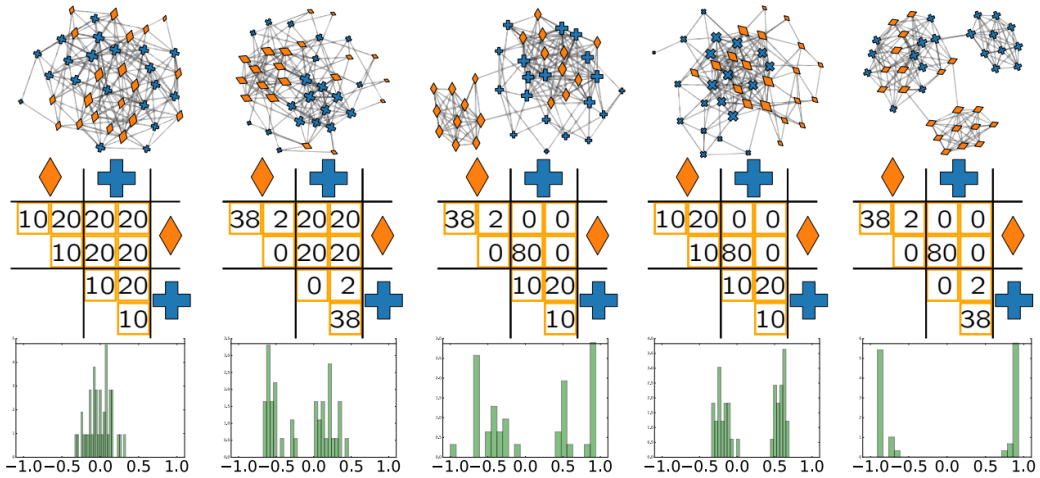


Abbildung 10.5: Fünf verschiedene Netzwerke mit jeweils 40 Knoten und 160 Kanten, die alle denselben globalen Assortativitäts-Wert von 0 aufweisen, jedoch sehr unterschiedliche lokale Muster zeigen. Die Verteilung unten zeigt, wie die lokalen Assortativitäts-Werte verteilt sind.

10.4.1 Messen von Assortativität auf nummerischen Knoten-Attribute

Zur Berechnung der Assortativität auf nummerischen Knoten-Attributen wird die Pearson Korrelation aus dem Unterabschnitt 10.3.1 verwendet.

Beim nachfolgenden Beispiel handelt sich dabei um ein ungerichtetes Netzwerk mit 5 Knoten und 6 Kanten.

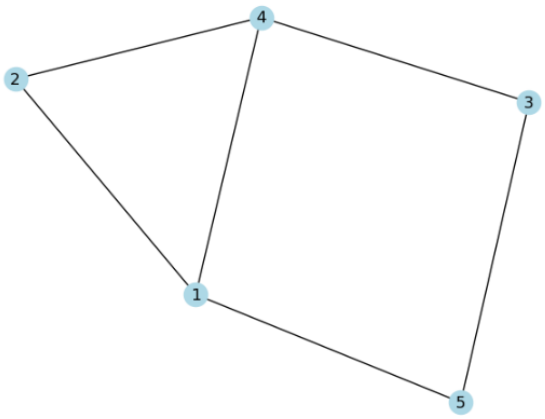


Abbildung 10.6: Beispiel-Netzwerk zur Erklärung der nummerischen Assortativität

In diesem Beispiel wird die Degree-Assortativität analysiert. Es können aber **beliebige nummerische Werte der Knoten** verwendet und somit auf Assortativität untersucht werden. In der nachfolgenden Tabelle werden alle Kanten und ein paar für die Berechnung notwendigen Werte abgebildet. Weil das Netzwerk ungerichtet ist, werden jeweils beide Kantenrichtungen berücksichtigt. Jede Kante im Netzwerk führt somit zu zwei

Zeilen in der Tabelle, jeweils mit beiden Kombinationen von X und Y. Bei gerichteten Graphen ist jede Kante nur einmal in der Tabelle abgebildet.

Edges (X-Y)	**Degree(X)**	**Degree(Y)**	**X-Avg(X)**	**Y-Avg(Y)**	**(X-Avg(X))(Y-Avg(Y))**
$1 \leftrightarrow 2$	3	2	0.5	-0.5	-0.25
$2 \leftrightarrow 1$	2	3	-0.5	0.5	-0.25
$1 \leftrightarrow 4$	3	3	0.5	0.5	0.25
$4 \leftrightarrow 1$	3	3	0.5	0.5	0.25
$1 \leftrightarrow 5$	3	2	0.5	-0.5	-0.25
$5 \leftrightarrow 1$	2	3	-0.5	0.5	-0.25
$2 \leftrightarrow 4$	2	3	-0.5	0.5	-0.25
$4 \leftrightarrow 2$	3	2	0.5	-0.5	-0.25
$3 \leftrightarrow 4$	2	3	-0.5	0.5	-0.25
$4 \leftrightarrow 3$	3	2	0.5	-0.5	-0.25
$3 \leftrightarrow 5$	2	2	-0.5	-0.5	0.25
$5 \leftrightarrow 3$	2	2	-0.5	-0.5	0.25
	Avg: 2.5	**Avg: 2.5**	**SumSq: 3**	**SumSq: 3**	**Sum: -1**

Tabelle 10.4: Tabelle zur Berechnung der Assortativität im Beispiel-Netzwerk

Nun werden diese Werte in die Formel zur Berechnung der Pearson Korrelation aus Gleichung 10.1 eingesetzt, wobei das n nun den Anzahl Kanten entspricht:

$$
\begin{aligned}
r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}} \\
= r_{xy} = \frac{-1}{\sqrt{3 \cdot 3}} \\
= r_{xy} = \frac{-1}{3} \\
= r_{xy} = -0.333
\end{aligned}
$$

Da der Wert deutlich negativ ist, weist das gegebene Netzwerk Disassortativität bezüglich den Degrees auf. Es besteht also eine Tendenz, dass ich gut verbundene Knoten mit weniger gut verbundenen Knoten verbinden und umgekehrt.

10.4.2 Messen von Assortativität auf kategorischen Knoten-Attribute

Die Assortativität auf kategorischen Knoten-Attributen sagt aus, in welchem Ausmass Knoten mit dem **gleichen Attribut** miteinander verbunden sind oder nicht. Zur Veranschaulichung wird das selbe Beispiel-Netzwerk von oben verwendet und zusätzlich um das kategorische Knoten-Attribut *Gender* ergänzt. Das Netzwerk sieht nun wie folgt aus:

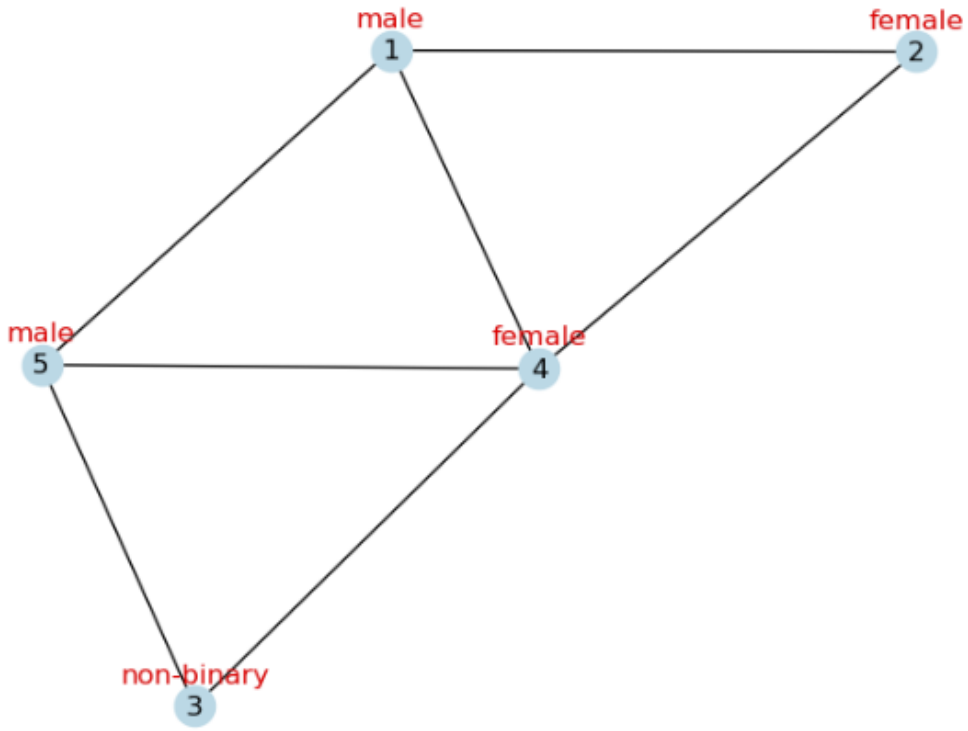


Abbildung 10.7: Beispiel-Netzwerk zur Erklärung der kategorischen Assortativität

Zur Berechnung der Assortativität wird zuerst die sogenannte *Mixing Matrix* erstellt. Diese bildet für alle Kategorien ab, wie viele Kanten zwischen Knoten mit dem jeweiligen Attribut existieren. In der nachfolgenden Tabelle ist ersichtlich, zwischen welchen Geschlechtern wie viele Kanten im Netzwerk erscheinen. Es handelt sich um die sogenannte *nicht normalisierte Mixing Matrix*. Auf der Diagonalen (fett markiert) ist ersichtlich, wie viele Kanten zwischen Knoten mit dem gleichen Geschlecht existieren:

	non-binary	female	male	Total out
non-binary	**0**	1	1	2
female	1	**2**	3	6
male	1	3	**2**	6
Total in	2	6	6	

Tabelle 10.5: Nicht-normalisierte Mixing Matrix für das Gender-Attribut

Hinweis: Da ein ungerichtetes Netzwerk vorliegt, ist jede Kante in der Mixing Matrix doppelt vorhanden.

In der Gleichung 10.3 ist die Berechnung der Assortativität bei kategorischen Knoten-Attributen dargestellt.

$$r = \frac{\sum_i e_{ii} - \sum_i a_i b_i}{1 - \sum_i a_i b_i} \tag{10.3}$$

wobei:

e_{ii} der Anteil der Kanten ist, die Knoten derselben Kategorie i verbinden,

a_i der Anteil der ausgehenden Kantenenden ist, die mit Knoten der Kategorie i verbunden sind,

b_i der Anteil der eingehenden Kantenenden ist, die mit Knoten der Kategorie i verbunden sind.

Bei ungerichteten Graphen sind a_i und b_i gleich.

In der Tabelle 10.5 sind die nicht-normalisierten Werte dargestellt. Für die Berechnung müssen die Werte normalisiert werden. Dies bedeutet, dass die Werte der nicht-normalisierten Mixing Matrix durch die Anzahl Kanten dividiert werden. Im vorliegenden Beispiel haben wir 7 Kanten und müssen die Werte deshalb durch 14 teilen, da alle ungerichteten Kanten in der Mixing Matrix doppelt vorhanden sind. Somit resultiert die folgende normalisierte Mixing-Matrix:

	non-binary	female	male	Total Out (a_i)
non-binary	**0**	0.071	0.071	0.143
female	0.071	**0.143**	0.214	0.428
male	0.071	0.214	**0.143**	0.428
Total In (b_i)	0.143	0.429	0.429	

Tabelle 10.6: Normalisierte Mixing Matrix für das Gender-Attribut

Zur Berechnung der Assortativität für die kategorischen Knoten-Attribute des gegebenen Beispiels nun in die Gleichung 10.3 ein:

$$r = \frac{\sum_i e_{ii} - \sum_i a_i b_i}{1 - \sum_i a_i b_i}$$

$$r = \frac{(0 + 0.143 + 0.143) - (0.143^2 + 0.428^2 + 0.428^2)}{1 - (0.143^2 + 0.428^2 + 0.428^2)}$$

$$r = \frac{0.286 - 0.386}{1 - 0.386}$$

$$r = \frac{-0.1}{0.614} = -0.163$$

Kapitel 11

Inferenzielle Statistik in Netzwerken

Alle bisher betrachteten Masse und Metriken haben einen deskriptiven Charakter. Sie beschreiben eine Eigenheit des Netzwerks wie beispielsweise, welche Aktoren sehr zentral sind, wie viele k-Cores in einem Netzwerk existieren, wie viele Bridges vorhanden sind, was der Durchmesser oder der Cluster Coeffizient des Netzwerks ist wie auch, ob Homophilie im Netzwerk ausgewiesen werden kann.

Was jedoch anhand solcher deskriptiven Werte nicht beurteilt werden kann, ist, ob die Masse und Metriken, die gemessen wurden, *normal* oder *aussergewöhnlich* sind. Und das ist genau das Ziel der *Inferenziellen Statistik*.

Es wird ein sogenannter Hypothesentest definiert und geprüft, ob die gemessenen deskriptiven Werte im zu erwarteten Bereich liegen oder signifikant (= nicht zufällig) davon abweicht. Falls sich der gemessene deskriptive Wert signifikant von den Referenz-Werten unterscheidet, dann handelt es sich um eine Eigenheit, welche im vorhandenen Netzwerk von spezieller Bedeutung ist. Der Aufbau von Hypothesentests wird im Abschnitt 11.2 genauer erläutert.

Es gibt verschiedene Arten von Hypothesentests, um die Eigenschaften des Netzwerks, der Knoten wie auch der Kanten auf Signifikanz zu testen. Die verschiedenen Arten von Hypothesentests werden im Abschnitt 11.3 genauer beschrieben und mit Beispielen ausgeschmückt.

11.1 Referenz-Netzwerke erzeugen

In vielen statistischen Signifikanztests (z.B. t-Test) vorausgesetzt wird, dass die Messwerte unabhängig voneinander sind. Dies ist bei Netzwerken nicht zwingend gegeben. Wenn in einem sozialen Netzwerk eine Person A mit einer Person B verbunden ist und die Person B mit der Person C, dann ist die Wahrscheinlichkeit hoch, dass die Person A auch mit der Person C verbunden ist. Es sind also nicht alle verbleibenden möglichen Kanten gleich wahrscheinlich. Zusätzlich würde das Beenden der Freundschaftsbeziehung von A zu B beide Knoten beeinflussen (hätten z.B. je einen Degree weniger).

Um die statistische Signifikanz in Netzwerken zu untersuchen, werden sogenannte Referenz-Netzwerke (Null Modelle) benötigt. Wichtig ist, dass die grundlegende Charakteristik im Ursprungs-Netzwerk in den generierten Referenz-Netzwerken enthalten bleibt. Es gibt unterschiedlich Modelle, um solche Referenz-Netzwerke zu erstellen.

Ein simples Modell ist das *Erdős-Rényi-Model* . Bei diesem Modell wird angegeben, wie viele Knoten das generierte Netzwerk enthalten soll und eine Wahrscheinlichkeit p für die Existenz von Kanten. Jede mögliche Kante existiert mit der Wahrscheinlichkeit p im generierten Graphen. Der Nachteil bei der Verwendung dieses Modells für die Untersuchung von statistischer Signifikanz ist, dass durch die Einfachheit viel der Charakteristik im Ursprungs-Netzwerk verloren geht. Wird dieses Modell als Referenz-Modell verwendet, können lediglich Aussagen in Bezug auf *völlig zufällige Netzwerke mit gleichen Anzahl Knoten und gleicher Kanten-Wahrscheinlichkeit* gemacht werden. Charakteristiken wie die Verteilung der Degrees oder der Community-Strukturen gehen bei der Generierung eines Netzwerks mit dem *Erdős-Rényi-Model* verloren.

Ein bekanntes Modell, welches bereits bei der Berechnung der Modularity verwendet wurde, ist das sogenannte *Configuration Model*. Hier wird die Verteilung der Knotengrade (engl. Degree Distribution) beibehalten, so dass das generierte Referenz-Netzwerk in dieser Charakteristik gleich bleibt. Dies bedeutet, dass im generierten Netzwerk die gleiche Anzahl Knoten existiert, welche einen Degree von 1, 2, ... haben. Zur Generierung von neuen Netzwerken wird das ursprüngliche Netzwerk verwendet, alle Kanten *durchgeschnitten* und zufällig neu verknüpft. Hat eine Kante ein Gewicht grösser als eins, kann dies als parallele Kanten zwischen den Knoten vorgestellt werden, die dann durchtrennt werden. Es kann passieren, dass es hierbei zu Self-Loops kommt. Umso grösser das Netzwerk, desto kleiner die Wahrscheinlichkeit für Self-Loops. Die Self-Loops können auch entfernt werden. So resultieren zwar nicht mehr die genau gleiche Degree-Verteilung zum Ursprungs-Netzwerk, was jedoch vernachlässigbar ist. Zudem können sich die Anzahl Connected Components ändern, da das permutierte Netzwerk nicht zwingend verbunden sein muss. Wichtig ist einfach, dass für jede Permutation das Original-Netzwerk als Basis verwendet wird, wenn beispielsweise Self-Loops entfernt werden. Aufgrund der gleichbleibenden Degree-Verteilung eignet sich das *Configuration Model* viel besser für viele Arten von Hypothesentests als das *Erdős-Rényi-Model*, da die Aussage über die Signifikanz im Vergleich zu Netzwerken mit der gleichen Degree-Verteilung ist. Es lassen sich jedoch keine Hypothesen zu den Degrees, resp. der Verteilung der Degrees untersuchen, da das *Configuration Model* dies genau so abbildet, wie im Ursprungsnetzwerk. Wir haben also keine zufällige Verteilung.

Wenn die Korrelation zwischen Relationen untersucht werden soll (z.B. ob zwei Personen, die physisch am Arbeitsplatz näher zusammen sitzen auch häufiger Nachrichten austauschen), dann kann dafür die *Quadratic Assignment Procedure (QAP)* verwendet werden. Dabei wird die initiale Korrelation der beiden Adjazenzmatrizen berechnet und im Anschluss werden diese permutiert. Dies führt dazu, dass die Knoten innerhalb des Netzwerks vertauscht werden.

Es gibt noch viele weitere Modelle, um Netzwerke zu generieren. Das *Stochastic Block Model (SBM)* sorgt bei der Generierung dafür, dass die Charakteristik der Community-Strukturen bestehen bleibt. Am meisten Flexibilität bieten die *Exponential Random Graph Models (ERGM)*. Bei denen kann als Parameter übergeben werden, welche Eigenschaften in den generierten Netzwerken beibehalten werden sollen.

11.2 Aufbau von Hypothesentests

Bei Hypothesentests geht es nicht nur darum zu zeigen, dass es einen statistischen Zusammenhang zwischen verschiedenen Variablen gibt, sondern auch, ob dieser signifikant, also nicht zufällig, ist. Nachfolgend der Aufbau eines Hypothesentests. Die Konzepte werden immer gleich auch anhand eines Beispiels erläutert.

1. Zuerst wird immer eine Nullhypothese (H_0) und eine Alternativhypothese (H_1) definiert. Die Nullhypothese besagt, dass es zwischen keinen statistisch signifikanten Unterschied in den zu untersuchenden Messwerten zwischen dem ursprünglichen Netzwerk und den Referenz-Netzwerken gibt. Die Alternativhypothese besagt das Gegenteil.
   Es soll untersucht werden, ob im vorliegenden Social Media Netzwerk eine positive lineare Korrelation zwischen dem persönlichen Glücks-Empfinden (Knoten-Attribut) und der Anzahl Kontakte im Social Media Netzwerk (Degree-Zentralität) besteht. Die Nullhypothese H_0 ist also, dass es keinen signifikanten Unterschied in der Korrelation zwischen dem Glücks-Empfinden und der Degree-Zentralität im Ursprungs-Netzwerk im Vergleich zu den Referenz-Netzwerken gibt. Die Alternativhypothese H_1 besagt, dass eine eine signifikante Korrelation existiert.

2. Zudem muss die sogenannte Irrtumswahrscheinlichkeit α (auch Signifikanz-Niveau genannt) definiert werden, welche in den meisten Fällen bei 0.05 (5%) liegt (kann je nach Anwendungsfall auch 1% sein). Dies bedeutet, dass als Resultat des Hypothesentests in 5% der Fälle ein statistisch signifikanter Zusammenhang angenommen wird (die Nullhypothese wird verworfen), obwohl dies nicht der Realität entspricht.
   In unserem Beispiel verwenden wir für α den Standard-Wert von 5%.

3. Die zu untersuchende Metrik (Anzahl k-Cores, Korrelation zwischen Zentralitätsmass und Knoten-Attribut, Assortativität, usw.) wird auf dem zu untersuchenden Original-Netzwerk gemessen.
   Der im Ursprungs-Netzwerk gemessene Pearson Korrelationskoeffizient zwischen dem Glücks-Empfinden und Degree-Zentralität ist 0.4.

4. Nun wird ein Referenz-Netzwerk erzeugt und die zu untersuchende Metrik auf dem Referenz-Netzwerk gemessen. Dieser Schritt wird tausend oder mehrere tausend Mal wiederholt, um die Verteilung auf den Referenz-Netzwerken zu erhalten.
   Jetzt werden 1'000 Mal die Degree-Zentralitäts-Werte und angegebenen Werte zum Glücksempfinden zufällig permutiert und für jede dieser zufälligen Permutationen gemessen, wie hoch der Pearson Korrelationskoeffizient auf den permutierten Daten ist.

5. Nun wird gezählt, wie häufig der gemessene Wert auf den tausenden Referenz-Netzwerken grösser oder gleich / kleiner oder gleich als der gemessene Wert auf dem Ursprungs-Netzwerk ist. Diese Anzahl wird dann durch die Anzahl Referenz-Netzwerke geteilt, so dass ein Wert zwischen 0 und 1 resultiert. Dieser Wert ist dann der *empirische p-Wert* des Hypothesentests. Der p-Wert ist laut Definition die Wahrscheinlichkeit, dass unter der Annahme, die Nullhypothese sei wahr, die Teststatistik den beobachteten oder einen extremeren Wert annimmt.
   200 Mal wurde bei diesen zufälligen Zuordnungen eine Korrelation gemessen, die

mindestens so gross ist, wie der Wert auf dem ursprünglichen Original-Netzwerk. Somit wäre der empirische p-Wert $\frac{20}{1'000} = 0.02$; oder anders ausgedrückt: In 2% der Fälle erscheint per Zufall eine Korrelation, welche mindestens so gross ist, wie der Referenzwert.

6. Wenn der gemessene *empirische p-Wert* kleiner als das definierte α ist, dann wird von einer statistischen Signifikanz gesprochen.
   Da der gemessene emprirische p-Wert (0.02) nicht grösser als unsere initial definierte Irrtumswahrscheinlichkeit α (0.05) ist, wird die Nullhypothese verworfen und dadurch gezeigt, dass die Korrelation der untersuchten Variablen statistisch signifikant ist.

11.3 Arten von Hypothesentests in Netzwerken

In diesem Abschnitt wird näher auf verschiedene Varianten von Hypothesentests in Netzwerken eingegangen und gezeigt, wie diese durchgeführt werden. Anhand von Verweisen und Beispiel wird der Horizont erweitert und gezeigt, dass viele bisherige Themen auch in Hypothesentests verwendet werden können.

11.3.1 Hypothesentests auf nummerischen Knoten-Attribute

Bei Hypothesentests auf nummerischen Knotenattributen, sogenannten *Monadischen Hypothestentests*, wird untersucht, ob eine auf Knoten berechnetes Netzwerk-Mass (z.B. Aktor-Zentralität, Prestige-Mass, Lokaler Clustering Coefficient, ...) mit einem nummerischen Knoten-Attribut (z.B. Alter, Vermögen, Berufserfahrung in Jahren, ...) einen statistisch signifikanten Zusammenhang aufweisen.

Beispielhypothesen wären:

- Reiche Personen (Vermögen als Knoten-Attibut) sind gut vernetzt (z.B. hoher Zentralitäts-Wert des Knotens)
- Gut vernetzte Personen (hoher Zentralitäts-Wert des Knotens) sind glücklicher (Knoten-Attribut)

Pearson und Spearman Korrelationsverfahren liefern uns den Korrelationskoeffizienten r. Daraus lässt sich die Richtung (positiv oder negativ) und die Stärke der Korrelation ablesen. Was jetzt aber noch für eine zuverlässige Aussage fehlt ist, ob es sich um eine *signifikante* Korrelation handelt. Dies bedeutet, dass die Korrelation nicht nur durch Zufall vorhanden ist.

Zuerst wird die Irrtumswahrscheinlichkeit $\alpha = 0.05$ definiert. In der nachfolgenden Auflistung sind die initialen Vektoren zu den Degree-Zentralitätswerten und den Vermögens-Werten der Knoten ersichtlich sind. Zusätzlich wurde der berechnete Pearson Korrelationskeffizient r abgebildet:

$$degree = [0.1, 0.2, 0.3, 0.5, 0.6]$$

$$wealth = [100, 400, 300, 900, 300]$$

$$r = 0.522$$

Das $r = 0.522$ ist der initiale Referenz-Wert der Korrelation zwischen dem Degree und dem Vermögen. Nun werden die Werte innerhalb der Vektoren beliebig vertauscht, erneut die Korrelation berechnet, z.B:

$$degree = [0.5, 0.3, 0.1, 0.6, 0.2]$$

$$wealth = [300, 300, 100, 400, 900]$$

$$r = -0.040$$

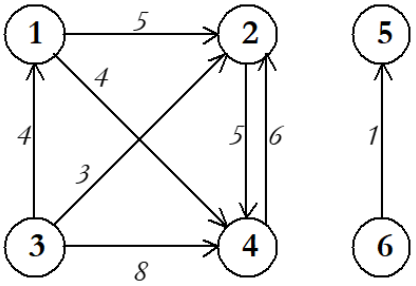
Der neu berechnete r Wert ist -0.040 und somit kleiner als der Referenz-Wert von 0.522. Deshalb wird der Zähler welcher nachführt, wie häufig per Zufall ein grösserer Wert als der initiale Referenz-Wert erscheint, nicht erhöht. Dieser Vorgang der Permutation wird nun noch mehrere tausend Mal (Standard ist 10'000 - 20'000 Mal) wiederholt und schlussendlich ein p-Wert zwischen 0 und 1 zurück gegeben, welcher dem Quotienten $\frac{Anzahl\ zufllige\ Korrelationen \geq Initiale\ Referenz-Korrelation}{Anzahl\ Durchlufe\ resp.\ Permutationen}$ entspricht. Ist dieser p-Wert kleiner als die initial festgelegte Irrtumswahrscheinlichkeit, dann wird von einer statistisch signifikanten Korrelation gesprochen.

11.3.2 Hypothesentests auf Kanten(-Attribute) in multirelationalen Netzwerken

Bei Hypothesentests auf multirelationalen Netzwerken kommen sogenannte *Dyadische Hypothesentests* zum Einsatz. Dabei wird vorausgesetzt, dass verschiedene Kantentypen für das gleiche Netzwerk existieren. Die Kanten können dabei ungewichtet oder gewichtet sein. In einem Sozialen Netzwerk könnten beispielsweise die Freunschaft (ungewichtete Kante, Freundschaft mit Angabe der Dauer (gewichtete Kante), die Anzahl ausgetauschter Nachrichten) als verschiedene Kantentypen abgebildet werden. Dann wird untersucht, ob einen statistisch signifikanten Zusammenhang zwischen den unterschiedlichen Beziehungen gibt. Im Unterabschnitt 11.3.3 wird dann noch eine weitere Möglichkeit vorgestellt, um zusätzliche nummerische Relationen basierend auf Knoten-Attribute im Netzwerk abzubilden. Für diesen Hypothesentest wird das Netzwerk als Adjazenzmatrix dargestellt.

In der Adjazenzmatrix existiert für jeden Knoten eine Zeile und eine Spalte (Speicherverbrauch in $O(N^2)$, wobei N für die Anzahl Knoten steht). Eine Kante wird dargestellt, indem das Kantengewicht in die entsprechende Zelle eingetragen wird. Die

korrekte Zelle wird gefunden, indem die Zeile dem Knoten-Ursprung entspricht und die Spalte dem Ziel-Knoten. Bei ungerichteten Netzwerken wird eine Kante in beide Richtungen eingetragen, was dazu führt, dass sich die Matrix in der Diagonalen spiegelt. In der Tabelle 11.1 ist ein Netzwerk und die zugehörige Adjazenzmatrix dargestellt.

Gewichtetes Beispielnetzwerk mit 6 Knoten:	Repräsentation des Beispielnetzwerk als Adjazenzmatrix:
	nach / von

von \ nach	1	2	3	4	5	6
1	-	5	-	4	-	-
2	-	-	–	5	–	–
3	4	3	–	8	–	–
4	–	6	–	–	–	–
5	–	–	–	–	–	–
6	–	–	–	–	1	–

Tabelle 11.1: Ein Beispiel-Graph und die zugehörige Adjazenzmatrix.

Im nachfolgenden Beispiel wird untersucht, ob Studierende, welche zusammen viel Zeit mit Lernen verbringen auch viel Zeit zusammen in der Bar geniessen. Dazu werden die entsprechenden zwei Netzwerke in Form von Adjazenzmatrizen benötigt:

- 1. Netzwerk: Studierende werden als Knoten dargestellt und die gemeinsamen Barbesuche in Stunden pro Woche als Kanten.

$$\overbrace{\begin{pmatrix} 0 & 3 & 2 & 0 \\ 3 & 0 & 1 & 0 \\ 2 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix}}^{\text{Bar-Netzwerk}} \tag{11.1}$$

- 2. Netzwerk: Studierende werden als Knoten dargestellt, die Kanten bilden ab, wer miteinander wie viele Stunden lernt.

$$\overbrace{\begin{pmatrix} 0 & 10 & 4 & 3 \\ 10 & 0 & 2 & 0 \\ 4 & 2 & 0 & 2 \\ 3 & 0 & 2 & 0 \end{pmatrix}}^{\text{Lern-Netzwerk}} \tag{11.2}$$

Um nun die Korrelation zwischen den beiden Adjazenzmatrizen zu untersuchen, müssen diese zu Vektoren transformiert werden. Dies zu bewerkstelligen ist einfach, denn es werden einfach alle Zeilen der Adjazenzmatrizen aneinandergereiht:

$$Bar - Netzwerk = [0, 3, 2, 0, 3, 0, 1, 0, 2, 1, 0, 1, 0, 0, 1, 0]$$

$$Lern - Netzwerk = [0, 10, 4, 3, 10, 0, 2, 0, 4, 2, 0, 2, 3, 0, 2, 0]$$

Da nur die Beziehungen zwischen verschiedenen Knoten von Interesse sind, sollten die Einträge in der Diagonalen entfernt werden. In einem Netzwerk ohne Self-Loops, wie im aktuellen Beispiel, sind diese alle 0. Es resultieren die folgenden Vektoren:

$$Bar - Netzwerk = [3, 2, 0, 3, 1, 0, 2, 1, 1, 0, 0, 1]$$

$$Lern - Netzwerk = [10, 4, 3, 10, 2, 0, 4, 2, 2, 3, 0, 2]$$

Nun kann die Korrelation zwischen den beiden Arrays berechnet werden. Wird der Pearson Korrelations-Koeffizient verwendet, entspricht der Korrelationskoeffizient $r = 0.87$. Zusätzlich soll auch wieder geprüft werden, ob es sich um eine signifikante Korrelation handelt. Im Gegensatz zum monadischen Hypothesentest werden nun nicht einfach die Werte innerhalb der Arrays permutiert, sondern es kommt die Quadratic Assignment Procedure (QAP) zum Einsatz. Dabei werden die Zeilen und Spalten einer Adjazenzmatrix permutiert anstatt nur einzelner Werte. Dies hat den grossen Vorteil, dass die Netzwerk-Eigenschaften des ursprünglichen Netzwerks enthalten bleiben. Bildlich vorgestellt bedeutet dies, dass die Netzwerk-Struktur bleibt und die Knoten vertauscht werden (z.B: Knoten A und Knotne B tauschen ihren Platz).

Die Gleichung 11.3 veranschaulicht, wie die resultierende Adjazenzmatrix aussieht, wenn die Zeilen und Spalten 1 mit 2 und 3 mit 4 vertauscht werden.

$$\overbrace{\begin{pmatrix} 0 & 10 & 4 & 3 \\ 10 & 0 & 2 & 0 \\ 4 & 2 & 0 & 2 \\ 3 & 0 & 2 & 0 \end{pmatrix}}^{\text{Lern-Netzwerkt (Ursprung)}} \Rightarrow \overbrace{\begin{pmatrix} 0 & 10 & 2 & 0 \\ 10 & 0 & 4 & 3 \\ 2 & 4 & 0 & 2 \\ 0 & 3 & 2 & 0 \end{pmatrix}}^{\text{Lern-Netzwerkt (Zeile uns Spalte 1 mit 2 permutiert)}} \Rightarrow \overbrace{\begin{pmatrix} 0 & 10 & 0 & 2 \\ 10 & 0 & 3 & 4 \\ 0 & 3 & 0 & 2 \\ 2 & 4 & 2 & 0 \end{pmatrix}}^{\text{Lern-Netzwerkt (komplett permutiert)}} \tag{11.3}$$

Nun erfolgt der gleiche Prozess zur Bestimmung des Korrelationskeffozienten zwischen dem permutierten Lern-Netzwerk und dem Barbesuch-Netzwerk. Zuerst wird aus der permutierten Adjazenzmatrix wird ein Vektor erzeugt und die Werte der Diagonalen entfernt. Die führt zu:

$$Lern - Netzwerk = [10, 0, 2, 10, 3, 4, 0, 3, 2, 2, 4, 2]$$

Danach wird der Pearson Korrelationskoeffizient zwischen dem Vektor der permutierten Adjazenzmatrix mit entfernten Nullen in der Diagonalen und dem Barbesuch-Netzwerk (ebenfalls ohne die Nullen in der Diagonalen) berechnet. Dabei resultiert ein Wert von $r = 0.52$. Dieser Prozess wird nun 10'000 bis 20'000 Mal wiederholt und gezählt, wie häufig in den Korrelationen mit dem permutierten Netzwerken ein Korrelationskoeffizient entsteht, welcher grösser oder gleich als der initiale Korrelationskoeffizient ist (hier $r = 0.87$). Der relative Wert dieser Häufigkeit stellt dann den p-Wert dar.

11.3.3 Hypothesentests auf Knoten- und Kantenattribute

Es gibt auch Situationen, in welchen der statistische Zusammenhang zwischen Knotenattributen und existierenden Kanten untersucht werden soll. Diese Art von Hypothesentest wird als *Gemischter Dyadisch-Monadischer Hypothesentest* bezeichnet. Zwei Beispiele wären:

- Es soll untersucht werden, ob Personen mit dem gleichen Geschlecht häufiger miteinander kommunizieren als Personen mit unterschiedlichen Geschlechtern.
- Es soll untersucht werden, ob der Altersunterschied zwischen Personen einen signifikanten Einfluss auf das Kommunikationsverhalten hat.

In beiden Beispielen sind Personen als Knoten abgebildet und als Kanten die Kommunikation zwischen den Personen. Der zu untersuchende Zusammenhang ist jedoch unterschiedlich. Das Knotenattribut *Geschlecht* ist ein kategorisches Attribut, was bedeutet, dass eine endliche Anzahl von verschiedenen Werten angenommen werden kann. Das Knotenattribut *Alter* ist nummerisch.

Um den Hypothesentest auszuführen, wird der gemischte Hypothesentest auf einen dyadischen Hypothesentest reduziert. Das Kommunikationsverhalten ist bereits als Kanten dargestellt. Nun müssen die die Knotenattribute noch als Kanten abgebildet werden können. Die Idee dabei ist, dass zu untersuchende Gemeinsamkeiten (oder Unterschiede) als (gewichtete) Kanten abgebildet werden. Dazu können für die vorliegenden Beispiele folgende Abbildungen verwendet werden:

- Geschlecht: Es wird ein neues Netzwerk mit den gleichen Knoten erzeugt. Die Knoten werden mit einer Kante verbunden, wenn zwei Knoten das gleiche Geschlecht aufweisen. Somit sind schlussendlich alle Personen mit dem gleichen Geschlecht in diesem Netzwerk verbunden.
- Alter: Es wird ein neues Netzwerk mit den gleichen Knoten erzeugt. Die Kanten werden auch zwischen allen Knotnepaaren gebildet und haben als Gewicht den Betrag des Altersunterschieds.

Da nun wieder zwei Adjazenzmatrizen korreliert werden, kann der dyadische Hypothesentest angewendet werden. Dies hat den Vorteil, dass die Netzwerk-Struktur garantiert gleich bleibt und nur die Knoten permutiert werden. Somit können schlussendlich Aussagen bezüglich statistischer Signifikanz im Vergleich zur gleichen Netzwerk-Struktur gemacht werden. Zudem ist garantiert, dass nummerische Attribute auf den Kanten (z.B. das Kantengewicht) direkt berücksichtigt wird. Alternativ kann für diese Art

von Hypothesentest auf die Assortativität als Netzwerk-Metrik berechnet und auf Signifikanz geprüft werden. Dies erfolgt dann jedoch mit einem *Configuration Model*. Der Vergleich findet also mit generierten Referenz-Netzwerken mit derselben Degree-Verteilung statt, ohne dass die restlichen strukturellen Eigenschaften im Ursprungs-Netzwerk zwingend enthalten sein müssen.

In Abbildung 11.1 ist das berühmte *Zachary's Karate-Club* Netzwerk abgebildet. Die Mitglieder der zwei Karate-Clubs sind als Knoten abgebildet, wobei die Knotenfarbe die Club-Zugehörigkeit repräsentiert. Die Kanten sind die Interaktionen zwischen den Personen.

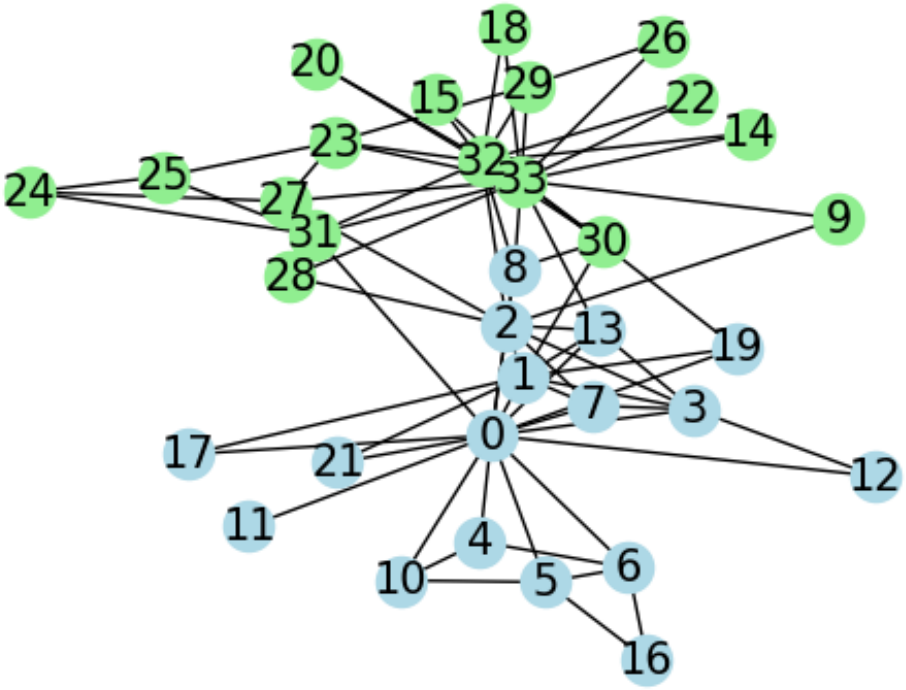


Abbildung 11.1: Zachary's Karate Club Netzwerk. Die Knoten-Farbe visualisiert die Club-Zugehörigkeit und die Kanten die Interaktion zwischen Personen.

Nun wird untersucht, wie stark die *Club Assortativität* ist, sprich, wie stark die Tendenz besteht, dass Personen eher mit Personen des gleichen Clubs interagieren. Der visuelle Eindruck lässt vermuten, dass dieser gross ist. In diesem Beispiel wurde die Signifikanz mit dem Configuration Model geprüft.

Das Resultat des Hypothesentests ist in Abbildung 11.2 sichtbar.

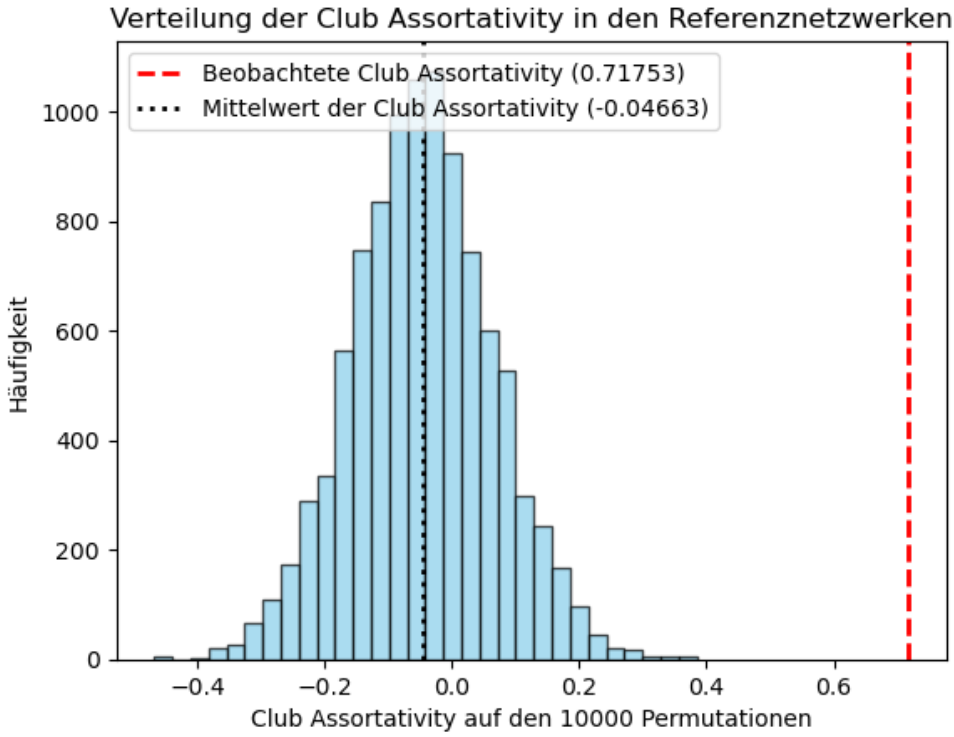


Abbildung 11.2: Resultat des Permutations-Tests der Club Assortativität auf dem Zachary's Karate Club Netzwerk. Die Club Assortativität ist wie erwartet sehr hoch und statistisch signifikant.

Die Club Assortativität im Ursprungs-Netzwerk ist mit 0.72 sehr hoch und deutlich statistisch signifikant, da die Club Assortativitäts-Werte auf den permutierten Netzwerken normalverteilt um den Mittelwert 0.05 sind.

11.3.4 Hypothesentets auf Netzwerk-Metriken

Für Hypothesentests auf Netzwerk-Metriken wird ein Vergleichs-Netzwerk benötigt um zu untersuchen, ob sich die gemessene Netzwerk-Metrik im Ursprungs-Netzwerk (Global Clustering Coefficient, Diameter, Netzwerk-Zentralisierungen (ausser Degree), ...) signifikant vom zu erwarteten Wert unterscheidet[1]. Im Abschnitt 11.1 wurden ein paar Möglichkeiten zur Generierung von Referenz-Netzwerken erwähnt. Für viele Anwendungsfälle ist das *Configuration Model* gut geeignet zur Erzeugung von Referenz-Netzwerken. Nur die Degrees, resp. die Verteilung der Degrees (Degree-Zentralisierung), lassen sich damit nicht untersuchen, da sich dies gleich verhält wie im Ursprungs-Netzwerk.

[1] Für den Netzwerk Durchmesser (Diameter) funktioniert dieser Ansatz leider nicht sehr gut, da beim Configuration Model viele unverbundene Graphen resultieren, deren Durchmesser dann *unendlich* ist.

Kapitel 12

Link-Prediction

Bei der *Link-Prediction* wird von einem bestehenden Netzwerk ausgegangen und versucht vorherzusagen, welche Kanten sich in naher Zukunft bilden werden. Die wohl bekannteste Anwendung ist das Vorschlagen neuer Freunde auf Sozialen Netzwerkplattformen.

Für diese Vorhersage existieren verschiedene Algorithmen. Ein paar davon werden im nachfolgenden Unterabschnitt vorgestellt. Es gibt nicht ein Algorithmus, welcher in allen Fällen gute Resultate liefert. Deshalb muss hier von Fall zu Fall evaluiert und entschieden werden, welcher Algorithmus die zutreffendsten Resultate liefert. Ein solcher Versuchsaufbau und zugehörige Evaluation wird im Abschnitt 12.2 im Detail beschrieben.

Detailliertere Informationen sowie auch weitere Algorithmen zum Thema Link-Prediction ist in [Rom] und [LNK07] auffindbar.

Hinweis: Leider verfügt Gephi (noch) nicht über ein Link-Prediction Plugin. Jedoch sind die hier vorgestellten Algorithmen alle in der Python Netzwerk Library *networkx* vorhanden.

12.1 Algorithmen

Die nachfolgenden Algorithmen zur Vorhersage von neuen Kanten basieren alle auf den Nachbarschafts-Informationen von Knoten. Deshalb wird die Funktion $N(..)$ hier definiert. Der Aufruf der Funktion $N(..)$ liefert alle Nachbarn eines Knotens in einem Set zurück liefert, z.B. $N(A)$ gibt alle Nachbarsknoten des Knotens A zurück.

Weiter wird immer der gleiche Beispielgraph verwendet. Um Platz zu sparen, wird dieser nicht in jedem Unterabschnitt nochmals neu abgebildet. Abbildung 12.1 zeigt den in den Beispielgraphen:

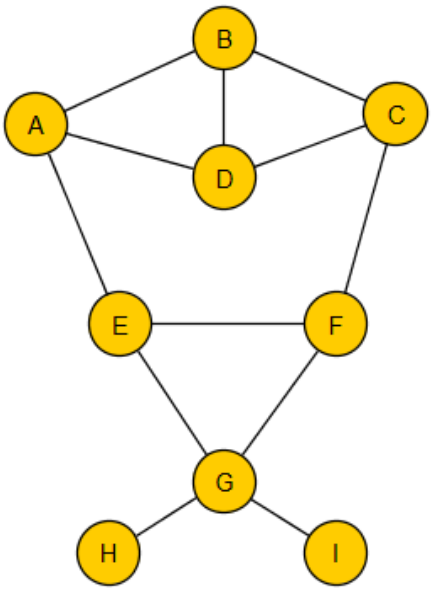


Abbildung 12.1: Beispiel-Graph für die Link-Prediction Algorithmen (aus [Rom])

Bei der Link-Prediction muss unterschieden werden, ob dies aus der Sicht des kompletten Netzwerks oder aus der Sicht eines einzelnen Knotens geschehen soll. Im ersten Fall müssen alle unverbundenen Knotenpaarungen berücksichtigt werden. Nachdem die Link-Prediction Metriken zwischen den Knotenpaaren mit einem Algorithmus berechnet wurden, hat immer die Knotenpaarung mit dem grössten Wert die höchste Priorität / ist die wahrscheinlichste Vorhersage des Algorithmus.

Wichtig: In den nachfolgenden Unterabschnitten werden jeweils nur wenige Berechnungsbeispiele gezeigt. Es geht darum zu veranschaulichen, wie die Berechnungen funktionieren. Für eine korrekte Link-Prediction müssen die Berechnungen zwischen allen infrage kommenden Knotenpaaren ausgeführt und die Resultate dann anhand ihres Wertes sortiert werden. Wenn in den Unterabschnitten eine Empfehlung für die nächste Kante als Beispiel erwähnt ist, dann bezieht sich dies immer nur auf die berechneten Beispielwerte.

12.1.1 Common Neighbours

Common Neighbours ist eine sehr einfache Metrik. Sie berechnet für zwei nicht verbundene Knoten, wie viele gemeinsame Nachbarn existieren. Die Formel (12.1) stellt dar, wie sich die Anzahl gemeinsamer Nachbarn von zwei Knoten X und Y berechnet lässt:

$$common_neighbours(X,Y) = \mid N(X) \cap N(Y) \mid \tag{12.1}$$

Hier ein paar Beispiele zur Berechnung der *Common Neighbours* Metrik für den Knoten

A:

$$common_neighbours(A, C) =\mid \{B, D\} \mid= 2$$

$$common_neighbours(A, F) =\mid \{E\} \mid \quad = 1$$

$$common_neighbours(A, I) =\mid \{\} \mid \quad = 0$$

Da der Knoten C die meisten gemeinsamen Knoten mit dem Knoten A aufweist, würde der Algorithmus vorschlagen, dass eine Kante zwischen diesen beiden Knoten als nächstes hergestellt werden sollte.

12.1.2 Soundarajan Hopcroft

Soundarajan Hopcroft erweitert die Common Neighbours Metrik, indem für alle gemeinsamen Nachbarn noch geprüft wird, ob sich diese in der gleichen Community befinden. Für alle Nachbarn der gemeinsamen Community gibt es einen Bonus. Vorausgesetzt wird natürlich, dass die Community-Information zuvor berechnet wird. Die Formel (12.2) stellt dar, wie sich die Anzahl gemeinsamer Nachbarn von zwei Knoten X und Y unter Berücksichtigung des Bonus lässt, wobei die Funktion $f(w)$ 1 zurückgibt, falls dieser Knoten der gleichen Community wie die Knoten X und Y angehört:

$$soundarajan_hopcroft(X, Y) =\mid N(X) \cap N(Y) \mid + \sum_{w \in N(X) \cap N(Y)} f(w) \qquad (12.2)$$

Hier ein paar Beispiele zur Berechnung der *Common Neighbours* Metrik anhand unseres Beispiel-Graphen. Es wird dabei angenommen, dass es zwei Communities gibt; eine mit den Knoten A, B, C, D und eine zweite mit den restlichen Knoten.

$$soundarajan_hopcroft(A, C) =\mid \{B, D\} \mid +2= 4$$

$$soundarajan_hopcroft(E, I) =\mid \{G\} \mid +1 \quad = 2$$

$$soundarajan_hopcroft(A, F) =\mid \{E\} \mid \quad = 1$$

12.1.3 Jaccard Coefficient

Die *Jaccard Coefficient* Metrik ist eine Erweiterung der *Common Neighbours* Metrik. Sie berücksichtigt nicht nur die Anzahl gemeinsamer Nachbarn zweier Knoten, sondern setzt diese ins Verhältnis zu den Anzahl Nachbarn beider Knoten. Haben zwei Knoten 100 Nachbarn und davon 5 gemeinsame, ist dies weniger aussagekräftig, als wenn die zwei Knoten jeweils nur 10 Nachbarn haben und davon 5 gemeinsame.

Die Formel (12.3) stellt dar, wie die *Jaccard Coefficient* Metrik zweier Knoten X und Y berechnet wird.

$$jaccard_coefficient(X, Y) = \frac{\mid N(X) \cap N(Y) \mid}{\mid N(X) \cup N(Y) \mid} \qquad (12.3)$$

Hier ein paar Beispiele zur Berechnung der *Jaccard Coefficient* Metrik für den Knoten A, wobei schlussendlich wieder der Knoten C als nächster direkter Nachbar vorgeschlagen wird, da dieser den grössten Wert aufweist:

$$jaccard_coefficient(A,C) = \frac{\mid \{B,D\} \mid}{\mid \{B,D,E,F\} \mid} = \frac{2}{4} = 0.5$$

$$jaccard_coefficient(A,F) = \frac{\mid \{E\} \mid}{\mid \{B,C,D,E,G\} \mid} = \frac{1}{5} = 0.2$$

Der insgesamt grösste mögliche Wert dieser Metrik ist 1, was bedeutet, dass alle Nachbarn zweier Knoten gemeinsame Nachbarn sind (Im Beispielgraphen bei den Knoten H und I).

12.1.4 Resource Allocation

Der Hintergedanke bei diesem Ansatz ist, dass ein Knoten X einem nicht direkt verbundenen Knoten Z *Ressourcen* (z.B. Informationen) über gemeinsame Nachbarn (als Beispiel hier Y) zukommen lassen kann. Es wird angenommen, X schickt die Ressource dem gemeinsamen Nachbarn Y. Y leitet die Ressource zu gleichem Anteil an alle seine Nachbarn weiterleitet. Hat der Knoten Y selbst sehr viele Nachbarn, erhält der Knoten Z schlussendlich nur einen sehr kleinen Anteil der Ressource.

Die Formel (12.4) stellt dar, wie die *Resource Allocation* Metrik zweier Knoten X und Y berechnet wird.

$$resource_allocation(X,Y) = \sum_{u \in N(X) \cap N(Y)} \frac{1}{\mid N(u) \mid} \tag{12.4}$$

Hier ein paar Beispiele zur Berechnung der *Resource Allocation* Metrik für den Knoten A, wobei schlussendlich wieder der Knoten C als nächster direkter Nachbar vorgeschlagen wird, da dieser den grössten Wert aufweist:

$$resource_allocation(A,C) = \underbrace{\frac{1}{3}}_{KnotenB} + \underbrace{\frac{1}{3}}_{KnotenD} = \frac{2}{3}$$

$$resource_allocation(A,F) = \underbrace{\frac{1}{3}}_{KnotenE} = \frac{1}{3}$$

12.1.5 Adamic-Adar

Diese Metrik berechnet sich fast genau gleich wie *Resource Allocation*. Der einzige Unterschied ist, dass das Gewicht des Nenners abgeschwächt wird, indem da der Logarithmus verwendet wird:

$$adamic_adar(X,Y) = \sum_{u \in N(X) \cap N(Y)} \frac{1}{\ln(\mid N(u) \mid)} \tag{12.5}$$

Hier ein paar Beispiele zur Berechnung der *Adamic-Adar* Metrik für den Knoten A, wobei schlussendlich wieder der Knoten C als nächster direkter Nachbar vorgeschlagen wird, da dieser den grössten Wert aufweist:

$$adamic_adar(A,C) = \underbrace{\frac{1}{\ln(3)}}_{KnotenB} + \underbrace{\frac{1}{\ln(3)}}_{KnotenD} = 1.82$$

$$adamic_adar(A,F) = \underbrace{\frac{1}{\ln(3)}}_{KnotenE} = 0.91$$

12.1.6 Preferential Attachment

Die Grundannahme bei *Preferential Attachment* ist, dass die Wahrscheinlichkeit, dass ein Knoten von einer neu hinzugefügten Kante betroffen ist, sich gerade proportional zu dessen Anzahl Nachbarn verhält. Umso mehr Nachbarn ein Knoten hat, desto grösser ist die Wahrscheinlichkeit, dass dieser betroffen ist.

Preferential Attachment lässt sich sehr einfach berechnen. Dazu werden die Anzahl Nachbarn beider Knoten miteinander multipliziert:

$$preferential_attachment(X,Y) = \mid N(X) \mid \cdot \mid N(Y) \mid \tag{12.6}$$

In unserem Beispielgraphen berechnet sich *Preferential Attachment* wie folgt:

$$preferential_attachment(A,C) = 3 \cdot 3 = 9$$

$$preferential_attachment(A,G) = 3 \cdot 4 = 12$$

Somit würde der *Preferential Attachment* Algorithmus eine Kante zwischen den Knoten A und G vor einer Kante zwischen A und C vorhersagen.

12.1.7 Weitere Algorithmen

Dies war natürlich nur ein Bruchteil aller bisher veröffentlichten Algorithmen zur Vorhersage der nächsten Kanten. In [LNK07] sind noch weitere Algorithmen aufgelistet, welche nicht nur auf Nachbarschaftsinformationen beruhen, sondern auch beispielsweise die Distanzen zwischen zwei Knoten berücksichtigen.

Interessant sind auch die Ansätze von Sucheta Soundarajan und John Hopcroft. Diese haben die vorgestellten Algorithmen *Common Neighbours* und *Resoruce Allocation* so erweitert, dass einem Knotenpaar zusätzlich ein Bonus verrechnet wird, wenn sich beide Knoten in derselben Community befinden.

12.2 Link-Prediction Experiment und Evaluation

Die Wahl des richtigen Link-Prediction Algorithmus für die individuellen Anwendungsfälle ist nicht einfach und lässt sich ohne Evaluation nur erahnen. Deshalb empfiehlt

es sich, für jeden Anwendungsfall verschiedene Link-Prediction Algorithmen zu evaluieren. In der Publikation *The Link Prediction Problem for Social Networks* [LNK07] wurde ein solches Experiment durchgeführt und verschiedene Link-Prediction Algorithmen auf unterschiedlichen Netzwerken evaluiert. Dieser Versuch wird im Anschluss genauer beschrieben.

Unter der Domain `http://www.arxiv.org` können Wissenschaftliche Publikationen verschiedener Bereiche veröffentlicht werden. An einer Publikation arbeiten meistens mehrere Personen gemeinsam und somit lässt sich dies als Two-Mode Netzwerk (Publikation <-> Autor) abbilden und dann schlussendlich in ein One-Mode Netzwerk transformieren. In diesem Fall wird auch von einem sogenannten *Co-Authorship* Netzwerk gesprochen. Für das Experiment wurden die Co-Authorship Netzwerke aus fünf Bereichen verwendet:

astro-ph Astrophysics

cond-mat Condensed matter

gr-qc General relativity and quantum cosmology

hep-ph High Energy Physics - phenomenology

hep-th High energy physics - theory

Von all diesen Bereichen wurden jeweils zwei Netzwerke extrahiert:

Trainings-Netzwerk Es wurden alle Veröffentlichungen in den Jahren 1994, 1995 und 1996 berücksichtigt, um einen sogenannten Trainings-Datensatz für die Link-Prediction Algorithmen zu erstellen. Dieses Netzwerk wird von den Algorithmen als *Ausgangslage* verwendet, um die zukünftigen Beziehungen (in diesem Fall Zusammenarbeiten von Wissenschaftlern) vorherzusagen.

Test-Netzwerk Hier wurden alle Veröffentlichungen aus den Jahren 1997, 1998 und 1999 eingesammelt. Damit lässt sich dann prüfen, wie korrekt die Vorhersagen der einzelnen Algorithmen waren. (Wie dies im Detail passiert wird später beschrieben)

Aus den entstandenen Netzwerken wurde zusätzlich der Kern (Core) extrahiert. Der Kern besteht aus aktiven Wissenschaftlern, von welchen mindestens 3 Veröffentlichungen im Trainings-Zeitraum sowie auch 3 Veröffentlichungen im Test-Zeitraum existieren. Dann wurde untersucht, wie viele Kanten zwischen den Autoren des Kern-Netzwerks im Trainings-Netzwerk ($| E_{old} |$) und wie viele im Test-Netzwerk ($| E_{new} |$) neu entstanden sind. Die genauen Zahlen sind der Abbildung 12.2 ersichtlich:

	training period			Core		
	authors	papers	edges	authors	$\|E_{old}\|$	$\|E_{new}\|$
astro-ph	5343	5816	41852	1561	6178	5751
cond-mat	5469	6700	19881	1253	1899	1150
gr-qc	2122	3287	5724	486	519	400
hep-ph	5414	10254	17806	1790	6654	3294
hep-th	5241	9498	15842	1438	2311	1576

Abbildung 12.2: Grösse der Trainings-Netzwerke sowie der jeweiligen Kerne

Die Evaluation aller Netzwerke und für jeden Algorithmus wurde gleich ausgeführt. Die Vorgehensweise wird hier an einem Beispiel (1 Algorithmus, 1 Netzwerk) aufgezeigt:

1. Dem Link-Prediction Algorithmus wurde das komplette Trainings-Netzwerk als Input gegeben und dessen Vorhersagen absteigend sortiert, so dass die wahrscheinlichste Kante (anhand des Algorithmus) zuerst genannt wurde.

2. Von den vorhergesagten Kanten werden nur diejenigen beibehalten, welche zwei Autoren des Kerns (Core) miteinander verbinden. Die absteigende Reihenfolge der Liste bleibt bestehen.

3. Nun werden die ersten $\mid E_{new} \mid$ (E_{new} ist das Set mit den neu hinzugekommenen Kollaborationen im Test-Netzwerk zwischen Autoren des Kerns) Einträge der Vorhersage genommen und geprüft, wie gross die Übereinstimmung der vorhergesagten Kanten der Wissenschaftler im Kern-Netzwerk mit den tatsächlich neuen erschienen Kanten im Test-Netzwerk ist.

Ein Ausschnitt der Resultate sind in der Abbildung 12.3 ersichtlich:

predictor	astro-ph	cond-mat	gr-qc	hep-ph	hep-th
probability that a random prediction is correct	0.475%	0.147%	0.341%	0.207%	0.153%
graph distance (all distance-two pairs)	*9.6*	*25.3*	*21.4*	*12.2*	*29.2*
common neighbors	**18.0**	**41.1**	**27.2**	**27.0**	**47.2**
preferential attachment	4.7	6.1	7.6	*15.2*	7.5
Adamic/Adar	*16.8*	**54.8**	**30.1**	**33.3**	**50.5**
Jaccard	*16.4*	**42.3**	19.9	**27.7**	*41.7*

Abbildung 12.3: Tabellarische Darstellung der Resultate der Link-Prediction Evaluation. Die Zahlen geben jeweils an, um welchen Faktor die Vorhersagen des Algorithmus beim jeweiligen Netzwerk zutreffender waren als eine zufällige Vorhersage (ersichtlich in der ersten Zeile). Fett geschriebene Zahlen heben Resultate hervor, welche mindestens so gut waren, wie der *Common Neighbours* Algorithmus.

In Abbildung 12.4 sind die Resultate für alle Algorithmen grafisch ersichtlich. Als Baseline wurde hier der *Common Neighbours* Algorithmus verwendet und die anderen Algorithmen relativ zu dessen Resultate gemessen:

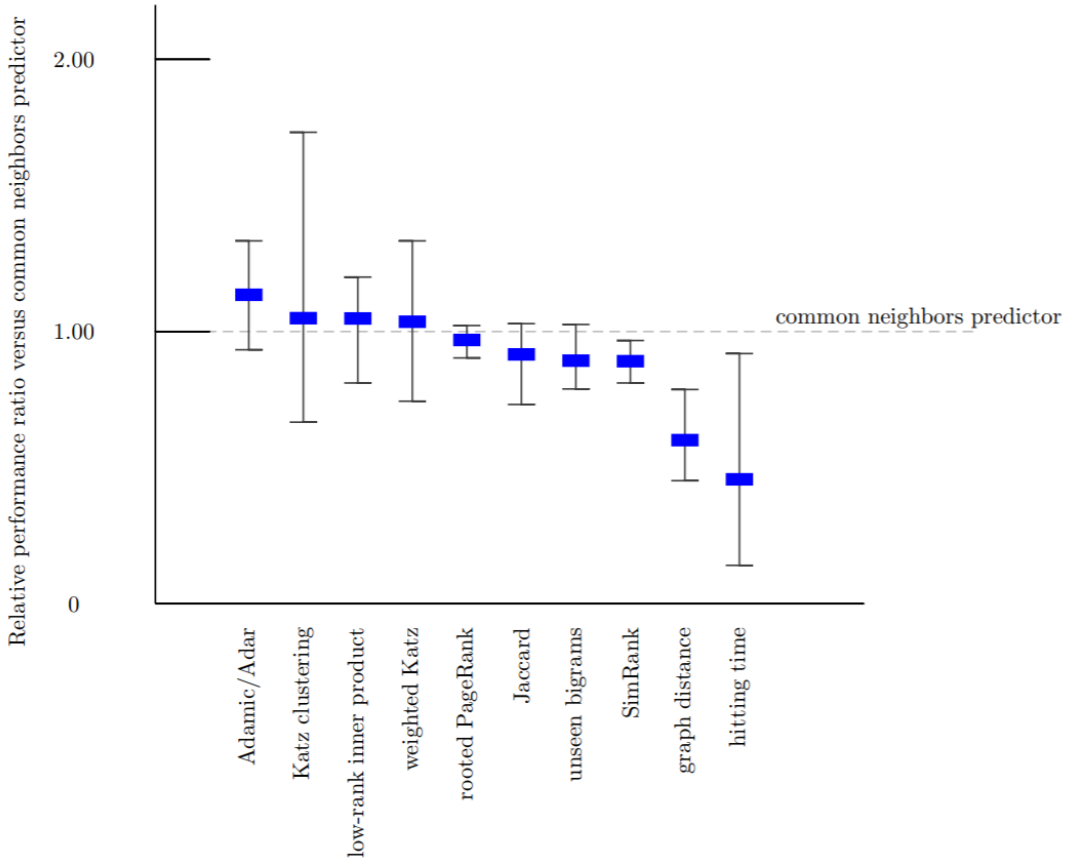


Abbildung 12.4: Grafischer Vergleich verschiedener Link-Prediction Algorithmen auf den 5 Netzwerken. Blau abgebildet ist die durchschnittliche Performance, die *Whiskers* zeigen das Minimum und das Maximum.

Es ist interessant zu sehen, dass ein eher simpler Ansatz wie der *Common Neighbours* oder der *Adamic-Adar* Algorithmus bereits eine sehr gute Performance liefert.

Aber es ist auch zu berücksichtigen, dass die Resultate jetzt für diesen Fall so aussehen. Dies kann in einem anderen Anwendungsfall komplett anders aussehen. Deshalb ist es wichtig, bei einem anderen Anwendungsfall verschiedene Algorithmen zu evaluieren und den passendsten zu wählen. Die detaillierten Ausführungen in diesem Abschnitt sollen dazu dienen, dass eine Evaluation nun selbständig durchgeführt werden kann. Natürlich ist auch die Wahl der Evaluations-Metrik situationsspezifisch zu wählen.

Kapitel 13

Diffusion

Diffusion bezeichnet den *Prozess von Informations- oder Wissensverbreitung über Interaktionen*. Dies geschieht über einen initialen Sender (resp. kleine Gruppe von Sendern) zu den schlussendlichen Empfängern. Vor allem Werbe-Kampagnen zielen darauf ab, dass möglichst viele Zielpersonen mit der Werbung in Kontakt kommen. Kurz nach der Erscheinung des Computerspiels „GTA 5“ wurde der Kurzmitteilungsportal Twitter nach weitergeleiteten Nachrichten (sogenannte „Re-Tweets“) mit dem Inhalt „GTA 5“ durchsucht und als Netzwerk modelliert[1]. Ein Ausschnitt aus diesem Netzwerk ist in Abbildung 13.1 sichtbar:

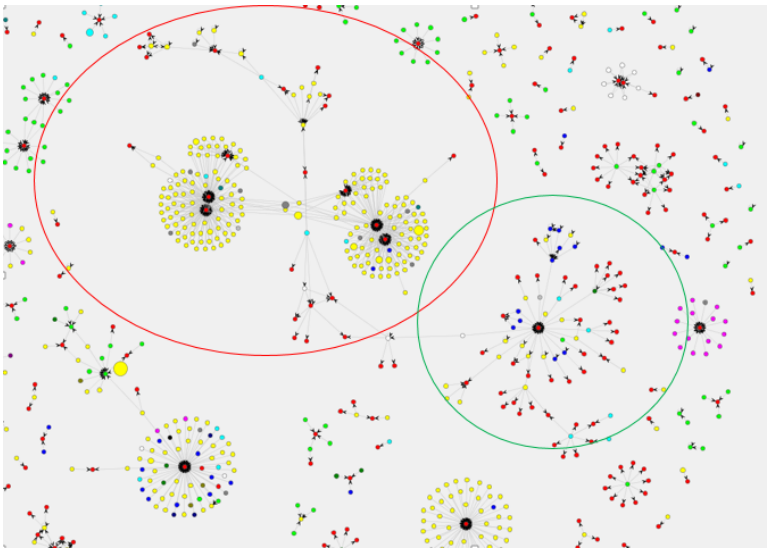


Abbildung 13.1: Retweet-Netzwerk zum Suchbegriff „GTA 5“ mit zwei zusammenhängenden Netzwerken (eingekreist)

Sofort stechen die beiden zusammenhängenden Teil-Netzwerke ins Auge. Das Zentrum im grünen Kreis ist Youtube. Beim Teilen von Youtube-Videos auf Twitter geht der Retweet auf dessen Konto. Für dieses Kapitel ist jedoch das rot eingekreiste Teilnetzwerk interessanter, weil es sehr weitreichend ist und viele Knoten resp. ganze Teile

[1] Der Knoten von „Rockstar Games“ wurde entfernt, da dieser mit Abstand am meisten weitergeleitet („retweetet“) wurde. Dies jedoch nur von einzelnen Personen.

des gesamten Netzwerks miteinander verbindet. Bei allen Retweets innerhalb des roten Kreises handelt es sich um denselben Tweet. Leider ist der genaue Wortlaut nicht mehr vorhanden. Jedoch hat eine Firma ein Gewinnspiel gestartet, indem eine XBox + GTA 5 gewonnen werden konnte. Die Teilnahmebedingung war, dass der Tweet dieser Firma weitergeleitet wurde. Dies hat dazu geführt, dass sich dieser weitreichend im Netzwerk verbreitet hat und ist ein schönes Beispiel für Diffusion.

Diese Art von Verbreitung lässt sich inzwischen häufig in den Sozialen Medien beobachten. Der amerikanische Soziologe Everett Rogers hat seine Theorie über Innovations-Diffusion in einem Buch veröffentlicht [Rog10] (die erste Auflage davon erschien im Jahre 1962). Er definiert Innovation als *Idee / Objekt, welches beim Adopter neuartig ist.* Er teilt die Übernahme (Adoption) von Innovationen in vier Schritte ein:

Bewusstheit Einer Person wird bewusst, dass das Produkt existiert. Sie hat jedoch nur sehr wenig Informationen darüber.

Interesse Die Person hat Interesse am Produkt und informiert sich.

Evaluation Die Person spielt die Adoption gedanklich durch und entscheidet sich, ob ein Versuch gewagt werden soll.

Trial Das Produkt wird getestet

Adoption Die Person entscheidet sich definitiv und übernimmt das Produkt.

Bei Innovationen erfolgt die Verbreitung immer nach dem gleichen Muster. Rogers hat die Personen anhand des Adoptionsverhaltens in 5 Gruppen eingeteilt[2]:

Innovators (top 2.5%) Diese Gruppe sind die ersten, welche eine Innovation übernehmen. Sie sind meistens jung, risikofreudig und in höheren sozialen Schichten angesiedelt. Sie haben häufig Kontakt zu Wissenschaftlichen Ressourcen und sind mit anderen Mitgliedern dieser Gruppe gut verbunden.

Early Adopters (13.5%) Diese Gruppe umfasst die zweitschnellsten Adoptoren. Sie sind meistens jung, gut ausgebildet und haben einen hohen sozialen Status. Im Unterschied zu den Innovators wählen sie ihre Adoptionen bedachter, um den zentralen sozialen Status zu wahren. Sie gelten zusätzlich als grösste *Opinion Leader*[3] Kategorie.

Early Majority (34 %) Personen in dieser Kategorie übernehmen eine Innovation nach einer gewissen Zeit. Sie verlangsamen den ganzen Adoptions-Prozess. Ihr sozialer Status ist meistens durchschnittlich und sie haben Kontakt zu Early Adopters.

Late Majority (34%) Diese Gruppe von Personen ist sehr skeptisch und übernehmen eine Innovation erst nach der Durchschnittsperson. Normalerweise haben sie einen durchschnittlichen sozialen Status und verfügen über geringere finanzielle Mittel.

[2] 5 Adopter Kategorien nach Rogers, `https://ondigitalmarketing.com/learn/odm/foundations/5-customer-segments-technology-adoption/`, [03.08.2017]

[3] Leute mit grossem Interesse an einer bestimmten Angelegenheit, die sich auch gerne dazu äussern

Laggards (16%) Hier befinden sich die zurückhaltendsten Personen. Sie sind eher traditionell veranlagt und mögen keine Veränderungen. Sie sind meistens älter und haben einen tiefen, sozialen Status. Sie stehen nur mit der Familie und engen Freunden in Kontakt.

Die Abbildung 13.2 zeigt die Normalverteilung der einzelnen Gruppen (blau). Zusätzlich zeigt die gelbe Kurve die kumulative Anzahl Adoptoren über die Zeit. Diese hat einen typischen S-Kurvenverlauf:

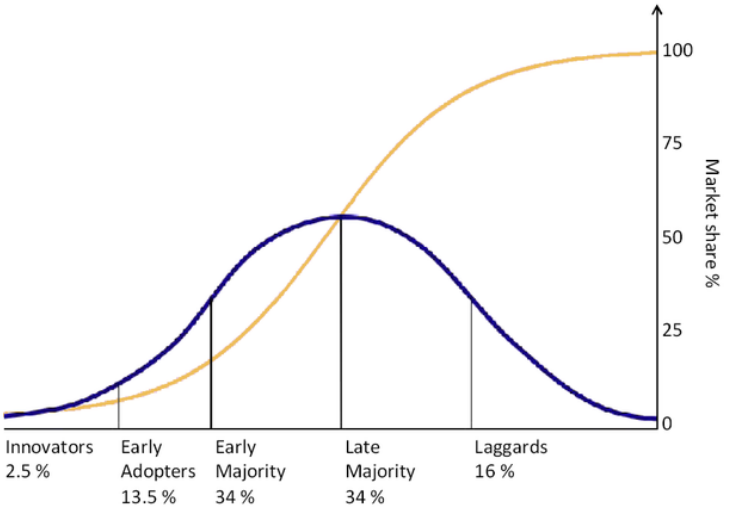


Abbildung 13.2: 5 Adopter Kategorien nach Rogers. Quelle: Siehe Fußnote 2

Ein anderes, bekanntes Beispiel von Informations-Diffusion ist aus dem Jahr 2013. Während des Superbowls gab es einen 34-minütigen Stromausfall[4]. Der Hersteller der Oreo-Kekse twitterte damals: „*Power out? No Problem, You can still dunk it in the dark.*“. Dieser Tweet verbreitete sich wie ein Lauffeuer. Er wurde sagenhafte 15'000-mal Retweetet und bescherte dem Hersteller zusätzliche 20'000 Likes auf Facebook in zwei Tagen. Der Hype um den Superbowl wurde perfekt ausgenutzt[5]. Eine 30 Sekunden lange Werbung während des Superbowls kostete damals noch 4 Millionen US Dollar (2017 bereits 5 Millionen US Dollar).

Bei der Modellierung des Diffusion Prozesses werden unterschiedliche Aspekte berücksichtigt: Ein Aspekt ist, ob eine Person unabhängig oder abhängig von anderen reagiert. Reagiert eine Person abhängig ist interessant zu wissen, in welchem Mass und von welchem Teil des Netzwerkes sie abhängig reagiert. Von einer **lokalen Abhängigkeit** wird gesprochen, wenn nur die direkten Nachbarsknoten berücksichtigt werden. Eine **globale Abhängigkeit** berücksichtigt alle Personen im Netzwerk. Ein anderer Aspekt ist, ob noch Faktoren ausserhalb des Netzwerks Einfluss auf die Verbreitung haben, und falls ja wie stark.

In den nachfolgenden Abschnitten wird auf verschiedene Diffusion-Modelle eingegangen. Beim Independent Cascade Model wird zudem der Ansatz des Greedy-Verfahrens

[4]Stromausfall während des Superbowls 2013, [https://www.wired.com/2013/02/oreo-twitter-super-bowl/,[04.08.2017]

[5]Ein 15 köpfiges Social Media Team war bereit, um auf das Geschehen des Superbowls zu reagieren.

gezeigt, um eine möglichst maximale Ausbreitung zu erreichen. Ein solcher Greedy-Ansatz kann natürlich auch bei den anderen Diffusion-Modellen angewendet werden. Neben den beschriebenen Verfahren gibt es noch viele weitere Algorithmen, um Diffusionsprozesse zu modellieren.

13.1 Independent Cascade Model (ICM)

Das ICM wurde 2003 und 2015 von David Kempe in der wissenschaftlichen Publikation [KKT15] vorgestellt und modelliert die Informationsübertragung über direkte Verknüpfungen zu den Nachbarsknoten. Das Modell basiert auf den folgenden Annahmen:

- Ein Knoten kann nur direkte Nachbarsknoten beeinflussen (Kantenrichtung bei gerichteten Graphen beachten.)
- Knoten können nur *aktiv* oder *inaktiv* sein. Aktiv bedeutet, dass er das Verhalten / Idee / Entscheidung übernommen hat.
- Ein aktivierter Knoten hat genau einmal die Möglichkeit, direkte Nachbarsknoten zu aktivieren (und nicht bei jeder Iteration erneut).
- Knoten können nur von inaktiv zu aktiv wechseln, aber nicht umgekehrt.

Im ICM wird von Sendern (aktivierte Knoten) und Empfängern (noch nicht aktivierte Knoten) gesprochen. Der Algorithmus funktioniert wie folgt:

1. Initial vorhanden ist
   - Ein Netzwerk
   - Jede Kante hat ein Attribut p. Dieses Attribut beschreibt, wie gross die Wahrscheinlichkeit ist, dass der Knoten das Verhalten vom Nachbarn übernimmt.
   - Ein Set A von Knoten, die initial aktiviert sind.
2. Nun wird für jeden Knoten im Set A $i_0, i_1...$ für alle Nachbarsknoten $j_0, j_1...$, die noch nicht aktiviert wurden, eine Zufallszahl r zwischen 0 und 1 berechnet. Ist die Zufallszahl r kleiner als die Wahrscheinlichkeit $p_{i,j}$ (Attribut der Kante zwischen dem Knoten und dem Nachbarsknoten), wird der Nachbarsknoten aktiviert. Der Nachbarsknoten wird in das Set A_{Neu} aufgenommen.
3. Sollte das Set A_{Neu} leer sein, ist der Algorithmus beendet. Ansonsten wird das Set A durch A_{Neu} ersetzt und wieder bei Punkt 2. fortgefahren. Jeder Knoten hat bei diesem Modell also nur genau einmal die Möglichkeit, seine Nachbarn zu aktivieren.

Ein Beispiel des ICM-Diffusionsprozesses ist in der Abbildung 13.3 (entnommen aus [ZAL14, 189]) ersichtlich:

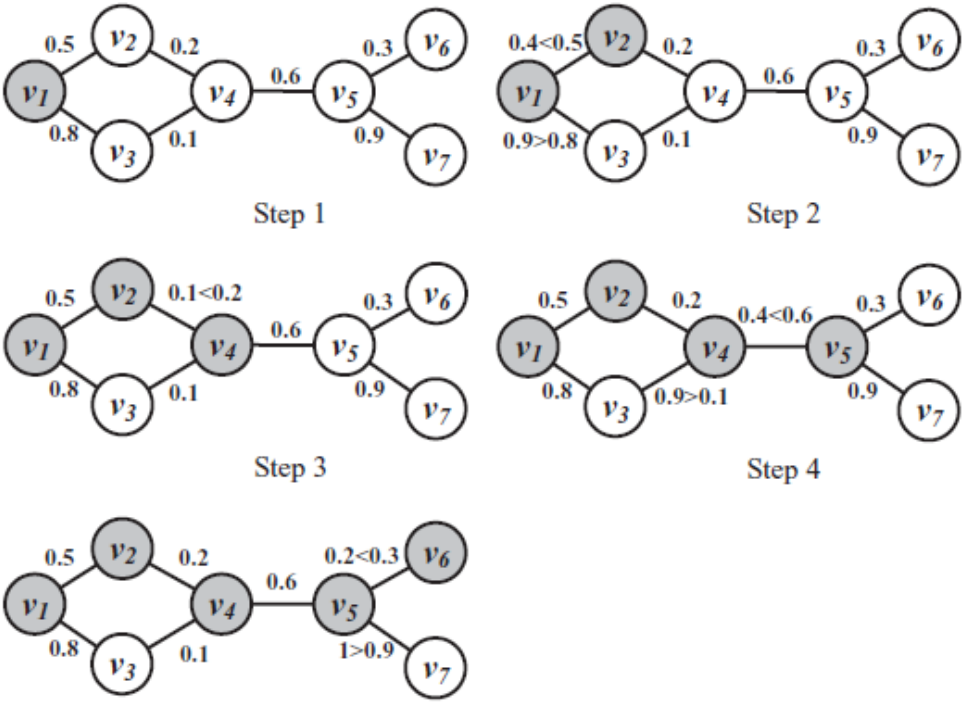


Abbildung 13.3: ICM-Diffusionsprozess in einem Netzwerk

Eine ausstehende Frage ist noch, wie die Wahrscheinlichkeiten p der Knoten zu definieren ist. Der Vorschlag in der Publikation [KKT15] war Zufallszahlen zu verwenden. Es wären jedoch auch Alternativen denkbar; nur schon, weil gewisse Personen mehr Einfluss ausüben können (z.B: langjährige Freunde) als andere (z.B. flüchtige Bekannte). Möglicherweise können frühere Diffusionen (falls vorhanden) als Grundlage verwendet werden. Eine naheliegende Möglichkeit ist die Ähnlichkeit zwischen Knoten mit Hilfe einer Assortativity-Metrik (Bestimmt Ähnlichkeit zwischen zwei Knoten)[6] zu berechnen.

Ausbreitung maximieren

Normalerweise soll die Information oder Werbung möglichst viele Personen im Netzwerk erreichen. Jedoch ist das Budget begrenzt, weshalb nur eine bestimmte Anzahl Knoten initial aktiviert werden kann.

S bezeichnet initiale Set der aktivierten Knoten (seed list). Zusätzlich wird die Funktion $f(S)$ definiert, die besagt, wie viele Knoten nach Beendung des Algorithmus aktiviert wurden für die in S festgelegten initialen Knoten. In der Abbildung 13.3 ist $|S|= 1$ und $f(S) = 5$. Gegeben ist eine Zahl k, welche die initiale Anzahl Knoten in S definiert. Nun geht es darum, diejenigen k Knoten in S zu haben, damit $f(S)$ möglichst maximal ist, sprich, dass wir mit den k initialen Knoten eine möglichst grosse Ausbreitung erreichen.

In diesem Abschnitt wird ein Algorithmus aus derselben Quelle wie oben vorgestellt,

[6] Wikipedia-Artikel zu Assortativity, `https://en.wikipedia.org/wiki/Assortativity`, [03.08.2017]

welcher das Problem angeht. Es wurde bewusst nicht der Begriff „löst“ verwendet, denn das Problem ist NP-hart, was bedeutet, dass es sich vermutlich nicht effizient lösen lässt. Der hier vorgestellte Algorithmus gehört zu der Gruppe „Greedy Algorithmus“. Diese Klasse von Algorithmen erarbeitet das Resultat schrittweise. Es wird jeweils der Folgezustand gewählt, welcher den *grössten Gewinn verspricht*.[7].

Damit dies mit dem ICM-Algorithmus aus dem vorherigen Abschnitt funktioniert, ist eine kleine Anpassung notwendig. Momentan werden die Zufallszahlen bei jedem Durchlauf neu berechnet. Der Greedy-Algorithmus berechnet die Ausbreitung für einen Knoten mehrmals und deshalb ist es erforderlich, dass sich die Ausbreitung nicht bei jedem Durchlauf ändern kann. Dazu wird die Berechnung der Zufallszahl für jede Kante ebenfalls im Initialisierungs-Schritt ausgeführt und abgespeichert.

Der Algorithmus wird zuerst kurz abstrakt erklärt und im Anschluss anhand eines Beispiels veranschaulicht.

1. Gegeben sind:
   - Ein Netzwerk
   - Alle Elemente für die Aktivierungsfunktion. Referenziert auf das obige Beispiel wären das die Adoptions-Wahrscheinlichkeiten $p_{i,j}$ für alle Kanten. Zusätzlich braucht es noch für alle Kanten eine Zufallszahl $r_{i,j}$ zwischen 0 und 1.
   - Set S (initial aktivierte Knoten), welches zu Beginn leer ist.
   - Zahl k (Anzahl Knoten in S (= Menge der initial aktivierten Knoten))
   - Zähler i, der die Durchläufe zählt
2. Solange $i < k$ ist:
   2.1. Berechne für alle Knoten v im Netzwerk, die noch nicht in S sind, die schlussendliche Ausbreitung, wenn diese in das initiale Set aufgenommen werden würden, also $f(S \cup v)$.
   2.2. Nehme denjenigen Knoten, für welchen $f(S \cup v)$ am grössten ist, in S auf. (Gibt es mehrere mit gleichem maximalem Wert, dann kann ein beliebiger davon gewählt werden.)
   2.3. Erhöhe den Schleifenzähler i um 1.
3. Gebe das berechnete Start-Set S zurück.

Das nachfolgende Beispiel stammt von [ZAL14, 191]. Gegeben ist ein Graph mit sechs nummerierten Knoten, gerichteten Kanten und einer Aktivierungsfunktion: $|i - j| \equiv 2 \ (mod\ 3)$. Ziel ist, für $k = 2$ diejenigen zwei Knoten zu finden, mit denen eine maximale Ausbreitung erreicht wird.

[7] Diese Klasse von Algorithmen sind normalerweise sehr schnell, lösen das Problem aber nicht optimal.

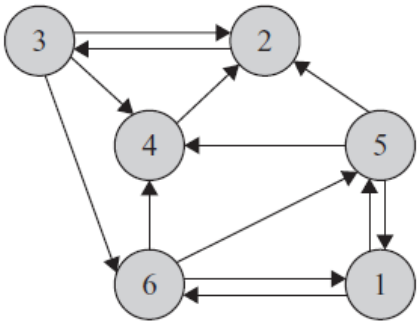


Abbildung 13.4: Information Cascade Maximierung Beispielgraph

Initial gegeben ist:

- Netzwerk (siehe Abbildung 13.4)
- $S = \{\}$
- $i = 0$
- $k = 2$

Da sich zu Beginn noch keine Knoten in S befinden, muss für alle Knoten v einzeln die schlussendliche Ausbreitung $f(v)$ berechnet werden. Es wird mit Knoten 1 begonnen, welcher eine direkte Verbindung zu den Knoten 5 und 6 hat. Deshalb werden zum Zeitpunkt $t = 0$ die beiden Knoten mit der Aktivierungsfunktion überprüft:

$$|1 - 6| \equiv 2(mod 3)$$

$$|1 - 5| \not\equiv 2(mod 3)$$

Zum Zeitpunkt $t = 1$ kann der neu aktivierte Knoten 6 andere Knoten aktivieren (1 kann dies nicht mehr). Der Knoten 6 hat ausgehende Verbindungen zu den Knoten 4 und 5:

$$|6 - 4| \equiv 2(mod 3)$$

$$|6 - 5| \not\equiv 2(mod 3)$$

Somit wird zum Zeitpunkt $t = 2$ der Knoten 4 aktiviert. Dieser hat einen Link zu Knoten 2, und weil $|4 - 2| \equiv 2(mod 3)$ ergibt, wird dieser Aktiviert. Der Knoten 2 kann jedoch keine weiteren Knoten mehr aktivieren. Deshalb ist $f(1) = 4$. Dies wird nun ebenfalls genau gleich für die restlichen Knoten einzeln berechnet. Es entsteht das folgende Resultat: $f(1) = 4$, $f(2) = 1$, $f(3) = 1$, $f(4) = 2$, $f(5) = 1$, $f(6) = 4$. Somit können der Knoten 1 oder 6 in das Start-Set S aufgenommen werden, weil diese zum aktuellen Zeitpunkt die „grössten Erfolgsaussichten“ nach dem Greedy-Algorithmus Prinzip versprechen. Wir nehmen die 6 in unser Start-Set auf, somit ist $S = \{6\}$. Laut Algorithmus müssten wir jetzt beim nächsten Durchlauf alle Knoten berechnen, die nicht in S sind, sprich 1 bis 5. Die verwendete Aktivierungs-Funktion erlaubt uns jedoch

eine Abkürzung, da die Aufnahme von Knoten in das Startset, welche auch von der 6 aktiviert werden können, zum gleichen Resultat führen. Deshalb entspricht $f(6,1) = f(6,2) = f(6,4) = f(6) = 4$. Aus diesem Grund können wir uns auf die übrigbleibenden zwei Knoten 3 und 5 konzentrieren. Es werden also die Reichweiten $f(6,3)$ und $f(6,5)$ berechnet und dies ergibt in beiden Fällen 5. Wir wählen wieder zufällig einen Knoten, in diesem Fall der Knoten 3. $|S|$ ist nun 2, weshalb der Algorithmus beendet wird und $S = \{6,3\}$ mit $f(S) = 5$ zurückgegeben wird.

Intervention

Um eine solche Ausbreitung in sozialen Medien zu unterbinden, gibt es in Theorie folgende Möglichkeiten (auf die man jedoch nicht beliebig Einfluss hat):

1. Die ausgehenden Kanten von Sendern reduzieren
2. Die eingehenden Kanten von Empfängern reduzieren
3. Reduktion der Aktivierungs-Wahrscheinlichkeit.

13.2 Voter Model

Das Voter Model ist ein sehr einfaches Model. Jeder Knoten hat initial einen Wert (± 1), ob die Meinung übernommen wurde (+1) oder nicht (-1). Nun wird in einem iterativen Prozess pro Durchgang ein zufälliger Knoten ausgesucht, welcher dann die Meinung eines zufälligen Nachbarn übernimmt. Dieser Prozess wird so lange ausgeführt, bis sich alle auf einen Konsens einigen. Die Wahrscheinlichkeit, dass schlussendlich alle Knoten den Wert 1 annehmen, entspricht dem relativen Anteil der Knoten, die den Wert 1 angenommen haben.

13.3 Threshold Model

Beim Threshold Model hat es zu Beginn eine kleine Menge von Knoten, welche eine Meinung bereits übernommen haben / infiziert sind. Jeder Knoten im Netzwerk hat einen eigenen Schwellwert, der definiert, welcher Anteil seiner Nachbarn eine Meinung übernommen haben müssen, damit sich dieser ebenfalls dem Gruppendruck nachgibt und die Meinung übernimmt. Nun wird bei jeder Iteration für alle Knoten, welche die Meinung noch nicht übernommen haben, geprüft, ob der relative Anteil der Nachbarn mit der entsprechenden Meinung den persönlichen Schwellwert übertrifft. Falls ja, übernimmt der Knoten die Meinung ebenfalls. Dieser Prozess wird so lange ausgeführt, bis eine festgelegte Anzahl Iterationen durchlaufen wurden oder es in einer Iteration zu keinen Anpassungen mehr kommt.

Kapitel 14

Graphlets

Bei *Graphlets* handelt es sich um kleine, verbundene Subgraphen in einem typischen Umfang von 2 bis 5 Knoten. Ursprünglich kommt das Konzept aus Biologischen Netzwerken, um beispielsweise die Interaktionen von Proteinen zu untersuchen[MP08]. Das Konzept lässt sich jedoch viel generischer anwenden. Es kann dazu verwendet werden, um die *Strukturelle Ähnlichkeit* (Structural Equivalence) von Knoten oder kompletter Netzwerke zu untersuchen. So können beispielsweise Gruppen von Knoten in einem Netzwerk ausfindig gemacht werden, welche sich zwar an komplett unterschiedlichen Positionen befinden, aber ähnliche lokale Verbindungsmuster aufweisen.

Zusätzlich zur Definition der Graphlets gibt es noch die Definition von *Oribts*. Orbits sind *eindeutige, äquivalente Positionen* von Knoten ein einem Graphlet.

In der Abbildung 14.1 aus [Prz07] ist das Konzept von Graphlets und Orbits schön veranschaulicht. Für die Subgraph-Grösse von 2 bis 5 Knoten sind alle Graphlets abgebildet. Dabei handelt es sich um alle eindeutigen Kombinationen, wie die entsprechende Anzahl Knoten miteinander verbunden werden können. Die Graphlets sind mit G_0 bis G_{29} notiert. Beispielsweise gibt es beim *2-node Graphlet* G_0 nur eine Möglichkeit, wie zwei Knoten verbunden werden können. Bei den *3-node Graphlets* gibt es jedoch schon zwei Kombinationen, wie 3 Knoten miteinander verbunden sein können. Entweder wie bei G_1, wo zwischen den 3 Knoten 2 Kanten bestehen oder wie bei G_2, wo alle Knoten miteinander verbunden sind. Umso mehr Knoten das Graphlet beinhaltet, desto exponentiell umfangreicher werden die Anzahl der Graphlets.

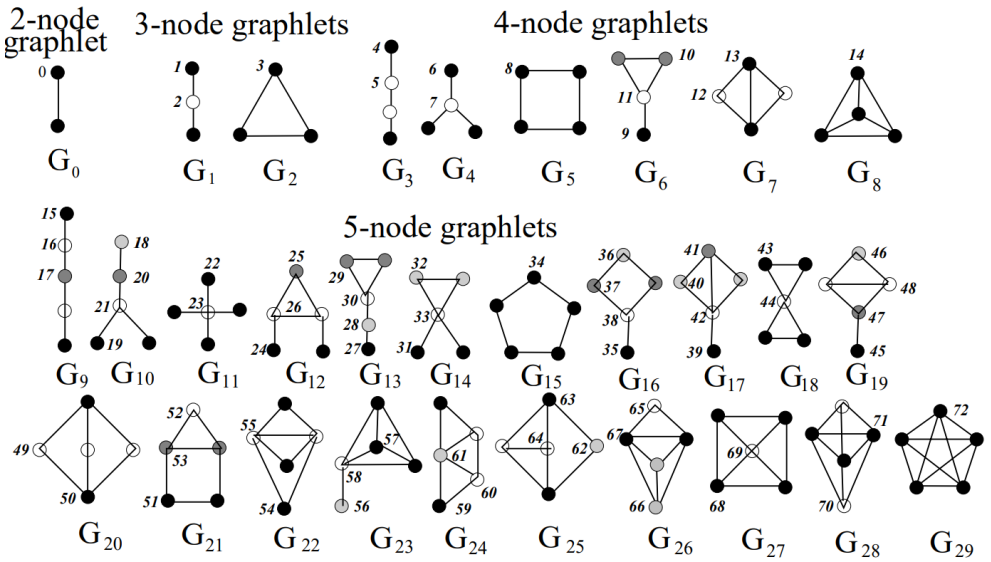


Abbildung 14.1: Graphlets und Orbits von Subgraphen der Grösse von 2 bis 5 Knoten.

Beim genaueren Blick auf die Graphlets in der Abbildung 14.1 ist erkennbar, das gewisse Knoten in den Graphlets nummeriert sind, insgesamt von 0 bis 72. Genau genommen erhält ein Knoten jeder Farbe (schwarz, weiss, hellgrau, dunkelgrau) in jedem Graphlet jeweils eine eindeutige Zahl. Es handelt sich dabei um die Orbits. Die Knoten der gleichen Farbe eines Graphlets haben die selbe Orbit-Nummer, weil sie strukturell gesehen gleich sind. Beispielsweies beim Graphlet G_0 sind beide Knoten schwarz gefärbt und haben die Nummer 0. Die Position lässt sich interpretieren als *ein Knoten, welcher direkt mit einem anderen Knoten verbunden ist.* Dies ist für beide Positionen (oben und unten) gleich, weshalb alle Knoten die gleiche Farbe und somit die gleiche Nummer haben. Beim Graphen G_2 der Gruppe 3-Node Graphlets haben ebenfalls alle die selbe Farbe und somit die gleiche Position. Jeder Knoten ist mit den anderen beiden Knoten verbunden, die wieder untereinander verbunden sind. Anders sieht es beim 3-Node Graphlet G_1 aus. Hier gibt es zwei unterschiedliche Knotenfarben. Die beiden Enden sind schwarz eingefärbt und mit der Nummer 1 versehen. Diese sind jeweils *mit einem Knoten verbunden, der mit dem dritten Knoten verbunden ist, ohne dass der Knoten selbst eine direkte Verbindung zu diesem hat.* Der weisse Knoten, nummeriert mit einer 2, ist der Knoten in diesem 3-Node Graphlet, welcher mit beiden anderen Knoten verbunden ist, die jedoch nicht miteinander verbunden sind. Insgesamt hat es in den 30 Graphlets 73 unterschiedliche Orbits.

Nachteilig von Graphlets ist, dass deren Berechnung sehr aufwändig ist und deshalb in grossen Netzwerken oder einer grossen Graphlet-Knotenanzahl aufgrund der kombinatorischen Explosion von Knotenanordnungen nicht praktikabel ist.

14.1 Relative Graphlet Frequency Distance

Mit der *Relative Graphlet Frequency Distance* lässt sich die strukturelle Ähnlichkeit von Netzwerken anhand der Graphlets, unabhängig der Anzahl Knoten und Kanten, berechnen. Dazu werden die Graphlets G_1 bis G_{29} verwendet. Das 2-Node Graphlet

wird ignoriert.

Für die Berechnung wird die Gesamtzahl der Graphlets im Netzwerk benötigt, da schlussendlich eine Normalisierung stattfindet:

$$T(G) = \sum_{i=1}^{29} N_i(G) \tag{14.1}$$

wobei die einzelnen Elemente die folgende Bedeutung haben:

$T(G)$: Totale Anzahl der Graphlets im Netzwerk G

$\sum_{i=1}^{29}$: Iteration und Aufsummierung der Resultate über alle Graphlets der Nummern 1 bis 29

$N_i(G)$: Anzahl der Graphlets mit der Nummer i im Netzwerk

Die Distanz zwischen zwei Netzwerken berechnet sich wie folgt:

$$D(G,H) = \sum_{i=1}^{29} |F_i(G) - F_i(H)| \tag{14.2}$$

$$F_i(G) = -\log\left(\frac{N_i(G)}{T(G)}\right) \tag{14.3}$$

mit den einzelnen Elementen:

$D(G,H)$ Distanz zwischen den zwei Netzwerken G und H

$\sum_{i=1}^{29}$ Summiert die Resultate der Differenzen zwischen den Netzwerken über alle Graphlets

$F_i(X)$ Berechnet den relativen Anteil des Graphlets i auf dem Netzwerk X. Zudem wird der negative Logarithmus verwendet, was dazu führt, dass kleinere Werte stärker gewichtet werden als grössere. Somit fallen selterene Graphlets stärker ins Gewicht.

Nachfolgend ein kleines Beispiel mit dem ersten Netzwerk in Abbildung 14.2 zur Berechnung der Relative Graphlet Frequency Distance. Achtung: Das Graphlet G_0 wird nicht berücksichtigt.

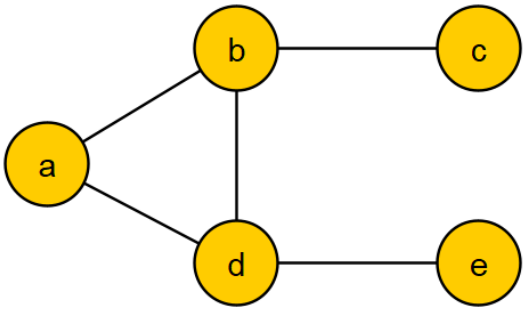


Abbildung 14.2: Beispiel-Netzwerk 1 zur Berechnung der Relative Graphlet Frequency Distance

Im Netzwerk in Abbildung 14.2 mit 5 Knoten und 5 Kanten existieren die folgenden Häufigkeiten der Graphlets:

G_1 4 $(F_1(N1) = -\log\left(\frac{4}{9}\right) = -\log(0.444) = 0.352)$

G_2 1 $(F_2(N1) = -\log\left(\frac{1}{9}\right) = -\log(0.111) = 0.954)$

G_3 1 $(F_3(N1) = -\log\left(\frac{1}{9}\right) = -\log(0.111) = 0.954)$

G_6 2 $(F_6(N1) = -\log\left(\frac{2}{9}\right) = -\log(0.222) = 0.653)$

G_{12} 1 $(F_{12}(N1) = -\log\left(\frac{1}{9}\right) = -\log(0.111) = 0.954)$

Somit resultieren im ersten Beispielnetzwerk total 9 Graphlets.

In der Abbildung 14.3 ist das zweite Beispiel-Netzwerk mit 5 Knoten und 6 Kanten:

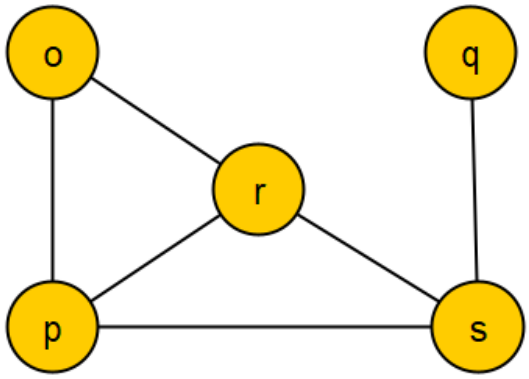


Abbildung 14.3: Beispiel-Netzwerk 2 zur Berechnung der Relative Graphlet Frequency Distance.

Im Netzwerk in Abbildung 14.2 existieren die folgenden Häufigkeiten der Graphlets:

G_1 4 $(F_1(N2) = -\log\left(\frac{4}{11}\right) = -\log(0.363) = 0.439)$

G_2 2 $(F_2(N2) = -\log\left(\frac{2}{11}\right) = -\log(0.182) = 0.740)$

G_3 2 $(F_3(N2) = -\log\left(\frac{2}{11}\right) = -\log(0.182) = 0.740)$

G_6 1 $(F_6(N2) = -\log\left(\frac{1}{11}\right) = -\log(0.091) = 1.041)$

G_7 1 $(F_7(N2) = -\log\left(\frac{1}{11}\right) = -\log(0.091) = 1.041)$

G_{19} 1 $(F_{19}(N2) = -\log\left(\frac{1}{11}\right) = -\log(0.091) = 1.041)$

Das zweite Netzwerk beinhaltet insgesamt 11 Graphlets.

Nun berechnet sich die Distanz zwischen den beiden Beispiel-Netzwerken wie folgt:

$$D(G,H) = \sum_{i=1}^{29} |F_i(G) - F_i(H)| =$$

$$|0.352 - 0.439| + |0.954 - 0.740| + |0.954 - 0.740| +$$

$$|0.653 - 1.041| + |0 - 1.041| + |0 - 0.954| + |1.041 - 0| =$$

$$0.087 + 0.241 + 0.241 + 0.388 + 1.041 + 0.954 + 1.041 = 3.993$$

Alternativ können die berechneten Funktionswerte F_i genutzt werden, um jedes Netzwerk als 29-dimensionalen Vektor abzubilden und dann anhand zu clustern, um in einer Vielzahl von Netzwerken diejenigen ausfindig zu machen, die sich strukturell am ähnlichsten sind.

14.2 Graphlet Degree Vektor

Im vorherigen Abschnitt wurde gezeigt, wie komplette Netzwerke anhand der Graphlet-Strukturen verglichen werden können. Die Graphlets können auch dafür verwendet werden, innerhalb eines Netzwerks Knoten zu finden, welche sich anhand der lokalen strukturellen Eigenheiten ähnlich sind unabhängig davon, wo sich diese im Netzwerk befinden.

Um dies zu bewerkstelligen, werden für die Knoten sogenannte *Graphet Decgree Vectors (GDV)* erstellt. Jede Dimension entspricht einem Orbit und die Anzahl Dimensionen entspricht den Orbits der zu untersuchenden Graphlets. Werden nur 2-Node Graphlets und 3-Node Graphlets untersucht, hat der Graphlet Degree Vektor jeweils 4 Dimensionen.

Nachfolgend in Abbildung 14.4 ein Beispiel, wie der Graphlet Degree Vector für den Knoten v berechnet wird. Oben links befindet sich das Beispiel-Netzwerk und rechts davon verschiedene Graphlets und die Orbits mit Kleinbuchstaben $a - d$. Unten links in der Tabelle ist der Graphlet Degree Vector für den Knoten v abgebildet und rechts davon aufgezeigt, von welchen Graphlets der Knoten v Teil ist und somit auch, welche Orbit-Positionen wie häufig eingenommen werden.

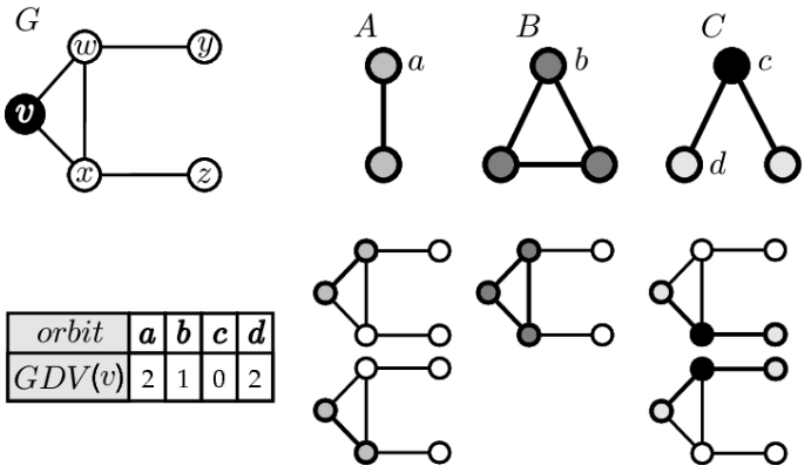


Abbildung 14.4: Berechnung des Graphlet Degree Vectors für ein Beispiel-Netzwerk aus [ARS17]

Diese Graphlet Degree Vektoren können natürlich auch noch normalisiert werden. In der Original-Publikation [MP08] fand sogar eine Gewichtung statt wo berücksichtigt wird, welche Orbits weitere Orbits beeinflussen. Denkbar wäre auch eine Normalisierung wie sie im vorherigen Abschnitt gemacht wurde bei der Berechnung der Relative Graphlet Frequency Distance. Diese wurde so normalisiert, dass selten erscheinende Graphlets stärker gewichtet werden. Auch hier könnte der gleiche Ansatz umgesetzt werden.

In der Abbildung 14.5 ist wieder das Karate-Club Netzwerk ersichtlich.

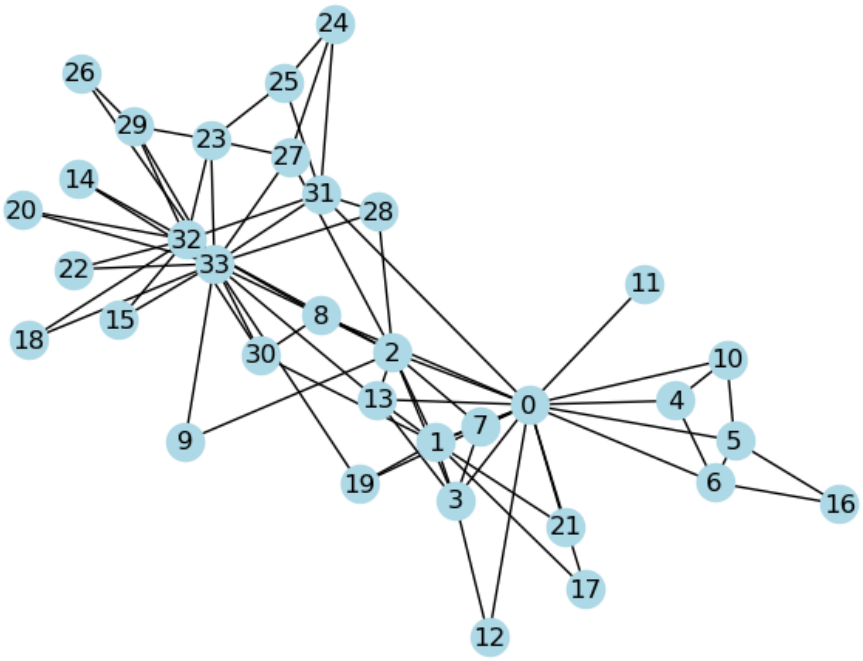


Abbildung 14.5: Karateclub als Beispiel-Netzwerk

Es wurden für alle Knoten der Graphlet Degree Vector für Graphlets bis zur Grösse 3 berechnet. Im Anschluss wurden die 4 Dimensionen mit t-SNE auf zwei Dimensionen reduziert. In der darauffolgenden Abbildung 14.6 ist nun die zweidimensionale Darstellung der Knoten ersichtlich. Es ist klar ersichtlich, dass Knoten, welche strukturelle Ähnlichkeiten haben, nun auch in der 2-dimensionalen Abbildung nahe beieinander liegen.

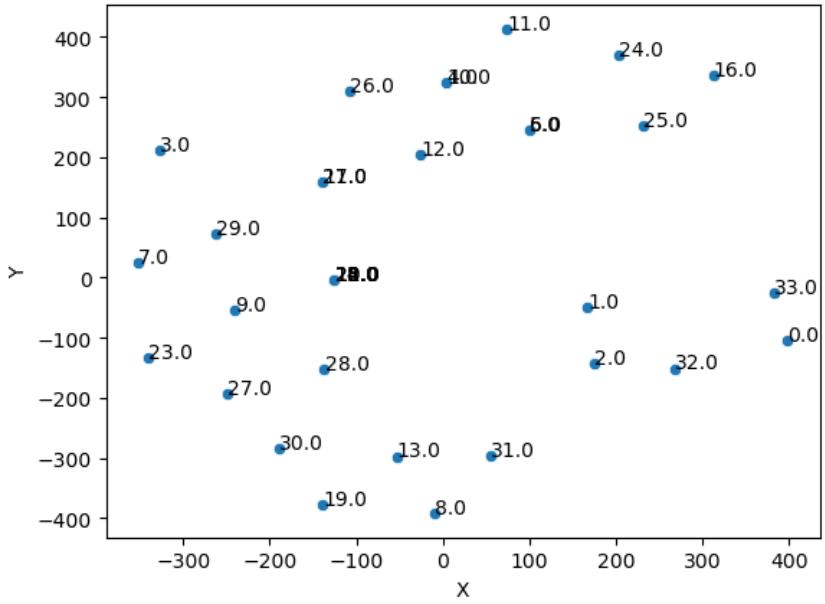


Abbildung 14.6: Mit t-SNE reduzierte Graphlet Degree Vektoren des Karate-Club Netzwerks.

In Abbildung 14.6 ist schön erkennbar, dass strukturell ähnliche Knoten im Vektorraum nahe beieinander abgebildet werden. Die beiden zentralsten Knoten 33 und 0 sind auf der rechten Seite nahe beieinander. Die Knoten 32, 1, und 2 sind ebenfalls in der Nähe, was auch Sinn macht, da diese ebenfalls sehr zentral sind. Oben rechts befinden sich die Knoten 11, 24, 16, 25, welche alle weit weg vom Zentrum und auch nicht sehr stark verbunden sind.

Literaturverzeichnis

[Ada] Lada Adamic. Coursera: Social network analaysis.

[AH97] Lisa R Anderson and Charles A Holt. Information cascades in the laboratory. *The American economic review*, pages 847–862, 1997.

[ARS17] David Oliveira Aparício, Pedro Manuel Pinto Ribeiro, and Fernando M. A. Silva. Extending the applicability of graphlets to directed networks. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 14:1302–1315, 2017.

[Ban92] Abhijit V Banerjee. A simple model of herd behavior. *The Quarterly Journal of Economics*, 107(3):797–817, 1992.

[BH06] Joachim Bauer and Armin Hauser. *Prinzip Menschlichkeit: Warum wir von Natur aus kooperieren.* Hoffmann und Campe Hamburg, 2006.

[Bou12] Pierre Bourdieu. ökonomisches kapital, kulturelles kapital, soziales kapital. In *Handbuch Bildungs-und Erziehungssoziologie*, pages 229–242. Springer, 2012.

[Bra02] Sebastian Braun. Soziales kapital, sozialer zusammenhalt und soziale ungleichheit. *Aus Politik und Zeitgeschichte*, 8(2002):29–30, 2002.

[DNMB11] Wouter De Nooy, Andrej Mrvar, and Vladimir Batagelj. *Exploratory social network analysis with Pajek*, volume 27. Cambridge University Press, 2011.

[Eve08] Sean S Everton. Tracking, destabilizing and disrupting dark networks with social networks analysis. 2008.

[Fre78] Linton C Freeman. Centrality in social networks conceptual clarification. *Social networks*, 1(3):215–239, 1978.

[Glo17] Peter A Gloor. Sociometrics and human relationships: Analyzing social networks to manage brands, predict trends, and improve organizational performance, 2017.

[Gol13] Jennifer Golbeck. *Analyzing the social web.* Newnes, 2013.

[Jan06] Dorothea Jansen. *Einführung in die Netzwerkanalyse: Grundlagen, Methoden, Forschungsbeispiele.* Springer-Verlag, 2006.

[KKT15] David Kempe, Jon M Kleinberg, and Éva Tardos. Maximizing the spread of influence through a social network. *Theory of Computing*, 11(4):105–147, 2015.

[LNK07] David Liben-Nowell and Jon Kleinberg. The link-prediction problem for social networks. *Journal of the American society for information science and technology*, 58(7):1019–1031, 2007.

[MAJ13] Ian McCulloh, Helen Armstrong, and Anthony Johnson. *Social network analysis with applications*. John Wiley & Sons, 2013.

[MP08] Tijana Milenkovic and Natasa Przulj. Uncovering biological network function via graphlet degree signatures, 2008.

[PDL18] Leto Peel, Jean-Charles Delvenne, and Renaud Lambiotte. Multiscale mixing patterns in networks. *Proceedings of the National Academy of Sciences*, 115(16):4057–4062, April 2018.

[Prz07] Natasa Przulj. Biological network comparison using graphlet degree distribution. *Bioinformatics*, 23(2):e177–e183, 01 2007.

[Rog10] Everett M Rogers. *Diffusion of innovations*. Simon and Schuster, 2010.

[Rom] Daniel Romero. Coursera: Applied social network analysis in python.

[Sco17] John Scott. *Social network analysis*. Sage, 2017.

[uNH] Anita Frischknecht und Nils Hänggi. Die selbstverkäufer.

[WF94] Stanley Wasserman and Katherine Faust. *Social network analysis: Methods and applications*, volume 8. Cambridge university press, 1994.

[ZAL14] Reza Zafarani, Mohammad Ali Abbasi, and Huan Liu. *Social media mining: an introduction*. Cambridge University Press, 2014.

Stichwortverzeichnis

Actor Group Centrality, 75
Adamic-Adar, 116
Adjazenzmatrix, 107
Aktor Zentralität, 62
Alternativhypothese, 105
Ansehen, 15, 72
Assortativity, 98
Assortativität, 98
Attribute, 42
Ausreisser, 94

Balance, 16, 87
Bestimmtheitsmass, 96
Betweeness Group Centrality, 76
Betweenness Centrality, 65
Betweenness Zentralisierung, 80
Bridge, 50, 89
Broker, 90
Brokerage Position, 66

Cambridge Analytica, 25
Clique, 46, 83
Closeness Centrality, 63
Closeness Group Centrality, 75
Closeness Zentralisierung, 81
Cluster Coefficient, 85
Clustering, 50
Co-Authorship Netzwerk, 118
Common Neighbours, 114
Community, 44
Configuration Model, 104, 112
Connected Component, 44, 46
    giant, 46
    strongly, 44
    weakly, 44
Connectivity, 89
Contextual View, 43
Cut-Vertex, 89

Degree Assortativität, 98
Degree Centrality, 62
Degree Distribution, 104
Degree Group Centrality, 75
Degree Zentralisierung, 79
Dichte, 83
Disassortativität, 98
Durchmesser (Graph), 84

Early Adopters, 122
Early Majority, 122
Edge Connectivity, 90
Edge-Betweenness Centrality, 50
Edge-Betweenness Clustering, 50
Ego Netzwerk, 43
Eigenvector Zentralität, 69
Einfluss, 63
Empfehlungssysteme, 31
Erdős-Rényi-Model, 104
Exchange Theory, 18

Facebook, 25
Firmenanalyse, 30

Gatekeeper, 66
GDV, 133
Gewichtete Transformation, 38
Giant Component, 46
Girvan-Neuman Clustering, 50
Global View, 42
Graph
    gerichtet, 34
    gewichtet, 35
    ungerichtet, 33
Graph Density, 83
Graph Diameter, 84
Graph Resilience, 89
Graphlet Degree Vector, 133
Graphlets, 129
Greedy Algorithmus, 126

Homogenität, 94
Homophilie, 14

Hypothesentest, 103
Hypothesentests, 105
    Dyadisch, 107
    Mixed, 110
    Monadisch, 106
    Netzwerkmetriken, 112

Indegree, 72
Indegree Centrality, 62
Indegree Popularity, 72
Indegree Prestige, 72
Independent Cascade Model, 124
Influencer, 27
Informations-Verbreitung, 30
Informationsfluss, 69
Innovation, 122
Innovations Diffusion, 122
Innovators, 122

Jaccard Coefficient, 115
Jaccard-Similarity, 40

k-connected, 90
Kanten, 33
    Bidirektional, 33
    ungerichtet, 33
Kanten-Attribute, 42
Kausalzusammenhang, 94
Knoten, 33
Knoten-Attribute, 42
Kommunikationsaktivität, 63
Kompletter Graph, 83
Korrelation, 92
Korrelationskoeffizient, 94

Label Propagation, 52
Laggards, 123
Late Majority, 122
Linearität, 95
Link-Prediction, 31, 113
Local View, 42
Looking Glass Self, 10
Louvain, 56

Marketing-Analyse, 30
Marketnig, 29
Maslowsche Bedürfnispyramide, 12
Microtargeting, 26
Mixing Matrix, 101
Modellierung, 35
Modularity, 56
Multirelationales Netzwerk, 36, 107

n-Cliques, 48
Netzwerk
    One-Mode, 35
    One-Mode Netzwerk
        Multirelationales Netzwerk, 36
        Signed Netzwerk, 36
    Two-Mode, 36
Netzwerk Zentralisierung, 78
Newman's weighted Projection, 38
Node Connectivity, 90
Normalisierung, 62
Null Modell, 103
Nullhypothese, 105
Nähe, 14, 63

OCEAN-Modell, 26
One-Mode Netzwerk, 35
Orbits, 129
Outdegree Centrality, 62
Overlap Weighted Projection, 40

p-Cliques, 48
Pearson Korrelation, 95
Persönlichkeitsprofil, 29
Preferential Attachment, 117
Prestige, 72
Primärgruppe, 10
Proximity Prestige, 72

QAP, 104, 109
Quadratic Assignment Procedure, 104, 109

Referenz-Netzwerk, 103
Resource Allocation, 116
Reziprozität, 14
Ring-Netzwerk, 79

Sentiment-Analyse, 30
Signed Netzwerk, 36
Signifikanz, 106
Signifikanz-Niveau, 105
Social Forces, 14
Soundarajan Hopcroft, 115
Soziale Anpassung, 15
Soziales Kapital, 20
Soziologie, 10
Spearman Korrelation, 96

Stern-Netzwerk, 79
Structural Hole, 19
StructuralEquivalence, 129
Subgraph, 44

t-Test, 103
Threshold Model, 128
Tie
    absent, 18
    strong, 17
    weak, 17
Tie Strength, 17
Transitivität, 16
Trend-Analyse, 30
Triaden, 16, 87
Two-Mode Netzwerk, 36
    Transformation zu One-Mode, 37

Verbrechensbekämpfung, 30
Voter Model, 128

Wahrnehmung, 63
Weighted Projection, 38

Zentralisierung (Netzwerk), 78
Zentralität (Aktor), 62